

POLITECNICO DI TORINO

Corso di Laurea Magistrale in Ingegneria Informatica
Orientamento Artificial Intelligence and Data Analytics

Dai pixel ai portafogli finanziari: generare scenari di mercato realistici tramite variational autoencoder

Riassunto della tesi

Candidato: Dylan Magliano (s337915) — Relatori: prof. Flavio Giobergia, dott. Sergio Caprioli,
dott. Emanuele Cagliero

Tesi svolta in collaborazione con Intesa Sanpaolo — Anno Accademico 2025–2026

1. Contesto e problema di ricerca

La matrice di correlazione fra i rendimenti degli asset è l'oggetto su cui poggia gran parte dell'analisi quantitativa dei portafogli, dalla formulazione di Markowitz in poi. Stimarla dalle sole serie storiche comporta però due limiti distinti, entrambi strutturali.

Il primo è il *rumore statistico*. Quando il numero di titoli N è dello stesso ordine di grandezza della lunghezza T della serie usata per la stima, la matrice empirica diventa instabile e il suo spettro si popola di autovalori spuri, un fenomeno studiato in modo sistematico dalla Random Matrix Theory.

Il secondo, più profondo, è la *limitatezza campionaria*: il passato offre una sola traiettoria fra tutte quelle che sarebbero state possibili. Configurazioni di mercato mai osservate nello specifico campione a disposizione, ma plausibili sul piano statistico, restano inaccessibili a qualunque analisi puramente storica.

Da qui la domanda di ricerca della tesi: è possibile costruire un modello generativo profondo che, appreso il modo in cui le correlazioni si organizzano nei dati reali, produca matrici di correlazione sintetiche nuove — matematicamente valide e strutturalmente indistinguibili da quelle vere — con cui popolare uno spazio di scenari più ricco di quello che la storia da sola può fornire? Il precedente più diretto in letteratura è CorrGAN (Marti, 2020), che affronta lo stesso problema con reti avversarie; il lavoro di Caprioli et al. (2024) mostra invece l'uso di un Variational Autoencoder su matrici storiche con ricampionamento nello spazio latente, impostazione metodologicamente affine a quella qui adottata.

2. Dati e pre-processing

Il fondamento empirico è un dataset di prezzi di chiusura rettificati dell'indice S&P 500 sul ventennio 2000–2020. Per garantire continuità delle serie ed evitare distorsioni campionarie, il paniere è stato filtrato richiedendo quotazioni ininterrotte sull'intero arco temporale: sopravvivono $N = 362$ titoli. La classificazione settoriale GICS, necessaria alle analisi di struttura gerarchica, non era disponibile da un provider strutturato ed è stata ricostruita tramite classificazione automatica affidata a un modello linguistico di grandi dimensioni (360 titoli su 362 classificati).

Dai prezzi si calcolano i log-rendimenti giornalieri e da questi, con una procedura a finestre mobili, le matrici di correlazione di Pearson. L'ampiezza della finestra è fissata a $T_w = 724$ giorni, esattamente il doppio del numero di asset: la scelta fissa per costruzione il rapporto di spettro $q = N/T_w = 0.5$, rendendo il livello di rumore omogeneo nel tempo e analiticamente governabile tramite i limiti di Marchenko–Pastur, e garantisce che ogni matrice sia di rango

pieno e dunque definita positiva. Con un passo di 10 giorni si ottengono 461 matrici.

Su questo insieme grezzo agisce un filtro di validità strutturale basato sulla proprietà di Perron–Frobenius empirica, che richiede al primo autovettore (il *market mode*) di avere componenti tutte dello stesso segno. Le prime 49 finestre non lo soddisfano; l’analisi puntuale mostra che si tratta di tutte e sole le finestre contenenti osservazioni antecedenti la metà di ottobre 2001, in cui l’unico titolo aurifero del paniere (NEM) risulta sistematicamente anticorrelato con il resto del listino nel suo tipico ruolo di bene rifugio. Non è un artefatto di misura ma la firma di un regime eccezionale, ed escluderlo delimita esplicitamente il dominio di validità del modello: restano **412 matrici valide**, poi mescolate casualmente e ripartite in 288 / 82 / 42 fra training, validation e test set. Il mescolamento casuale, in luogo del partizionamento cronologico, neutralizza il *distribution shift* di regime macroeconomico che nei test preliminari impediva alle architetture profonde di generalizzare.

Il vincolo di semidefinita positività e la parametrizzazione di Cholesky

Un passaggio metodologico decisivo riguarda la forma dell’input. Una matrice di correlazione deve essere semidefinita positiva (PSD): è un vincolo globale sullo spettro, non imponibile agendo separatamente sui singoli coefficienti. Nella prima versione della pipeline i modelli ricostruivano direttamente il triangolo inferiore della matrice di correlazione; le verifiche spettrali hanno rivelato la comparsa di autovalori negativi, e basta un solo autovalore negativo — anche di magnitudo trascurabile — perché la decomposizione di Cholesky fallisca e con essa l’intera simulazione di scenari.

La pipeline definitiva risolve il problema alla radice, cambiando l’oggetto appreso: ogni matrice viene decomposta come $\mathbf{C} = \mathbf{L}\mathbf{L}^T$ e ciò che viene linearizzato e dato in pasto ai modelli è il fattore triangolare inferiore $\mathbf{L}$, non la matrice. Qualunque vettore il decoder produca, la matrice $\hat{\mathbf{L}}\hat{\mathbf{L}}^T$ che se ne ricompone è una matrice di Gram e quindi PSD per costruzione, indipendentemente dalla qualità dell’apprendimento; una rinormalizzazione finale a diagonale unitaria riporta il risultato nel dominio della correlazione senza alterare i segni degli autovalori. L’input canonico è quindi un vettore di $D = N(N+1)/2 = 65\,703$ elementi.

3. Architetture e protocollo sperimentale

Il confronto segue un percorso incrementale su quattro modelli, tutti addestrati sulla medesima parametrizzazione Cholesky e valutati a parità di dimensione latente K :

1. **Principal Component Analysis**, benchmark lineare che fissa il limite massimo di compressione lineare;
2. **Autoencoder Lineare**, singolo layer denso senza bias né attivazioni, costruito per replicare quel sottospazio e verificare empiricamente il teorema di Bourlard e Kamp;
3. **Autoencoder Profondo**, design a imbuto $2048 \rightarrow 1024 \rightarrow 512 \rightarrow K$ con attivazioni LeakyReLU, che introduce la non-linearità;
4. **Variational Autoencoder**, che condivide l’encoder a imbuto del precedente ma sostituisce il bottleneck deterministico con un modulo di inferenza probabilistica ($\mu, \log \sigma^2$, *reparameterization trick*).

La *loss* di ricostruzione del VAE non è l’usuale errore quadratico medio, ma la **Divergenza di Jeffreys** fra le distribuzioni gaussiane associate alla matrice originale e a quella ricostruita. La motivazione è precisa: l’MSE tratta i coefficienti come grandezze indipendenti e risulta dominato dalle correlazioni di ampiezza maggiore, restando di fatto cieco sugli autovalori più piccoli dello spettro — proprio quelli che individuano i portafogli a varianza minima. Le matrici

inverse presenti nella formulazione di Jeffreys ribaltano questa gerarchia e pesano l'errore in termini relativi lungo ogni direzione dello spettro. Poiché anche il termine di ricostruzione è così una divergenza, esso è omogeneo al termine di regolarizzazione di Kullback–Leibler: l'obiettivo impiegato è di tipo VAE, composto dalla divergenza di Jeffreys nel dominio delle matrici e dalla divergenza di Kullback–Leibler nello spazio latente, con peso unitario ($\beta = 1$).

La valutazione combina due famiglie di metriche: errori spaziali (MSE, MAE, norma di Frobenius) e metriche topologiche costruite sul *Minimum Spanning Tree* (percentuale di archi in comune, indice di Jaccard, sovrapposizione dei nodi a più alta *betweenness centrality*, scarti di lunghezza media dei cammini). Le seconde servono a verificare che una ricostruzione accurata “in media” non abbia comunque alterato la gerarchia dei legami fra i titoli.

4. Risultati sulla ricostruzione storica

Le misurazioni confermano empiricamente il teorema di Bourlard e Kamp: PCA e Autoencoder Lineare convergono, a parità di K , sul medesimo limite di errore. L'Autoencoder Profondo supera nettamente tale soglia a ogni K e senza mostrare segni di *overfitting*: a $K = 20$ il suo MSE di test (7.19×10^{-5}) è di quasi quattro volte inferiore a quello della PCA (2.73×10^{-4}). Il vantaggio della non-linearità si rivela di *efficienza rappresentativa*: l'AE raggiunge già con $K = 10$ la stessa qualità che la PCA ottiene soltanto con $K = 100$.

Il Variational Autoencoder si colloca in posizione intermedia. A $K = 20$ ottiene un MSE di 1.55×10^{-4} , **inferiore** sia a quello della PCA sia a quello dell'Autoencoder Lineare, pur restando superiore a quello dell'Autoencoder Profondo deterministico. MAE e norma di Frobenius restituiscono esattamente la stessa graduatoria, il che indica che l'ordinamento non è un artefatto della sensibilità dell'MSE agli *outlier*. Il quadro topologico è ancora più netto e coerente: sull'*edge overlap* dell'MST il VAE recupera i due terzi della distanza fra modelli lineari e Autoencoder Profondo (88.4% contro 83.0% della PCA e 91.1% dell'AE). Il costo che la regolarizzazione variazionale impone alla fedeltà di ricostruzione è quindi contenuto, e minore di quanto una prima intuizione suggerirebbe.

Tre run condotte a $K \in \{10, 20, 30\}$, identiche in ogni altro iperparametro, mostrano un comportamento peculiare del VAE: l'errore di ricostruzione *peggiora* lievemente al crescere di K , all'opposto degli altri tre modelli. L'analisi dello spettro di attività dello spazio latente ne suggerisce una spiegazione: in tutte e tre le configurazioni solo circa sei dimensioni risultano effettivamente attive, mentre le restanti subiscono un *posterior collapse*. La dimensionalità effettiva della *manifold* delle correlazioni emerge dunque non come un iperparametro da calibrare, ma come una proprietà dei dati che il modello individua da sé; aggiungere dimensioni nominali non accresce la capacità utilizzata e amplia soltanto lo spazio su cui il vincolo di conformità al *prior* deve essere soddisfatto. La scelta di $K = 20$ — compiuta prima delle due run supplementari, sul gomito della curva di ricostruzione dei modelli deterministici — non è dunque un *optimum* empirico del VAE (a $K = 10$ l'errore di ricostruzione è anzi lievemente inferiore), ma un compromesso metodologico che queste prove mostrano essere poco critico.

5. Generazione stocastica di scenari e validazione

È sul piano generativo che il VAE mostra il proprio valore distintivo. L'Autoencoder Profondo deterministico, per quanto superiore nella pura ricostruzione, dispone di uno spazio latente frammentario e privo di significato al di fuori dei punti osservati: campionarvi un vettore casuale tende a produrre output privi di coerenza economico-finanziaria. La regolarizzazione di Kullback–Leibler, unita al rumore di campionamento, modella invece uno spazio latente continuo e denso, in cui è possibile campionare in modo significativo. La sintesi più efficace dei risultati è questa complementarità: *l'AE per ricordare, il VAE per immaginare*.

La procedura di generazione effettivamente adottata non è però un semplice campionamento dal *prior* $\mathcal{N}(\mathbf{0}, \mathbf{I})$, che produrrebbe uno scenario plausibile qualsiasi, scollegato dal presente. L'obiettivo è più specifico: costruire una distribuzione di scenari sintetici della struttura di correlazione *a un orizzonte nominale di 21 giorni a partire dallo stato di mercato osservato oggi*, con cui stimare la possibile variabilità delle correlazioni in ottica di rischiosità. La tecnica impiegata è un **block-bootstrap storico nello spazio latente**, articolato in quattro passaggi: l'encoder ricostruisce la traiettoria latente storica giorno per giorno; se ne calcolano gli incrementi giornalieri; si campiona casualmente un blocco di 21 incrementi consecutivi (un mese lavorativo) e se ne cumula il salto; il salto viene sommato allo stato attuale e decodificato, ottenendo per costruzione una matrice PSD. Ripetendo mille volte si ottiene una distribuzione di evoluzioni possibili, ancorata al presente ma diversificata dalla variabilità storica campionata a blocchi.

I mille scenari così prodotti sono stati validati rispetto ai cinque fatti stilizzati delle matrici di correlazione finanziarie, ciascuno tradotto in un indicatore scalare confrontabile con la matrice odierna e con l'intervallo osservato sulle 412 matrici reali:

1. **Distribuzione *pairwise* asimmetrica verso valori positivi:** media fra 0.4609 e 0.5352 su tutti gli scenari, contro 0.4512 della matrice odierna.
2. **Spettro e Marchenko–Pastur:** autovalore di mercato λ_1 nell'intervallo $[172.4, 197.2]$ contro 169.1 odierno, circa due ordini di grandezza oltre il limite superiore del *bulk*, accompagnato da 7–9 modi settoriali.
3. **Proprietà di Perron–Frobenius:** componente minima del *market mode* sempre positiva, con margine dalla soglia di violazione superiore a quello della stessa matrice odierna.
4. **Struttura gerarchica settoriale:** rapporto fra correlazione media intra-settore e inter-settore sempre maggiore di 1 e interno all'intervallo storico; i dendrogrammi riproducono visivamente gli stessi blocchi cromatici settoriali della matrice reale.
5. **Topologia *scale-free* del MST:** esponente della legge di potenza compreso fra 2.053 e 2.306, dentro l'intervallo $2 < \gamma < 3$ atteso dalla letteratura.

L'esito è che **tutti e 1000 gli scenari soddisfano simultaneamente i cinque criteri**, e tutte le matrici risultano definite positive, in linea con la semidefinita positività garantita per costruzione dalla parametrizzazione di Cholesky. L'ispezione grafica di dettaglio su un singolo scenario corrobora il quadro anche sugli oggetti che nessun indicatore scalare può riassumere: la similarità coseno rispetto alla matrice odierna è 0.9999 sul *market mode* e 0.9893 e 0.9883 sui due modi settoriali successivi.

6. Limiti e sviluppi futuri

Il lavoro dichiara esplicitamente i propri limiti metodologici. La verifica aggregata riduce ciascun fatto stilizzato a un indicatore scalare, mentre l'ispezione visiva completa resta limitata a un singolo scenario rappresentativo; i mille scenari derivano inoltre da blocchi di 21 giorni ampiamente sovrapposti, con numerosità campionaria effettiva inferiore a mille, e l'intera verifica è ancorata a un unico stato di mercato di partenza. Il mescolamento casuale, pur affrontando il *distribution shift*, non elimina la sovrapposizione informativa fra finestre adiacenti (fino al 98.6% di osservazioni condivise), il che costituisce un rischio limitato ma reale di ottimismo nelle metriche di generalizzazione. Il confronto fra modelli, infine, non copre uniformemente tutte le dimensioni latenti per il VAE, e la classificazione settoriale GICS non è stata validata con fonti ufficiali.

Il proseguimento naturale è l'applicazione della distribuzione di scenari generata alla gestione

del rischio di portafoglio, confrontando il quadro che se ne ricava con quello ottenibile dai soli dati storici. Seguono il rafforzamento della validazione statistica — ripetendo la verifica a partire da una pluralità di stati iniziali distribuiti lungo il ventennio ed estendendola da indicatori scalari a test formali di aderenza distributiva — il confronto diretto con paradigmi generativi alternativi (CorrGAN, e più in generale i modelli di diffusione), e l'estensione della pipeline ad altre *asset class* e a panieri di titoli internazionali.

7. Conclusione

La tesi ha progettato, implementato e valutato empiricamente un framework completo per la compressione, ricostruzione e generazione stocastica di matrici di correlazione finanziarie realistiche. Il risultato più significativo è che la parametrizzazione di Cholesky risolve strutturalmente il vincolo di semidefinita positività, e che su questa base il Variational Autoencoder paga un costo contenuto in fedeltà di ricostruzione — restando anzi superiore ai benchmark lineari — in cambio della proprietà che rende possibile la generazione stocastica. La conformità simultanea dei mille scenari generati ai cinque fatti stilizzati supporta l'impiego dell'architettura proposta come strumento autonomo per la produzione di ecosistemi finanziari sintetici matematicamente coerenti.