

POLITECNICO DI TORINO

Corso di Laurea Magistrale in Ingegneria Informatica

Orientamento Artificial Intelligence and Data Analytics

Tesi di Laurea Magistrale

Dai pixel ai portafogli finanziari: generare scenari di mercato realistici tramite variational autoencoder



Relatori

prof. Flavio Giobergia

prof. Sergio Caprioli

firma dei relatori

.....
.....

Candidato

Dylan Magliano

firma del candidato

.....

Anno Accademico 2025-2026

A mio padre

† A mio nonno Pino

Sommario

Il presente lavoro di tesi si inserisce nel contesto della finanza quantitativa, affrontando le limitazioni dei modelli deterministici nella stima delle matrici di correlazione empiriche, tipicamente affette da rumore statistico e limiti di campionamento storico. L'obiettivo centrale è testare l'efficacia dei *Variational Autoencoder* (VAE) come modello generativo stocastico per la simulazione di scenari di mercato realistici. Un vincolo matematico imprescindibile in questo dominio è che le matrici sintetiche prodotte risultino rigorosamente semidefinite positive (PSD), proprietà che il framework garantisce strutturalmente modellando la decomposizione di Cholesky delle matrici stesse.

La metodologia delinea un percorso evolutivo, basato sui rendimenti giornalieri di un campione rappresentativo di 362 titoli dell'indice S&P 500 nell'orizzonte temporale 2000-2020. Per valutare il potere ricostruttivo dei vari modelli nelle diverse configurazioni degli spazi latenti K , le matrici vengono analizzate impiegando sia metriche di errore classiche (MSE, MAE, norma di Frobenius) e strutturali (MST), sia l'aderenza ai fatti stilizzati. Lo studio stabilisce inizialmente un *benchmark* lineare tramite la Principal Component Analysis (PCA), per poi passare all'implementazione di Autoencoder Lineari (Linear AE) in grado di approssimarne il sottospazio. Il passo successivo prevede l'integrazione della non-linearità attraverso Autoencoder Profondi (AE), dimostrando come la stratificazione profonda consenta di catturare in modo più fedele la complessa curvatura geometrica delle interdipendenze finanziarie.

Questo percorso di affinamento strutturale trova la sua naturale e logica conclusione nell'evoluzione verso i VAE. Introducendo una componente probabilistica nello spazio latente, il VAE capitalizza la capacità di astrazione appresa nelle fasi deterministiche precedenti per abilitare una generazione di scenari puramente stocastica.

Per quanto concerne l'output generativo, le nuove matrici sintetiche campionate dal VAE vengono valutate esclusivamente sulla base della loro conformità ai cinque fatti stilizzati (*stylized facts*) caratteristici delle matrici di correlazione finanziarie. Nello specifico, le matrici generate dimostrano una rigorosa aderenza a tali proprietà fondamentali: distribuzione asimmetrica verso valori positivi, conformità dello spettro degli autovalori alla distribuzione di Marchenko-Pastur, validità della proprietà di Perron-Frobenius, conservazione della struttura gerarchica (tramite *clustering* gerarchico) e topologia *scale-free* del *Minimum Spanning Tree* (MST). Ciò valida l'architettura proposta come uno strumento solido e autonomo per la generazione di ecosistemi finanziari matematicamente coerenti.

Indice

I	Fondamenti Teorici	7
1	Introduzione	9
1.1	Contesto generale e problematica della generazione di scenari	9
1.2	Definizione del problema di ricerca e motivazione dell'uso dei modelli generativi profondi	9
1.3	Obiettivi della tesi	10
2	Matrici di Correlazione in Ambito Finanziario	13
2.1	Il ruolo della correlazione e la necessità di previsioni future (Markowitz) . .	13
2.2	Il problema del rumore nelle matrici empiriche	14
2.3	Generazione di scenari stocastici futuri tramite decomposizione di Cholesky	14
3	Fatti Stilizzati delle Matrici di Correlazione	17
3.1	Introduzione alle proprietà strutturali dei mercati reali	17
3.2	Distribuzione asimmetrica delle correlazioni pairwise	18
3.3	Analisi spettrale e distribuzione di Marchenko-Pastur	18
3.4	Proprietà di Perron-Frobenius empirica	19
3.5	Struttura gerarchica delle correlazioni	20
3.6	Il Minimum Spanning Tree (MST) e la proprietà scale-free	20
3.7	Benchmark test: fallimento strutturale della Random Matrix Theory . . .	21
4	Riduzione della Dimensionalità e Modelli Generativi	23
4.1	Principal Component Analysis (PCA): teoria e limiti lineari	23
4.2	Autoencoder Lineari (Linear AE): ponte verso le reti neurali	24
4.3	Autoencoder Profondi (AE): introduzione alla non-linearità	25
4.4	Variational Autoencoders (VAE) e regolarizzazione dello spazio latente . .	25
II	Metodologia e Pipeline di Analisi	27
5	Pre-processing e Costruzione del Dataset	29
5.1	Descrizione del dataset	29
5.2	Calcolo dei rendimenti e stima delle matrici empiriche	30
5.3	Tecnica di campionamento: il Random Shuffle per la stazionarietà	30

5.4	Estrazione e flattening delle matrici triangolari inferiori	31
6	Architetture dei Modelli e Setup Sperimentale	33
6.1	Implementazione della PCA come baseline	33
6.2	Design e iperparametri dell'Autoencoder Lineare	33
6.3	Design e iperparametri dell'Autoencoder Non-Lineare	34
6.4	Design e iperparametri del VAE	35
6.5	Metriche di valutazione e criteri di convergenza	35
III	Risultati, Validazione e Applicazioni	37
7	Analisi della Compressione e Ricostruzione Storica	39
7.1	Valutazione della PCA e dell'AE Lineare: il benchmark della linearità . . .	39
7.2	Performance di ricostruzione: AE Non-Lineare e VAE	40
7.3	Il trade-off tra compressione esatta e flessibilità generativa	40

Parte I

Fondamenti Teorici

Capitolo 1

Introduzione

1.1 Contesto generale e problematica della generazione di scenari

Nell'analisi dei dati e nella modellizzazione di sistemi complessi, la disponibilità di scenari ampi e diversificati è un requisito fondamentale per testare la robustezza di qualsiasi framework analitico. Tradizionalmente, in ambito quantitativo, gli operatori si affidano alle serie storiche per campionare le matrici di correlazione empiriche, le quali quantificano le interdipendenze tra le diverse variabili in gioco. Tuttavia, l'uso esclusivo dei dati storici presenta una criticità intrinseca e ineliminabile: il passato offre solamente una singola traiettoria degli eventi possibili.

Questa limitatezza campionaria impedisce di esplorare configurazioni alternative o eventi estremi che, pur non essendosi mai verificati nello specifico campione a disposizione, risultano statisticamente plausibili. Per superare questo ostacolo, l'analisi moderna si affida ampiamente a metodologie di simulazione che necessitano di generatori di dati capaci di produrre scenari sintetici. L'efficacia e l'affidabilità di tali simulazioni dipendono in maniera critica dal realismo delle matrici generate: se i modelli matematici sottostanti non riescono a catturare fedelmente le interdipendenze profonde e la complessa topologia dei dati reali, gli scenari prodotti risultano distorti e privi di utilità pratica.

1.2 Definizione del problema di ricerca e motivazione dell'uso dei modelli generativi profondi

Il principale ostacolo nell'applicazione pratica e nella generazione di scenari risiede nella natura intrinseca delle matrici di correlazione empiriche. Quando stimata a partire da serie storiche, la matrice soffre in modo significativo del problema del rumore statistico. Quando il numero di variabili analizzate (N) è dello stesso ordine di grandezza della lunghezza della serie storica (T), la matrice empirica diventa instabile, introducendo autovalori spuri che ne degradano l'affidabilità informativa, un fenomeno ampiamente studiato nell'ambito della *Random Matrix Theory* (RMT).

Nel presente lavoro, l'analisi si concentra sui rendimenti giornalieri dei titoli componenti l'indice S&P 500 estratti lungo un ampio orizzonte temporale ventennale, compreso tra il 2000 e il 2020. Al fine di garantire la coerenza e la continuità della serie storica, la ricerca isola un paniere target di 362 asset, selezionando esclusivamente le aziende che presentano quotazioni ininterrotte lungo l'intero arco temporale considerato.

I metodi tradizionali per simulare o gestire il rumore in tali matrici presentano forti limiti: tendono a linearizzare le relazioni, eliminano anomalie informative preziose o rimangono strettamente vincolati alla dinamica storica, impedendo l'effettiva esplorazione di scenari inediti. In questo panorama, i modelli generativi profondi (*Deep Generative Models*) offrono un cambio di paradigma radicale. Architetture basate sui *Variational Autoencoders* (VAE) consentono di mappare lo spazio ad alta dimensionalità delle matrici empiriche in uno spazio latente continuo, dal quale è possibile campionare in modo stocastico.

Per garantire che le matrici sintetiche generate risultino rigorosamente semidefinite positive (PSD) — un vincolo algebrico imprescindibile per qualsiasi matrice di correlazione valida — l'input dei modelli non si basa sulla matrice cruda, bensì sulla sua decomposizione di Cholesky. Attraverso questa parametrizzazione, i modelli apprendono a comprimere e successivamente riprodurre l'intera struttura informativa nel pieno rispetto dei vincoli matematici.

Al fine di mappare con rigore scientifico le capacità di questi strumenti, il framework introduce un percorso di validazione applicato uniformemente alle tecniche testate — Principal Component Analysis (PCA), Autoencoder Lineari (Linear AE), Autoencoder Profondi (AE) e Variational Autoencoder (VAE). L'integrazione di metriche di errore matematico classiche combinate con metriche topologiche permette di valutare sia il potere ricostruttivo delle architetture di base, sia l'effettiva capacità del VAE di generare ecosistemi realistici.

1.3 Obiettivi della tesi

Il presente lavoro di tesi si propone di progettare, implementare e testare un framework basato su architetture neurali profonde per la compressione, ricostruzione e generazione stocastica di matrici di correlazione realistiche.

Gli obiettivi specifici della ricerca possono essere declinati nei seguenti punti:

1. **Sviluppo della pipeline di pre-processing:** Definire una procedura rigorosa per l'estrazione e la pulizia dei dati dell'S&P 500 (2000-2020). Al fine di garantire la continuità delle serie storiche ed evitare distorsioni campionarie, i dati sono stati filtrati richiedendo la presenza ininterrotta delle quotazioni per l'intero ventennio, isolando così un bacino di studio di 362 asset. Viene successivamente implementata la decomposizione di Cholesky per ottimizzare l'input per le reti neurali e garantire strutturalmente la positività semidefinita delle matrici prodotte.
2. **Studio comparativo del potere ricostruttivo:** Valutare le performance di compressione e ricostruzione storica seguendo un approccio metodologico incrementale: dall'istituzione di un *benchmark* lineare (PCA), alla sua approssimazione neurale

(Linear AE), fino all'introduzione della non-linearità (AE). L'obiettivo è dimostrare quantitativamente, tramite metriche di errore spaziale (MSE, MAE, norma di Frobenius) e topologiche (MST), come le architetture profonde superino i limiti dei modelli lineari nelle varie configurazioni dello spazio latente K .

3. **Integrazione probabilistica e generazione stocastica:** Superare i limiti di simulazione deterministica introducendo una componente probabilistica nello spazio latente attraverso i Variational Autoencoder (VAE). Lo scopo centrale è testare l'esclusiva capacità generativa del modello, campionando matrici sintetiche inedite e validandone la robustezza sulla base della loro conformità ai cinque *fatti stilizzati* fondamentali delle matrici di correlazione finanziarie empiriche.

Capitolo 2

Matrici di Correlazione in Ambito Finanziario

2.1 Il ruolo della correlazione e la necessità di previsioni future (Markowitz)

La formalizzazione moderna del concetto di diversificazione trova il suo fondamento nella *Modern Portfolio Theory* (MPT), introdotta da Harry Markowitz nel 1952. Il paradigma fondamentale si basa su un principio molto intuitivo: un investitore razionale cerca sempre di massimizzare il rendimento atteso minimizzando al contempo il rischio complessivo del proprio portafoglio. In questo contesto, il rischio non dipende solamente dalla volatilità dei singoli asset isolati, ma soprattutto da come questi si muovono congiuntamente nel tempo.

Questa dinamica di co-movimento è catturata geometricamente e matematicamente dalla matrice di correlazione. Il potere della diversificazione risiede interamente nelle proprietà di questa matrice: inserendo in un portafoglio titoli che non si muovono in perfetta sincronia (ovvero con una correlazione inferiore a 1), il rischio di sistema risulta strettamente inferiore alla semplice somma dei rischi individuali.

Tuttavia, l'applicazione pratica di questo principio si scontra con un limite temporale cruciale. Ottimizzare un portafoglio o calcolarne i rischi basandosi esclusivamente sulla matrice di correlazione storica significa assumere implicitamente che le interdipendenze del passato rimangano immutate. Nella realtà, i mercati finanziari sono ecosistemi altamente dinamici e la struttura delle correlazioni è soggetta a continui mutamenti, specialmente nei periodi di stress.

Le decisioni di investimento e di gestione del rischio vengono prese nel presente, ma i loro effetti si manifestano nel futuro. Per questo motivo, l'obiettivo moderno della finanza quantitativa non è semplicemente descrivere il passato, ma **prevedere la struttura di correlazione futura**. Nello specifico del nostro framework, lo scopo è sviluppare modelli in grado di apprendere le dinamiche complesse del mercato per generare scenari realistici e prevedere le matrici di correlazione a **un mese di distanza nel futuro**. Solo anticipando

l'evoluzione delle dipendenze a un orizzonte di 21 giorni lavorativi (1 mese) è possibile costruire strategie robuste, evitando che il portafoglio crolli in performance non appena testato fuori campionario.

2.2 Il problema del rumore nelle matrici empiriche

Nella pratica finanziaria, la vera matrice di correlazione della popolazione non è osservabile direttamente. Gli analisti si affidano quindi allo stimatore campionario standard, partendo dalle serie storiche dei rendimenti degli asset.

Questo approccio incontra un limite strutturale severo, noto come la “maledizione della dimensionalità” o problema del rumore statistico. L'accuratezza dello stimatore dipende in modo critico dal parametro di spettro q , definito come il rapporto tra la dimensione spaziale e quella temporale del dataset:

$$q = \frac{N}{T} \quad (2.1)$$

dove N è il numero di asset e T è la lunghezza della serie storica (giorni di negoziazione).

Nei mercati moderni, la necessità di analizzare panieri ad alta dimensionalità (come il nostro sottoinsieme dell'indice S&P 500, dove $N = 362$) si scontra con la limitatezza dei dati storici stazionari. Quando la lunghezza temporale T non è infinitamente superiore al numero di asset N , la matrice empirica accumula un livello di rumore campionario così elevato da perdere consistenza statistica.

Dal punto di vista dell'algebra lineare, l'instabilità si manifesta macroscopicamente attraverso lo spettro degli autovalori della matrice. Gli autovalori più piccoli tendono artificialmente verso lo zero, mentre i più grandi vengono sistematicamente sovrastimati. L'impatto operativo di tale distorsione è dirompente: gli algoritmi finiscono per allocare la maggior parte del capitale sfruttando autovalori minuscoli che non descrivono reali relazioni di diversificazione, ma sono meri artefatti statistici. Il risultato pratico è un collasso delle performance su dati reali (*out-of-sample breakdown*).

2.3 Generazione di scenari stocastici futuri tramite decomposizione di Cholesky

Per far fronte al problema del rumore e alla necessità di valutare il portafoglio a un mese di distanza, i sistemi di *risk management* si affidano a metodologie di simulazione avanzate, come i motori Monte Carlo. Il cuore di tali simulazioni risiede nella capacità di generare migliaia di scenari stocastici futuri che preservino rigorosamente la struttura delle dipendenze del mercato reale.

Supponendo di voler simulare scenari a un mese nel futuro, il processo richiede di proiettare la struttura di correlazione attesa su vettori stocastici indipendenti $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N)$. Per compiere questa operazione in modo matematicamente coerente, è fondamentale che la matrice di correlazione sintetica $\mathbf{C}$ sia simmetrica e definita positiva (PSD). Se questa proprietà è rispettata, è possibile calcolare la sua decomposizione di Cholesky, individuando

una matrice triangolare inferiore $\mathbf{L}$ tale per cui:

$$\mathbf{C} = \mathbf{L}\mathbf{L}^T \quad (2.2)$$

Il vettore dei rendimenti simulati per l'orizzonte temporale futuro viene quindi sintetizzato applicando una trasformazione lineare basata su $\mathbf{L}$ alle variabili casuali indipendenti.

Se la matrice di correlazione generata dai modelli deterministici classici perde la proprietà di positività semidefinita (a causa di rumore, arrotondamenti o errori di previsione), l'estrazione di Cholesky fallisce, rendendo impossibile la simulazione dello scenario. Inoltre, i metodi tradizionali non riescono a simulare efficacemente gli *shock* asimmetrici. È in questo spazio che si inserisce la necessità di un'architettura generativa profonda (come i VAE) che garantisca matematicamente la correttezza algebrica della scomposizione di Cholesky e, al tempo stesso, sia in grado di prevedere la reale morfologia delle correlazioni finanziarie a un mese di distanza.

Capitolo 3

Fatti Stilizzati delle Matrici di Correlazione

3.1 Introduzione alle proprietà strutturali dei mercati reali

In finanza quantitativa, il termine *stylized facts* (fatti stilizzati) identifica un insieme di regolarità statistiche ed empiriche ampiamente verificate nei mercati finanziari globali, le quali risultano persistenti nel tempo, invarianti rispetto alle diverse asset class e indipendenti dagli specifici orizzonti temporali di campionamento. Sebbene l'andamento individuale dei prezzi dei titoli segua dinamiche fortemente stocastiche e apparentemente caotiche, le relazioni di interdipendenza congiunta manifestano vincoli geometrici e topologici estremamente rigidi.

Quando si analizza un sistema ad alta dimensionalità composto da attività finanziarie reali — come il paniere rappresentativo di 100 asset estratti dall'indice S&P 500 nell'orizzonte 2000-2020 — la relativa matrice di correlazione empirica $\hat{C}$ cessa di essere un mero aggregato statistico di coefficienti indipendenti. Essa assume invece la natura di un operatore strutturato che riflette l'organizzazione interna del sistema economico.

Identificare e formalizzare queste proprietà strutturali è un prerequisito fondamentale per la validazione di qualsiasi modello di compressione o generazione. Un framework generativo basato su *deep learning*, come un Variational Autoencoder, non deve semplicemente minimizzare un errore di ricostruzione puntuale (come l'MSE), ma deve dimostrare la capacità matematica di preservare e sintetizzare ex-novo tali regolarità biologiche del mercato. Al fine di tracciare un confine netto tra le informazioni strutturali e il rumore statistico puramente casuale, la letteratura scientifica definisce cinque proprietà geometriche essenziali che caratterizzano univocamente i mercati reali.

3.2 Distribuzione asimmetrica delle correlazioni pairwise

La prima proprietà macroscopica di una matrice di correlazione finanziaria reale risiede nella morfologia della distribuzione di probabilità dei suoi elementi fuori diagonale C_{ij} con $i \neq j$, noti come coefficienti *pairwise*.

In un mercato teorico puramente casuale, in cui i rendimenti dei titoli fossero ortogonali e statisticamente indipendenti, la distribuzione empirica dei coefficienti di correlazione si presenterebbe come una curva simmetrica centrata esattamente sullo zero, le cui fluttuazioni campionarie attorno al valore nullo dipenderebbero unicamente dalla limitatezza della serie storica T .

Al contrario, nei mercati finanziari reali si osserva un fenomeno sistematico di deviazione statistica (*distribution shift*). La distribuzione delle correlazioni *pairwise* è marcatamente asimmetrica e significativamente spostata verso valori positivi, con una media campionaria stabilmente superiore allo zero, tipicamente confinata nell'intervallo $[0.2, 0.5]$. Questo spostamento globale riflette l'esistenza del cosiddetto "effetto mercato" o fattore di rischio sistematico: in condizioni macroeconomiche ordinarie, e in modo ancora più esasperato durante i crolli finanziari, la quasi totalità degli asset tende a muoversi nella medesima direzione, spinta da shock sistemici globali che dominano sulle componenti idiosincratiche dei singoli titoli.

3.3 Analisi spettrale e distribuzione di Marchenko-Pastur

L'analisi dello spettro degli autovalori fornisce la descrizione algebrica più profonda della struttura informativa contenuta in $\hat{\mathbf{C}}$. Sia $\{\lambda_1, \lambda_2, \dots, \lambda_N\}$ l'insieme degli autovalori stabili della matrice di correlazione empirica, ordinati in senso decrescente tale per cui $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$.

Il punto di riferimento matematico per isolare il rumore è fornito dalla *Random Matrix Theory* (RMT). Sotto l'ipotesi nulla che la matrice dei dati $\mathbf{X} \in \mathbb{R}^{N \times T}$ sia composta da variabili aleatorie indipendenti e identicamente distribuite con media nulla e varianza unitaria, lo spettro degli autovalori della matrice empirica, nel limite $N \rightarrow \infty, T \rightarrow \infty$ con rapporto di spettro $q = N/T$ costante, converge rigorosamente alla densità di probabilità di Marchenko-Pastur (MP):

$$P(\lambda) = \frac{1}{2\pi q} \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{\lambda} \cdot \mathbb{I}_{[\lambda_-, \lambda_+]}(\lambda) \quad (3.1)$$

I confini teorici dello spettro di puro rumore, noti come *bulk* di Marchenko-Pastur, sono definiti analiticamente dai limiti rigidi:

$$\lambda_{\pm} = (1 \pm \sqrt{q})^2 \quad (3.2)$$

Quando si analizza lo spettro di una matrice di correlazione reale, l'evidenza empirica mostra una violazione drammatica della legge di Marchenko-Pastur, ripartendo gli autovalori in tre componenti distinte:

1. **Il primo autovalore dominante** ($\lambda_1 \gg \lambda_+$): Si osserva un singolo autovalore di magnitudo straordinaria che si colloca ordini di grandezza al di sopra del limite superiore del *bulk* casuale. Questo autovalore cattura l'effetto mercato descritto nella sezione precedente e da solo spiega una frazione enorme (spesso superiore al 30-40%) della varianza totale del sistema finanziario.
2. **Gli autovalori settoriali intermedi** ($\lambda_k > \lambda_+$): Un ristretto numero di autovalori intermedi riesce a violare il limite λ_+ , posizionandosi al di fuori della densità di MP. Questi autovalori descrivono le interdipendenze stabili esistenti tra gruppi di asset appartenenti a specifici comparti industriali o economici.
3. **Il bulk del rumore** ($\lambda \leq \lambda_+$): La stragrande maggioranza dei rimanenti autovalori (spesso oltre il 90% del totale) rimane confinata all'interno dell'intervallo $[\lambda_-, \lambda_+]$. Questa porzione dello spettro è statisticamente indistinguibile dal puro rumore bianco, confermando che la frazione predominante delle relazioni puntuali descritte dalle matrici empiriche è priva di reale contenuto informativo stazionario.

3.4 Proprietà di Perron-Frobenius empirica

La natura dominante del primo autovalore λ_1 trova una rigorosa formalizzazione nelle proprietà dell'autovettore ad esso associato, indicato come $\mathbf{v}_1 = [v_{1,1}, v_{1,2}, \dots, v_{1,N}]^T$. In ambito puramente matematico, il teorema di Perron-Frobenius stabilisce che per matrici a elementi strettamente non negativi, l'autovettore principale possiede componenti tutte dello stesso segno.

Sebbene le matrici di correlazione finanziaria empiriche non siano strettamente non negative — poiché presentano fisiologicamente coefficienti negativi dovuti a coperture o dinamiche avverse — la forte dominanza delle correlazioni positive medie indotta dall'effetto mercato fa sì che il sistema finanziario manifesti una sorta di “proprietà di Perron-Frobenius empirica”.

Le implicazioni di questa proprietà si traducono in due vincoli algebrici per la matrice $\hat{\mathbf{C}}$:

1. **Unicità e non degenerazione:** L'autovalore massimo λ_1 è reale, strettamente positivo e possiede molteplicità uno. Ciò garantisce che la direzione a massima varianza dello spazio finanziario sia unica.
2. **Uniformità di segno:** Nonostante la presenza di correlazioni *pairwise* negative all'interno della matrice, tutti gli elementi del primo autovettore associato $\mathbf{v}_1$ presentano sistematicamente il medesimo segno algebrico. Per convenzione standard di normalizzazione, possono essere assunti come strettamente positivi ($v_{1,i} > 0 \forall i = 1, \dots, N$).

Dal punto di vista economico-finanziario, questa proprietà è cruciale. Poiché ciascuna componente $v_{1,i}$ quantifica il livello di partecipazione del titolo i -esimo al primo fattore principale, l'uniformità del segno dimostra che l'effetto mercato agisce in modo cooperativo su tutti i titoli del paniere. Pur con intensità diverse, nessuno degli asset analizzati si

muove strutturalmente in opposizione di fase rispetto al trend macroeconomico globale dominante.

3.5 Struttura gerarchica delle correlazioni

Un'altra proprietà fondamentale dei mercati reali è l'organizzazione sub-strutturale delle correlazioni secondo un principio gerarchico. All'interno del tessuto economico, le aziende non interagiscono in modo uniforme: imprese appartenenti alla medesima filiera o al medesimo comparto industriale (es. *Information Technology* o *Energy*) manifestano livelli di co-movimento mutuo significativamente più intensi rispetto a quelli registrati tra aziende operanti in settori ortogonali.

Se si applica un algoritmo di ordinamento ottimale basato su metriche di clustering gerarchico sulla matrice $\hat{\mathbf{C}}$, l'organizzazione interna si palesa visivamente sotto forma di blocchi densi disposti lungo la diagonale principale. Questa struttura ad albero (esprimibile analiticamente mediante dendrogrammi) dimostra che il mercato è organizzato secondo un'architettura multi-scala: un livello globale (effetto mercato), macro-cluster stabili (i settori GICS) e micro-aggregazioni locali (le sotto-industrie). La preservazione di tale gerarchia è il test fondamentale per determinare se un modello architetturale profondo stia apprendendo la reale tassonomia economica dei dati.

3.6 Il Minimum Spanning Tree (MST) e la proprietà scale-free

Per estrarre l'ossatura topologica essenziale eliminando le ridondanze informative della matrice di correlazione, la finanza quantitativa utilizza strumenti derivati dalla teoria dei grafi. Il metodo d'elezione consiste nella costruzione del *Minimum Spanning Tree* (Albero di Espansione Minima).

Il primo passaggio richiede la trasformazione della matrice dei coefficienti di correlazione $\mathbf{C}$ in una matrice delle distanze geometriche $\mathbf{D}_{\text{graph}}$. Per ridefinire gli elementi C_{ij} come distanze metriche reali che soddisfino gli assiomi di positività, simmetria e disuguaglianza triangolare, si applica la trasformazione non lineare:

$$d_{ij} = \sqrt{2(1 - C_{ij})} \quad (3.3)$$

Il coefficiente d_{ij} assume valore 0 in caso di correlazione perfetta positiva ($C_{ij} = 1$), valore $\sqrt{2}$ per asset indipendenti ($C_{ij} = 0$) e valore 2 per titoli perfettamente anticorrelandoli ($C_{ij} = -1$).

Utilizzando la matrice delle distanze come mappa dei pesi di un grafo completo, si applicano algoritmi classici di ottimizzazione combinatoria (quali l'algoritmo di Kruskal o di Prim) per estrarre l'MST. L'MST è un sottografo connesso e privo di cicli che collega tutti gli N nodi (gli asset) selezionando gli $N - 1$ archi che minimizzano la somma totale delle distanze geometriche.

La proprietà stilizzata che qualifica gli MST dei mercati finanziari reali è la natura *scale-free* (invariante di scala) della loro topologia di rete. Sia k_i il grado del nodo i -esimo, definito come il numero di archi incidenti sul nodo stesso nell'albero ottimizzato. Nei mercati reali, la distribuzione empirica del grado dei nodi $P(k)$ non segue una curva gaussiana o poissoniana, ma è governata da una legge di potenza:

$$P(k) \propto k^{-\gamma} \quad (3.4)$$

dove γ rappresenta l'esponente di scala strutturale, solitamente confinato nell'intervallo $2 < \gamma < 3$.

La validità della legge di potenza implica la presenza di una topologia fortemente accentrata. L'MST finanziario è dominato da pochissimi nodi ad altissima connettività, definiti *hubs* super-connessi, che agiscono come centri collettori dell'informazione finanziaria (tipicamente grandi aziende leader di settore o holding sistemiche), attorno ai quali si dispongono radialmente ampi cluster di nodi periferici a basso grado (nodi foglia).

3.7 Benchmark test: fallimento strutturale della Random Matrix Theory

Al fine di validare rigorosamente la significatività statistica dei cinque fatti stilizzati descritti, viene definito un protocollo di *benchmark test* basato sul confronto diretto tra le matrici finanziarie reali e le matrici puramente casuali generate sinteticamente tramite i teoremi della Random Matrix Theory.

Generando una matrice di controllo mediante l'estrazione di N serie temporali di puro rumore gaussiano bianco i.i.d., si costruisce la corrispondente matrice di correlazione casuale. Sottoponendo tale matrice al medesimo protocollo di analisi qualitativo e quantitativo, si registra un fallimento strutturale sistematico nell'adempimento delle proprietà del mercato reale:

Stylized Fact	Mercato Reale (S&P 500)	Benchmark RMT (Pure Noise)
Distribuzione <i>Pairwise</i>	Fortemente asimmetrica, shifted verso valori positivi.	Perfettamente simmetrica e centrata sullo zero.
Spettro degli Autovalori	Presenza di $\lambda_1 \gg \lambda_+$ (mercato) e $\lambda_k > \lambda_+$ (settori).	Interamente vincolato entro i limiti di MP: $[\lambda_-, \lambda_+]$.
Proprietà di Perron-Frobenius	Valida: $\mathbf{v}_1$ ha componenti unicamente positive.	Fallita: $\mathbf{v}_1$ ha componenti a segni casuali stocastici.
Organizzazione Interna	Struttura gerarchica e tassonomica a blocchi settoriali.	Assenza totale di pattern; matrice omogenea amorfa.
Topologia dell'MST	Rete <i>scale-free</i> retta da legge di potenza con <i>hubs</i> .	Grafo casuale omogeneo privo di nodi centrali dominanti.

Tabella 3.1. Quadro comparativo strutturale tra le proprietà geometriche dei mercati reali e il benchmark probabilistico della Random Matrix Theory.

Questo fallimento radicale dimostra matematicamente che i cinque fatti stilizzati costituiscono la firma geometrica esclusiva dell'informazione finanziaria reale. Qualsiasi modello generativo profondo non può limitarsi a operare nel dominio di metriche rigide di errore quadratico medio, ma deve necessariamente superare questo *benchmark test*. Il Variational Autoencoder, per essere considerato un valido motore stocastico di scenari, dovrà generare matrici sintetiche dallo spazio latente che non solo si discostino dal rumore di MP, ma che replichino fedelmente tutte le asimmetrie e le leggi di potenza che la Random Matrix Theory non è in grado di spiegare.

Capitolo 4

Riduzione della Dimensionalità e Modelli Generativi

4.1 Principal Component Analysis (PCA): teoria e limiti lineari

La *Principal Component Analysis* (PCA) rappresenta lo standard aureo classico per la riduzione della dimensionalità e l'estrazione di feature in ambito statistico e finanziario. Dal punto di vista algebrico, la PCA opera una trasformazione ortogonale lineare che proietta i dati originali in un nuovo sistema di coordinate, in cui gli assi (le componenti principali) sono allineati lungo le direzioni di massima varianza del dataset.

Considerando il vettore linearizzato di input $\mathbf{x} \in \mathbb{R}^D$ (che nel nostro dominio rappresenta gli elementi della matrice triangolare inferiore), la PCA ricerca una matrice di proiezione $\mathbf{W} \in \mathbb{R}^{D \times k}$ con $k < D$, tale per cui le colonne di $\mathbf{W}$ siano ortonormali ($\mathbf{W}^T \mathbf{W} = \mathbf{I}_k$). La proiezione nello spazio latente lineare è data da:

$$\mathbf{z} = \mathbf{W}^T \mathbf{x} \quad (4.1)$$

dove $\mathbf{z} \in \mathbb{R}^k$ rappresenta il vettore delle coordinate compresse. La ricostruzione nello spazio originale si ottiene applicando la trasformazione inversa:

$$\hat{\mathbf{x}} = \mathbf{W} \mathbf{z} = \mathbf{W} \mathbf{W}^T \mathbf{x} \quad (4.2)$$

L'ottimizzazione della PCA consiste nel trovare la matrice $\mathbf{W}$ che minimizzi l'errore quadratico medio di ricostruzione (MSE) globale, equivalente a massimizzare la traccia della matrice di covarianza proiettata. La soluzione analitica a questo problema coincide con l'autodecomposizione della matrice di covarianza dei dati: le colonne di $\mathbf{W}$ sono gli autovettori associati ai k autovalori dominanti.

Tuttavia, l'applicazione della PCA per la modellizzazione di matrici di correlazione finanziarie incontra un limite insormontabile: la linearità intrinseca. La PCA assume che la *manifold* (la varietà geometrica sotterranea) su cui risiedono i dati reali sia un iperpiano lineare. I mercati finanziari, al contrario, sono caratterizzati da dinamiche non lineari

estreme, come asimmetrie nei co-movimenti sistemici durante le crisi (*tail dependence*) e complesse interazioni gerarchiche di settore. Una trasformazione puramente lineare come la PCA è matematicamente incapace di catturare queste curvature topologiche, producendo ricostruzioni storiche che tendono ad appiattire l'informazione complessa.

4.2 Autoencoder Lineari (Linear AE): ponte verso le reti neurali

Per superare il paradigma dell'algebra lineare classica, l'architettura dei modelli di *deep learning* introduce gli *Autoencoder* (AE). Un autoencoder è una rete neurale *feed-forward* addestrata in modo non supervisionato con l'obiettivo di copiare il proprio input nel proprio output, passando attraverso uno strato intermedio compresso detto "collo di bottiglia" (*bottleneck*).

L'architettura minima è composta da due funzioni: un *Encoder* f_ϕ che mappa l'input nello spazio latente $\mathbf{z} = f_\phi(\mathbf{x})$, e un *Decoder* g_θ che ricostruisce l'input $\hat{\mathbf{x}} = g_\theta(\mathbf{z})$.

Il punto di giunzione teorico tra reti neurali e algebra statistica è rappresentato dall'Autoencoder Lineare. Affinché tale modello replichi fedelmente la PCA, è necessario imporre vincoli architetturali rigorosi: le funzioni di attivazione devono essere strettamente lineari (identità), la rete deve essere priva di termini di *bias* e non deve essere applicata alcuna forma di regolarizzazione sui pesi (come il *weight decay*), garantendo che l'ottimizzatore minimizzi esclusivamente il puro errore quadratico medio (MSE):

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - g_\theta(f_\phi(\mathbf{x}_i))\|^2 \quad (4.3)$$

Sotto tali condizioni, assumendo i dati in ingresso centrati, le equazioni della rete si riducono a una doppia trasformazione matriciale pura: $\mathbf{z} = \mathbf{W}_1 \mathbf{x}$ per l'Encoder e $\hat{\mathbf{x}} = \mathbf{W}_2 \mathbf{z}$ per il Decoder.

Come dimostrato formalmente dallo studio seminale di Bourlard e Kamp (1988), l'addestramento di un Linear AE così vincolato comporta una convergenza geometrica rigorosa verso l'ottimo globale. L'algoritmo di retropropagazione farà sì che lo spazio latente generato dalle matrici dei pesi $\mathbf{W}_1$ e $\mathbf{W}_2$ ricopra esattamente il medesimo sottospazio principale identificato dalle prime k componenti della PCA.

Sebbene le matrici dei pesi dell'AE non siano necessariamente ortogonali come nella PCA, l'Autoencoder Lineare funge da prova matematica cruciale: le reti neurali sono in grado di replicare perfettamente l'ottimo globale lineare. Questo lo rende il *benchmark* strutturale di partenza prima di introdurre la complessità profonda.

4.3 Autoencoder Profondi (AE): introduzione alla non-linearità

L'evoluzione naturale dell'architettura lineare è l'Autoencoder Profondo (Deep AE). Aggiungendo strati nascosti (*hidden layers*) sovrapposti e introducendo funzioni di attivazione non lineari (come ReLU, Tanh o Sigmoid), la rete neurale acquisisce la capacità, sancita dal Teorema di Approssimazione Universale, di modellare qualsiasi funzione continua complessa.

In questo regime, l'Encoder e il Decoder cessano di essere semplici matrici di proiezione e si trasformano in operatori topologici non lineari. Il Deep AE è in grado di apprendere una *manifold* curva e contorta, piegando lo spazio a latente per mappare in modo efficiente le relazioni gerarchiche settoriali e le proprietà non gaussiane delle matrici di correlazione. La dimensionalità D originale viene progressivamente ridotta attraverso gli strati fino alla dimensione latente k .

Tuttavia, per quanto formidabile nella fase di compressione e ricostruzione storica, il Deep AE fallisce qualora venga impiegato come motore stocastico per simulazioni Monte Carlo. Il problema risiede nella natura non vincolata del suo spazio latente. La rete apprende a disporre i campioni storici nello spazio $\mathbf{z}$ unicamente per minimizzare l'errore di ricostruzione, ignorando l'organizzazione globale di tale spazio. Il risultato è un dominio latente altamente irregolare, frammentato, popolato da vaste "zone vuote" prive di significato geometrico. Se si estraesse un vettore $\mathbf{z}_{\text{random}}$ casuale da questo spazio e lo si facesse passare per il Decoder, la rete genererebbe una matrice di correlazione sintetica totalmente priva di senso economico, incapace di rispettare i fatti stilizzati (violazione del limite di Marchenko-Pastur o della proprietà di Perron-Frobenius). Il Deep AE è eccellente nel ricordare, ma strutturalmente inadatto a immaginare.

4.4 Variational Autoencoders (VAE) e regolarizzazione dello spazio latente

Per abilitare la generazione stocastica di scenari realistici, è necessario un cambio di paradigma architetturale che conduca dal determinismo geometrico alla teoria dell'inferenza probabilistica variazionale. Il *Variational Autoencoder* (VAE), introdotto da Kingma e Welling (2013), risolve il problema della frammentazione dello spazio latente costringendo l'Encoder a emettere non più singoli vettori puntuali, ma intere distribuzioni di probabilità.

Nel VAE, per ogni campione di input $\mathbf{x}$, l'Encoder (ora definito come rete di inferenza) prevede due vettori distinti: un vettore delle medie $\boldsymbol{\mu}$ e un vettore delle varianze $\boldsymbol{\sigma}^2$. Questi vettori parametrizzano una distribuzione gaussiana multivariata $q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$ dalla quale viene campionato il vettore latente $\mathbf{z}$. Affinché questo processo di estrazione stocastica sia differenziabile tramite *backpropagation*, si implementa il cosiddetto *Reparameterization Trick*:

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon} \quad \text{con} \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (4.4)$$

La grandezza ingegneristica del VAE risiede nella sua funzione di *loss*, che massimizza il limite inferiore dell'evidenza (ELBO). Essa è composta da due termini antagonisti:

$$\mathcal{L}_{\text{VAE}} = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[-\log p_\theta(\mathbf{x}|\mathbf{z})]}_{\text{Reconstruction Loss}} + \underbrace{\beta D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z}))}_{\text{KL Divergence}} \quad (4.5)$$

Il primo termine è la *Reconstruction Loss* (tipicamente calcolata come MSE nel nostro dominio continuo), che spinge la rete a minimizzare l'errore tra la matrice di correlazione in ingresso e quella ricostruita.

Il secondo termine, la Divergenza di Kullback-Leibler (D_{KL}), è il motore stocastico dell'architettura. Essa agisce come un rigoroso regolarizzatore topologico, penalizzando l'Encoder se le distribuzioni generate $q_\phi(\mathbf{z}|\mathbf{x})$ si allontanano da una distribuzione *prior* di riferimento, solitamente una gaussiana normale standard $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$.

La competizione tra questi due termini plasma uno spazio latente rivoluzionario. La Divergenza KL costringe tutte le distribuzioni dei singoli campioni ad addensarsi vicino all'origine dello spazio e a sovrapporsi le une con le altre in modo continuo e omogeneo (*packing*), eliminando le zone vuote tipiche degli AE classici. Contemporaneamente, la Reconstruction Loss costringe i campioni simili (es. matrici di correlazione di fasi di espansione economica) a rimanere vicini per poter essere decodificati correttamente, preservando un'ordinata morfologia strutturale.

Questo spazio latente continuo, denso e regolarizzato è il dominio perfetto per il campionamento stocastico. Nelle fasi di simulazione di portafoglio, sarà sufficiente campionare un vettore casuale $\mathbf{z}_{\text{sim}} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ e passarlo al Decoder deterministico $p_\theta(\mathbf{x}|\mathbf{z})$. Il modello estrarrà dalla regione di sovrapposizione un pattern coerente, generando una matrice di correlazione sintetica totalmente nuova, mai apparsa nella storia passata, ma che rispecchierà rigorosamente l'infrastruttura topologica e i vincoli finanziari (fatti stilizzati) del mercato di addestramento.

Parte II

Metodologia e Pipeline di
Analisi

Capitolo 5

Pre-processing e Costruzione del Dataset

5.1 Descrizione del dataset

Il fondamento empirico di questo lavoro di tesi è costituito da un dataset storico di natura azionaria, focalizzato sull'indice S&P 500, assunto come proxy rappresentativa del mercato azionario globale e dell'economia statunitense. Al fine di garantire una base dati sufficientemente ampia per l'addestramento dei modelli di *deep learning* e, contestualmente, catturare molteplici regimi di mercato (incluse fasi di espansione, recessione e shock sistemici), l'orizzonte temporale di riferimento è stato fissato tra l'anno 2000 e il 2020.

Per assicurare la continuità e la stabilità statistica del dataset, l'intera popolazione dei titoli è stata filtrata applicando un rigoroso requisito di sopravvivenza ininterrotta (*survivorship*). Sono stati mantenuti esclusivamente gli asset che hanno registrato quotazioni giornaliere continue per tutto il ventennio di osservazione. Questo processo di epurazione ha prodotto un bacino finale di $N = 362$ titoli azionari. A differenza di campionamenti ridotti, il mantenimento dell'intera popolazione sopravvissuta garantisce una rappresentazione macrostrutturale completa del mercato, eliminando potenziali bias di selezione e preservando in modo organico l'eterogeneità settoriale GICS (*Global Industry Classification Standard*). Tale eterogeneità è fondamentale affinché le matrici di correlazione empiriche manifestino la tipica struttura gerarchica e lo spettro degli autovalori aderente alla vera realtà economica.

I dati grezzi sono costituiti dai prezzi di chiusura giornalieri rettificati (*adjusted closing prices*), i quali incorporano ex-ante gli effetti di operazioni societarie straordinarie, quali stacchi di dividendi, *stock split* e raggruppamenti, prevenendo salti artificiali nelle serie storiche che inquinerebbero il calcolo delle covarianze.

5.2 Calcolo dei rendimenti e stima delle matrici empiriche

A partire dalla matrice dei prezzi storici $\mathbf{P} \in \mathbb{R}^{N \times T_{\text{tot}}}$, dove T_{tot} rappresenta il numero totale di giorni di contrattazione nel ventennio e $N = 362$, il primo passaggio di trasformazione algebrica consiste nel calcolo dei log-rendimenti giornalieri continui. Il rendimento dell'asset i -esimo al tempo t è definito come:

$$r_{i,t} = \ln \left(\frac{P_{i,t}}{P_{i,t-1}} \right) \quad (5.1)$$

L'addestramento di modelli di *machine learning* richiede un dataset composto da centinaia di campioni. Poiché la serie storica produce un'unica traiettoria temporale, si rende necessario implementare una procedura di estrazione a finestre mobili (*rolling windows*).

Sia T_w l'ampiezza temporale della finestra di osservazione, fissata operativamente a 724 giorni lavorativi (corrispondenti a quasi tre anni solari di contrattazioni). Definendo un parametro di passo (*stride*) S , la finestra viene fatta scorrere lungo l'intera serie storica. Per ogni step k , si isola un sotto-campione di log-rendimenti $\mathbf{X}^{(k)} \in \mathbb{R}^{N \times T_w}$ e si calcola la corrispondente matrice di correlazione di Pearson empirica $\mathbf{C}^{(k)} \in \mathbb{R}^{N \times N}$, il cui generico elemento è:

$$C_{ij}^{(k)} = \frac{\text{Cov}(r_i, r_j)}{\sigma_i \sigma_j} \quad \text{con dati estratti in } t \in [k \cdot S, k \cdot S + T_w] \quad (5.2)$$

Applicando un passo $S = 10$ giorni (corrispondente esattamente a due settimane lavorative), si bilancia la necessità di generare un numero congruo di campioni per l'addestramento con l'esigenza di ridurre la ridondanza informativa del micro-rumore giornaliero. Questa estrazione tramite finestre ampie cattura in modo molto stabile e privo di rumore transitorio i veri *shift* strutturali di medio-lungo periodo del mercato. In ogni finestra, il rapporto di dimensionamento temporale (rapporto di spettro) si attesta esattamente a $q = N/T_w = 362/724 = 0.5$. Tale valore, mantenendosi rigorosamente costante nel tempo, determina un livello di rumore statistico omogeneo e perfettamente bilanciato, il cui comportamento spettrale è analiticamente governabile dalle leggi della *Random Matrix Theory* e dai limiti di Marchenko-Pastur discussi nei capitoli precedenti.

5.3 Tecnica di campionamento: il Random Shuffle per la stazionarietà

Nella strutturazione convenzionale di serie storiche finanziarie per il *deep learning*, la prassi consolidata prevede una rigida divisione cronologica dei dati in *Training Set*, *Validation Set* e *Test Set*, accompagnata da tecniche di *purging* per gestire la sovrapposizione temporale causata dalle finestre mobili. Tuttavia, test preliminari condotti mediante partizionamento temporale sequenziale hanno evidenziato una dinamica di *distribution shift* estrema: i regimi macroeconomici passati non fornivano informazioni topologiche sufficienti per permettere alle architetture profonde di generalizzare fuori campionario sui regimi futuri.

Per valutare il reale potere ricostruttivo e la capacità di compressione geometrica delle reti neurali, isolandole dall'impatto dei mutamenti macroeconomici radicali nel tempo, la pipeline sperimentale adotta una strategia di campionamento tramite mescolamento casuale (*random shuffle*) sull'intero pool di matrici.

Il processo di estrazione a finestre mobili, applicando il passo costante (*stride*) $S = 10$ giorni lavorativi lungo l'intera serie storica dei prezzi, produce un bacino complessivo di 412 matrici di correlazione empiriche. Queste matrici vengono interamente mischiate in modo stocastico prima di essere ripartite nei tre set operativi, portando alla seguente conformazione tensoriale finale:

- **Training Set:** *shape* (288, 362, 362)
- **Validation Set:** *shape* (82, 362, 362)
- **Test Set:** *shape* (42, 362, 362)

Questo approccio garantisce che la distribuzione statistica sottostante ai tre sottoinsiemi sia perfettamente omogenea e stazionaria: scenari di elevata volatilità e scenari di mercato stabili risultano equamente distribuiti sia nel set di addestramento che in quelli di validazione e test. Questa omogeneizzazione annulla l'impatto del *distribution shift* e permette di testare rigorosamente la capacità dei modelli (PCA, Linear AE, Deep AE, VAE) di apprendere la complessa *manifold* delle correlazioni a parità di condizioni statistiche.

5.4 Estrazione e flattening delle matrici triangolari inferiori

L'ultimo passaggio della pipeline riguarda la conformazione dell'input per le reti neurali. Ogni matrice di correlazione empirica generata $\mathbf{C}^{(k)}$ ha dimensione $N \times N$, ovvero 362×362 . Tuttavia, per le proprietà intrinseche dell'operatore di correlazione, la matrice è perfettamente simmetrica rispetto alla diagonale principale ($C_{ij} = C_{ji}$) e presenta esclusivamente valori unitari sulla diagonale stessa ($C_{ii} = 1$).

Fornire in pasto a un modello di *deep learning* l'intera griglia 362×362 comporterebbe un grave spreco di risorse computazionali e introdurrebbe una ridondanza geometrica dannosa, costringendo il modello ad allocare pesi sinaptici per apprendere relazioni di simmetria identiche e valori costanti banalmente noti.

Per ottimizzare drasticamente lo spazio delle feature, si procede all'isolamento e all'estrazione della sola matrice triangolare inferiore (*strictly lower triangular matrix*), scartando sia la diagonale principale sia la porzione superiore. Il numero D di elementi unici e informativi estratti da una matrice $N \times N$ segue la formula delle combinazioni semplici:

$$D = \frac{N(N-1)}{2} \quad (5.3)$$

Essendo il paniere azionario composto da $N = 362$ titoli, ogni singola matrice viene compressa in un vettore di dimensione spaziale estremamente elevata:

$$D = \frac{362 \times 361}{2} = 65341 \text{ elementi} \quad (5.4)$$

Attraverso un'operazione di *flattening*, gli elementi della matrice triangolare inferiore vengono linearizzati in un vettore monodimensionale $\mathbf{x}^{(k)} \in \mathbb{R}^{65341}$. Questo vettore strutturato e formattato costituisce a tutti gli effetti l'input canonico $\mathbf{x}$ ad altissima dimensionalità che alimenterà i *layer* di ingresso della PCA, dei modelli deterministici (Linear AE, Deep AE) e probabilistici (VAE) nei successivi step sperimentali.

Capitolo 6

Architetture dei Modelli e Setup Sperimentale

6.1 Implementazione della PCA come baseline

Al fine di stabilire un *benchmark* quantitativo rigoroso per valutare le performance delle reti neurali, la pipeline sperimentale prevede l'implementazione iniziale della *Principal Component Analysis* (PCA). Questo modello funge da base comparativa per determinare il limite massimo di compressione lineare raggiungibile sui dati.

La PCA è stata addestrata sul *Training Set* linearizzato, composto dai vettori $\mathbf{x} \in \mathbb{R}^{65341}$ rappresentanti le componenti triangolari inferiori delle matrici di correlazione. Fissata una dimensione target K per lo spazio compresso, l'algoritmo estrae gli autovettori corrispondenti ai K autovalori dominanti della matrice di covarianza globale del set di addestramento. Le performance di ricostruzione, misurate tramite l'Errore Quadratico Medio (MSE) sulle matrici del *Test Set*, costituiscono la soglia che i modelli di *deep learning* devono teoricamente eguagliare (nel caso lineare) o superare (nel caso non lineare).

6.2 Design e iperparametri dell'Autoencoder Lineare

L'Autoencoder Lineare (Linear AE) è stato progettato per fungere da ponte analitico tra l'apprendimento profondo e l'algebra lineare. Per garantire la perfetta replicabilità del sottospazio della PCA, l'architettura è stata sottoposta a vincoli ingegneristici stringenti:

- **Struttura:** Un singolo *layer* denso per l'Encoder ($\mathbb{R}^{65341} \rightarrow \mathbb{R}^K$) e uno speculare per il Decoder ($\mathbb{R}^K \rightarrow \mathbb{R}^{65341}$).
- **Funzioni di attivazione:** Rigorosamente identità (lineari) in ogni nodo della rete.
- **Assenza di Bias e Regolarizzazione:** I termini di *bias* sono stati disabilitati in tutti i *layer* ($\mathbf{b} = 0$) e non è stata applicata alcuna penalizzazione di tipo *weight decay* (L2) per non alterare la magnitudo della scomposizione spettrale appresa.

L'ottimizzazione dei pesi è stata condotta minimizzando esclusivamente la funzione di costo spaziale MSE. Come prassi di *sanity check*, gli iperparametri di addestramento (in particolare la scelta dell'ottimizzatore, come Adam, e il *Learning Rate*) sono stati calibrati in modo iterativo per garantire che la *loss* del Linear AE convergesse asintoticamente sull'orizzonte esatto dettato dalla PCA sul set di addestramento, validando l'assenza di minimi locali sub-ottimali.

6.3 Design e iperparametri dell'Autoencoder Non-Lineare

Per superare la rigidità geometrica dei modelli precedenti e catturare le interdipendenze gerarchiche e asimmetriche del mercato reale, è stato sviluppato un Autoencoder Profondo (AE). L'inclusione di strati multipli e funzioni non lineari dota il modello della flessibilità necessaria per piegare lo spazio latente e fittare la *manifold* complessa dei dati finanziari.

L'architettura è strutturata con un *design* a imbuto (simmetrico):

- **Encoder e Regolarizzazione:** L'infrastruttura inizia con il *layer* di ingresso ($\mathbb{R}^{65341}$), seguito da strati nascosti (*hidden layers*) a dimensionalità decrescente, fino al livello di *bottleneck* ($\mathbb{R}^K$). Per forzare la rete ad apprendere rappresentazioni più robuste e distribuite delle dinamiche di mercato, mitigando contestualmente il rischio di memorizzazione mnemonica (*co-adaptation*), è stato interposto un *layer* di *Dropout* tra gli strati dell'Encoder.
- **Decoder:** Struttura speculare che riceve il vettore latente K -dimensionale e lo proietta nuovamente alla dimensione originale attraverso un'espansione simmetrica.
- **Funzioni di attivazione:** Per tutti gli strati nascosti è stata adottata la funzione di attivazione LeakyReLU (con parametro di pendenza α fissato a 0.01) per scongiurare il problema del *vanishing gradient* e garantire un flusso di gradiente non nullo anche per valori di input negativi. Per l'ultimo *layer* di output del Decoder è stata sistematicamente impiegata l'attivazione Tanh (tangente iperbolica), una scelta architeturale atta a mappare rigorosamente i valori ricostruiti nel dominio continuo $[-1, 1]$, coerente con la natura geometrica dei coefficienti di correlazione di Pearson.

Al fine di prevenire l'*overfitting* e selezionare la configurazione ottimale, il protocollo di addestramento prevede l'esecuzione per un numero prefissato di epoche, monitorando costantemente il *Validation Set* (generato tramite la tecnica del *random shuffle*). La strategia di salvataggio dei pesi (*Model Checkpointing*) è impostata per conservare esclusivamente il modello in corrispondenza del valore minimo assoluto della *Validation Loss*.

Grazie all'omogeneità statistica garantita dal campionamento casuale, che annulla il problema del *distribution shift* temporale, il Deep AE dimostra una capacità espressiva eccezionale: la *Training Loss* e la *Validation Loss* risultano stabilmente decrescenti, scendendo al di sotto del limite rigido fissato dal *benchmark* della PCA per medesimi valori di K . Questo successo empirico certifica la capacità della rete di superare i limiti dell'algebra lineare, generalizzando efficacemente sulle dinamiche non lineari del mercato.

Tuttavia, l'eccellente potere ricostruttivo del Deep AE porta alla luce un limite strutturale di diversa natura: l'incapacità generativa. Trattandosi di un modello puramente deterministico, l'Encoder mappa l'input in vettori latenti $\mathbf{z}$ puntuali, creando uno spazio disaggregato e privo di organizzazione probabilistica. Estrapolare nuovi scenari campionando vettori casuali da questo dominio produrrebbe matrici del tutto prive di validità macroeconomica. Tale ostacolo sancisce definitivamente la necessità di transitare verso il paradigma variazionale (VAE), progettato esattamente per superare il determinismo e abilitare la simulazione stocastica.

6.4 Design e iperparametri del VAE

Il Variational Autoencoder (VAE) rappresenta l'apice ingegneristico della pipeline, deputato non solo alla compressione, ma alla generazione stocastica. L'architettura espande la topologia del Deep AE trasformando lo strato di *bottleneck* deterministico in un modulo di inferenza probabilistica.

- **Rete di Inferenza (Encoder):** Al termine degli strati nascosti, la rete si biforca in due layer paralleli che emettono, rispettivamente, il vettore delle medie $\boldsymbol{\mu}$ e il vettore delle varianze logaritmiche $\log(\boldsymbol{\sigma}^2)$ della distribuzione latente, per garantire la stabilità numerica.
- **Sampling e Reparameterization:** Lo strato latente non riceve un input fisso, ma un campione estratto dinamicamente tramite il *reparameterization trick* $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$, dove $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
- **Rete Generativa (Decoder):** Il Decoder speculare riceve $\mathbf{z}$ e procede alla ricostruzione.

Il bilanciamento tra l'errore di ricostruzione (MSE) e il vincolo topologico imposto dalla Divergenza di Kullback-Leibler (KL) è l'iperparametro critico del sistema. L'addestramento modella uno spazio continuo che permette, in fase di test, di estrarre nuove matrici sintetiche campionando puramente dalla normale standard $p(\mathbf{z})$ senza necessitare di input originari.

6.5 Metriche di valutazione e criteri di convergenza

L'addestramento dei modelli neurali è stato governato monitorando un set di metriche oggettive e applicando precise policy di ottimizzazione per massimizzare la stabilità dell'apprendimento e la capacità di estrapolazione fuori campionato:

1. **Metriche Spaziali Rigide:** La valutazione quantitativa puntuale si basa sul *Mean Squared Error* (MSE), impiegato direttamente come funzione di costo e indicatore primario. A questo si affiancano il *Mean Absolute Error* (MAE), più resistente agli *outlier*, e la Norma di Frobenius, che quantifica l'energia complessiva residua tra la matrice empirica originale e la sua approssimazione ricostruita o generata.

2. **Ottimizzatore e Learning Rate Policy:** È stato impiegato l'algoritmo di ottimizzazione Adam, rinomato per la gestione dinamica del momento del gradiente. Per facilitare il superamento del limite lineare sul *Training Set* e agevolare la discesa verso il minimo globale, è stato implementato uno *scheduler* per il *Learning Rate* basato sulla tecnica del *Cosine Annealing*. Questa strategia riduce il tasso di apprendimento seguendo il decadimento morbido e continuo della funzione coseno, permettendo esplorazioni ampie nelle fasi iniziali e un'ottimizzazione fine, priva dei bruschi salti tipici degli approcci *step-based*, man mano che la rete si avvicina al *plateau* di convergenza.
3. **Monitoraggio della Convergenza:** La gestione a epoche (*epochs*) tramite *mini-batches* è stata affiancata dall'impiego del *Validation Set* come arbitro indipendente per il *Model Checkpointing*. L'algoritmo valuta l'intero ciclo di epoche prefissato e salva i pesi architetturali esclusivamente in corrispondenza del valore minimo assoluto raggiunto dalla *Validation Loss*. Questo protocollo garantisce che le prestazioni valutate in sede finale sul *Test Set* costituiscano la stima più imparziale e robusta possibile per gli scenari futuri di *asset allocation*.

Parte III

Risultati, Validazione e Applicazioni

Capitolo 7

Analisi della Compressione e Ricostruzione Storica

7.1 Valutazione della PCA e dell'AE Lineare: il benchmark della linearità

La prima fase di validazione empirica ha avuto come obiettivo la misurazione delle capacità di ricostruzione dei modelli puramente lineari. È fondamentale precisare la natura dello spazio vettoriale analizzato: l'input fornito ai modelli non è costituito dalle serie storiche dei rendimenti originali, bensì dai vettori appiattiti $\mathbf{x} \in \mathbb{R}^{4950}$ rappresentanti le porzioni triangolari inferiori delle matrici di correlazione mobili. Di conseguenza, la PCA in questa fase non estrae il classico "fattore di mercato" associato ai titoli (che deriverebbe dall'autodecomposizione dei rendimenti), ma identifica le direzioni di massima varianza nello *spazio delle correlazioni*.

In questo dominio a 4950 dimensioni, la prima componente principale cattura tipicamente la dinamica macro-strutturale dominante: la tendenza sistemica delle correlazioni *pairwise* a variare coralmemente nel tempo (il cosiddetto *breathing effect* o "respiro" del mercato), come accade durante i regimi di panico finanziario in cui i livelli di correlazione media subiscono bruschi innalzamenti globali. Un modello lineare di proiezione ortogonale risulta storicamente efficace nel mappare questa espansione e contrazione strutturale di base.

Le misurazioni sul *Training Set* hanno confermato rigorosamente il teorema di Bourlard e Kamp (1988): a parità di dimensione del collo di bottiglia K , l'Autoencoder Lineare (privo di *bias* e funzioni di attivazione) converge asintoticamente al medesimo Errore Quadratico Medio (MSE) della *Principal Component Analysis* (PCA). Fissato questo limite, la PCA e il Linear AE stabiliscono il *benchmark* assoluto per la pura compressione lineare dello spazio delle correlazioni: qualsiasi architettura profonda proposta deve dimostrare di poter infrangere tale soglia sfruttando la propria espressività topologica.

Tuttavia, l'analisi dell'errore di ricostruzione sul *Test Set* rivela il limite strutturale di questi approcci. La rigidità dell'iperpiano di proiezione impedisce ai modelli lineari di

adattarsi alle complesse interdipendenze non lineari che governano le rotazioni settoriali e le asimmetrie strutturali tra diversi regimi di mercato. La PCA comprime l'informazione in modo algebricamente efficiente, ma restituisce una ricostruzione storicamente "appiattita", faticando a preservare la complessa microstruttura dei veri *stylized facts* finanziari fuori dal campione di addestramento.

7.2 Performance di ricostruzione: AE Non-Lineare e VAE

L'introduzione della non-linearità attraverso l'Autoencoder Profondo (Deep AE) ha prodotto un netto superamento del limite imposto dalla PCA sul set di addestramento. Sfruttando la capacità delle funzioni LeakyReLU ($\alpha = 0.01$) di piegare lo spazio delle feature e l'azione del *Dropout*, il Deep AE minimizza l'errore quadratico medio (MSE) sul *Training Set*, dimostrando una notevole capacità di *fitting* locale. Tuttavia, come evidenziato dal monitoraggio del *Validation Set*, tale flessibilità si traduce in un severo *overfitting* temporale: le performance fuori campionato rimangono stagnanti, a causa dell'incapacità intrinseca dei modelli deterministici di adattarsi al *distribution shift* dei regimi macroeconomici futuri.

Il passaggio al Variational Autoencoder (VAE) introduce una dinamica prestazionale che, sotto il puro profilo della ricostruzione storica, risulta peggiorativa non solo rispetto al Deep AE, ma spesso anche rispetto ai *benchmark* lineari (PCA e Linear AE). Le evidenze empiriche mostrano infatti che il VAE registra un incremento sistematico dell'MSE di ricostruzione sia sui dati di *training* sia sui dati mai visti di *test*.

Questo comportamento non costituisce un'anomalia algoritmica, bensì la diretta conseguenza matematica della struttura della *loss* variazionale. Il termine di Divergenza di Kullback-Leibler (D_{KL}) agisce come un vincolo estremamente penalizzante e coercitivo: esso forza l'ibridazione e l'addensamento delle distribuzioni latenti verso una *prior* gaussiana standard $\mathcal{N}(\mathbf{0}, \mathbf{I})$. Questo costante processo di regolarizzazione contrasta l'ottimizzazione matematica della *Reconstruction Loss*, impedendo al *Decoder* di specializzarsi nella scomposizione geometrica esatta dei campioni storici. Il VAE, pertanto, si rivela sperimentalmente il modello meno efficiente nella pura replica puntuale delle matrici di correlazione passate.

7.3 Il trade-off tra compressione esatta e flessibilità generativa

I risultati finora descritti delineano chiaramente il compromesso fondamentale che giustifica l'adozione delle architetture variazionali in finanza quantitativa: l'insanabile dicotomia tra l'accuratezza della compressione storica e la reale utilità generativa del modello.

L'Autoencoder Profondo deterministico massimizza l'efficacia della compressione sul passato, ma fallisce totalmente qualora lo si voglia utilizzare come motore di simulazione. Poiché lo spazio latente di un AE classico non è governato da alcuna restrizione probabilistica, i vettori $\mathbf{z}$ si dispongono in modo disaggregato e frammentario, creando vaste regioni

di vuoto geometrico. Tentare di generare nuovi scenari campionando un vettore casuale da tale spazio e proiettandolo attraverso il *Decoder* produce output matematicamente degradati o privi di coerenza economico-finanziaria. L'AE deterministico è confinato alla pura memorizzazione di un passato statico.

Al contrario, l'impiego del VAE viene proposto e validato non per le sue doti di ricostruzione, nelle quali è penalizzato, ma per la sua esclusiva ed eccellente *capacità generativa*. Accettando una perdita di precisione storica (un MSE più elevato), il vincolo della D_{KL} modella uno spazio latente continuo, denso e privo di singolarità. Questa specifica topologia trasforma l'architettura in un perfetto generatore stocastico fuori campionario.

In ottica di *risk management*, l'estrazione di vettori casuali $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ permette al VAE di generare infinite matrici di correlazione sintetiche inedite. Pur non essendo identiche a quelle storiche, tali matrici conservano intatta l'infrastruttura strutturale del mercato, dimostrando la capacità di sintetizzare scenari alternativi plausibili e coerenti. È proprio questa virtù generativa, e non l'accuratezza del *fitting*, a sancire la superiorità metodologica del VAE per la stima del *Value at Risk* (VaR) e per la simulazione di scenari di stress macroeconomico.