

POLITECNICO DI TORINO

Corso di Laurea Magistrale in Ingegneria Informatica

Orientamento Artificial Intelligence and Data Analytics

Tesi di Laurea Magistrale

Dai pixel ai portafogli finanziari: generare scenari di mercato realistici tramite variational autoencoder



Relatori

prof. Flavio Giobergia

prof. Sergio Caprioli

firma dei relatori

.....
.....

Candidato

Dylan Magliano

firma del candidato

.....

Anno Accademico 2025-2026

A mio padre

† A mio nonno Pino

Sommario

Il presente lavoro di tesi si inserisce nel contesto della finanza quantitativa, affrontando le limitazioni dei modelli deterministici nella stima delle matrici di correlazione empiriche, tipicamente affette da rumore statistico e limiti di campionamento storico. L'obiettivo centrale è testare l'efficacia dei *Variational Autoencoder* (VAE) come modello generativo stocastico per la simulazione di scenari di mercato realistici. Un vincolo matematico imprescindibile in questo dominio è che le matrici sintetiche prodotte risultino rigorosamente semidefinite positive (PSD), proprietà che il framework garantisce strutturalmente modellando la decomposizione di Cholesky delle matrici stesse.

La metodologia delinea un percorso evolutivo, basato sui rendimenti giornalieri di un campione rappresentativo di 362 titoli dell'indice S&P 500 nell'orizzonte temporale 2000-2020. Per valutare il potere ricostruttivo dei vari modelli nelle diverse configurazioni degli spazi latenti K , le matrici vengono analizzate impiegando sia metriche di errore classiche (MSE, MAE, norma di Frobenius) e strutturali (MST), sia l'aderenza ai fatti stilizzati. Lo studio stabilisce inizialmente un *benchmark* lineare tramite la Principal Component Analysis (PCA), per poi passare all'implementazione di Autoencoder Lineari (Linear AE) in grado di approssimarne il sottospazio. Il passo successivo prevede l'integrazione della non-linearità attraverso Autoencoder Profondi (AE), dimostrando come la stratificazione profonda consenta di catturare in modo più fedele la complessa curvatura geometrica delle interdipendenze finanziarie.

Questo percorso di raffinamento strutturale trova il proprio culmine nell'adozione del Variational Autoencoder (VAE): pur restando la sua capacità di ricostruzione storica lievemente inferiore a quella dell'Autoencoder Profondo deterministico, nel dominio Cholesky il VAE supera sia la PCA sia l'Autoencoder Lineare, a dimostrazione che la regolarizzazione variazionale imposta dalla divergenza di Kullback-Leibler non compromette in modo sostanziale la fedeltà di ricostruzione. È proprio tale regolarizzazione a rendere lo spazio latente continuo, denso e privo di singolarità, condizione necessaria per abilitare una generazione di scenari puramente stocastica altrimenti preclusa a un autoencoder deterministico, il cui spazio latente resta frammentario e privo di significato al di fuori dei punti osservati in addestramento.

La procedura di generazione effettivamente adottata non consiste in un semplice campionamento dal *prior* dello spazio latente, bensì in un *block-bootstrap* storico degli incrementi latenti giornalieri, che ancora ciascuno scenario sintetico allo stato di mercato osservato oggi per proiettarne l'evoluzione a un orizzonte di un mese. Le nuove matrici di correlazione così generate vengono valutate sulla base della loro conformità ai cinque fatti

stilizzati (*stylized facts*) caratteristici delle matrici di correlazione finanziarie. Nello specifico, le matrici generate dimostrano una rigorosa aderenza a tali proprietà fondamentali: distribuzione asimmetrica verso valori positivi, conformità dello spettro degli autovalori alla distribuzione di Marchenko-Pastur, validità della proprietà di Perron-Frobenius, conservazione della struttura gerarchica (tramite *clustering* gerarchico) e topologia *scale-free* del *Minimum Spanning Tree* (MST). Ciò valida l'architettura proposta come uno strumento solido e autonomo per la generazione di ecosistemi finanziari matematicamente coerenti.

Indice

I	Fondamenti Teorici	9
1	Introduzione	11
1.1	Contesto generale e problematica della generazione di scenari	11
1.2	Definizione del problema di ricerca e motivazione dell'uso dei modelli generativi profondi	11
1.3	Obiettivi della tesi	13
2	Matrici di Correlazione in Ambito Finanziario	15
2.1	Il ruolo della correlazione e la necessità di previsioni future (Markowitz) . .	15
2.2	Il problema del rumore nelle matrici empiriche	16
2.3	Generazione di scenari stocastici futuri tramite decomposizione di Cholesky	16
3	Fatti Stilizzati delle Matrici di Correlazione	19
3.1	Introduzione alle proprietà strutturali dei mercati reali	19
3.2	Distribuzione asimmetrica delle correlazioni pairwise	21
3.3	Analisi spettrale e distribuzione di Marchenko-Pastur	22
3.4	Proprietà di Perron-Frobenius empirica	23
3.5	Struttura gerarchica delle correlazioni	24
3.6	Il Minimum Spanning Tree (MST) e la proprietà scale-free	25
3.7	Benchmark test: fallimento strutturale della Random Matrix Theory . . .	26
4	Riduzione della Dimensionalità e Modelli Generativi	33
4.1	Principal Component Analysis (PCA): teoria e limiti lineari	33
4.2	Autoencoder Lineari (Linear AE): ponte verso le reti neurali	34
4.3	Autoencoder Profondi (AE): introduzione alla non-linearità	35
4.4	Variational Autoencoders (VAE) e regolarizzazione dello spazio latente . .	35
II	Metodologia e Pipeline di Analisi	39
5	Pre-processing e Costruzione del Dataset	41
5.1	Descrizione del dataset	41
5.2	Calcolo dei rendimenti e stima delle matrici empiriche	42
5.3	Tecnica di campionamento: il Random Shuffle per la stazionarietà	43

5.4	Estrazione e flattening delle matrici triangolari inferiori	44
6	Architetture dei Modelli e Setup Sperimentale	47
6.1	Implementazione della PCA come baseline	47
6.2	Design e iperparametri dell'Autoencoder Lineare	47
6.3	Design e iperparametri dell'Autoencoder Non-Lineare	48
6.4	Design e iperparametri del VAE	49
6.5	Metriche di valutazione e criteri di convergenza	50
III	Risultati, Validazione e Applicazioni	53
7	Analisi della Compressione e Ricostruzione Storica	55
7.1	Valutazione della PCA e dell'AE Lineare: il benchmark della linearità . . .	55
7.2	Performance di ricostruzione: AE Non-Lineare e VAE	56
7.3	Il trade-off tra compressione esatta e flessibilità generativa	58
8	Generazione Stocastica di Nuovi Scenari (Validazione del VAE)	61
8.1	Campionamento dallo spazio latente: dal prior al block-bootstrap storico .	61
8.2	Verifica dei cinque fatti stilizzati sulle matrici generate	63
8.3	Limiti della validazione e sviluppi futuri	66
9	Conclusioni e Sviluppi Futuri	69
9.1	Sintesi dei risultati ottenuti	69
9.2	Impatto nel campo del Risk Management quantitativo	70
9.3	Limiti del modello attuale	70
9.4	Sviluppi futuri	71

Parte I

Fondamenti Teorici

Capitolo 1

Introduzione

1.1 Contesto generale e problematica della generazione di scenari

Nell'analisi dei dati e nella modellizzazione di sistemi complessi, la disponibilità di scenari ampi e diversificati è un requisito fondamentale per testare la robustezza di qualsiasi framework analitico. Tradizionalmente, in ambito quantitativo, gli operatori si affidano alle serie storiche per campionare le matrici di correlazione empiriche, le quali quantificano le interdipendenze tra le diverse variabili in gioco. Tuttavia, l'uso esclusivo dei dati storici presenta una criticità intrinseca e ineliminabile: il passato offre solamente una singola traiettoria degli eventi possibili.

Questa limitatezza campionaria impedisce di esplorare configurazioni alternative o eventi estremi che, pur non essendosi mai verificati nello specifico campione a disposizione, risultano statisticamente plausibili. Per superare questo ostacolo, l'analisi moderna si affida ampiamente a metodologie di simulazione che necessitano di generatori di dati capaci di produrre scenari sintetici. L'efficacia e l'affidabilità di tali simulazioni dipendono in maniera critica dal realismo delle matrici generate: se i modelli matematici sottostanti non riescono a catturare fedelmente le interdipendenze profonde e la complessa topologia dei dati reali, gli scenari prodotti risultano distorti e privi di utilità pratica.

1.2 Definizione del problema di ricerca e motivazione dell'uso dei modelli generativi profondi

Il principale ostacolo nell'applicazione pratica e nella generazione di scenari risiede nella natura intrinseca delle matrici di correlazione empiriche. Quando stimata a partire da serie storiche, la matrice soffre in modo significativo del problema del rumore statistico. Quando il numero di variabili analizzate (N) è dello stesso ordine di grandezza della lunghezza della serie storica (T), la matrice empirica diventa instabile, introducendo autovalori spuri che ne degradano l'affidabilità informativa, un fenomeno ampiamente studiato nell'ambito della *Random Matrix Theory* (RMT) [Bouchaud and Potters, 2009, Plerou et al., 2002].

Nel presente lavoro, l'analisi si concentra sui rendimenti giornalieri dei titoli componenti l'indice S&P 500 estratti lungo un ampio orizzonte temporale ventennale, compreso tra il 2000 e il 2020. Al fine di garantire la coerenza e la continuità della serie storica, la ricerca isola un paniere target di 362 asset, selezionando esclusivamente le aziende che presentano quotazioni ininterrotte lungo l'intero arco temporale considerato.

I metodi tradizionali per simulare o gestire il rumore in tali matrici presentano forti limiti: tendono a linearizzare le relazioni, eliminano anomalie informative preziose o rimangono strettamente vincolati alla dinamica storica, impedendo l'effettiva esplorazione di scenari inediti. In questo panorama, i modelli generativi profondi (*Deep Generative Models*) offrono un cambio di paradigma radicale. Architetture basate sui *Variational Autoencoders* (VAE) consentono di mappare lo spazio ad alta dimensionalità delle matrici empiriche in uno spazio latente continuo, dal quale è possibile campionare in modo stocastico.

Il presente lavoro si inserisce in un filone di ricerca ancora giovane ma in rapida crescita, che applica modelli generativi profondi — inizialmente sviluppati per il dominio delle immagini — alla sintesi di matrici di correlazione finanziarie. Il precedente più rilevante in letteratura è *CorrGAN* [Marti, 2019], che per primo ha proposto di campionare matrici di correlazione realistiche tramite una *Generative Adversarial Network* (GAN), validando l'output generato proprio sulla base dei cinque fatti stilizzati ripresi anche in questa tesi (Capitolo 3). Particolarmente affine all'impostazione qui adottata è inoltre il lavoro di Caprioli et al. [2024], che sostituisce l'approccio avversariale con un Variational Autoencoder addestrato su matrici di correlazione storiche, ottenendo uno spazio latente a bassa dimensionalità interpretabile e utilizzabile, tramite ricampionamento (*bootstrap*) delle sue coordinate, per stimare distribuzioni di rischio di portafoglio senza ricorrere a ripetute simulazioni Monte Carlo — un'analogia metodologica diretta con la procedura di generazione a blocchi bootstrap nello spazio latente impiegata nel Capitolo 8 di questo lavoro.

Per garantire che le matrici sintetiche generate risultino rigorosamente semidefinite positive (PSD) — un vincolo algebrico imprescindibile per qualsiasi matrice di correlazione valida — l'input dei modelli non si basa sulla matrice cruda, bensì sulla sua decomposizione di Cholesky. Attraverso questa parametrizzazione, i modelli apprendono a comprimere e successivamente riprodurre l'intera struttura informativa nel pieno rispetto dei vincoli matematici.

Al fine di mappare con rigore scientifico le capacità di questi strumenti, il framework introduce un percorso di validazione applicato uniformemente alle tecniche testate — Principal Component Analysis (PCA), Autoencoder Lineari (Linear AE), Autoencoder Profondi (AE) e Variational Autoencoder (VAE). L'integrazione di metriche di errore matematico classiche combinate con metriche topologiche permette di valutare sia il potere ricostruttivo delle architetture di base, sia l'effettiva capacità del VAE di generare ecosistemi realistici.

1.3 Obiettivi della tesi

Il presente lavoro di tesi si propone di progettare, implementare e testare un framework basato su architetture neurali profonde per la compressione, ricostruzione e generazione stocastica di matrici di correlazione realistiche.

Gli obiettivi specifici della ricerca possono essere declinati nei seguenti punti:

1. **Sviluppo della pipeline di pre-processing:** Definire una procedura rigorosa per l'estrazione e la pulizia dei dati dell'S&P 500 (2000-2020). Al fine di garantire la continuità delle serie storiche ed evitare distorsioni campionarie, i dati sono stati filtrati richiedendo la presenza ininterrotta delle quotazioni per l'intero ventennio, isolando così un bacino di studio di 362 asset. Viene successivamente implementata la decomposizione di Cholesky per ottimizzare l'input per le reti neurali e garantire strutturalmente la positività semidefinita delle matrici prodotte.
2. **Studio comparativo del potere ricostruttivo:** Valutare le performance di compressione e ricostruzione storica seguendo un approccio metodologico incrementale: dall'istituzione di un *benchmark* lineare (PCA), alla sua approssimazione neurale (Linear AE), fino all'introduzione della non-linearità (AE). L'obiettivo è dimostrare quantitativamente, tramite metriche di errore spaziale (MSE, MAE, norma di Frobenius) e topologiche (MST), come le architetture profonde superino i limiti dei modelli lineari nelle varie configurazioni dello spazio latente K .
3. **Integrazione probabilistica e generazione stocastica:** Superare i limiti di simulazione deterministica introducendo una componente probabilistica nello spazio latente attraverso i Variational Autoencoder (VAE). Lo scopo centrale è testare l'esclusiva capacità generativa del modello, campionando matrici sintetiche inedite e validandone la robustezza sulla base della loro conformità ai cinque *fatti stilizzati* fondamentali delle matrici di correlazione finanziarie empiriche.

Capitolo 2

Matrici di Correlazione in Ambito Finanziario

2.1 Il ruolo della correlazione e la necessità di previsioni future (Markowitz)

La formalizzazione moderna del concetto di diversificazione trova il suo fondamento nella *Modern Portfolio Theory* (MPT), introdotta da Harry Markowitz nel 1952 [Markowitz, 1952]. Il paradigma fondamentale si basa su un principio molto intuitivo: un investitore razionale cerca sempre di massimizzare il rendimento atteso minimizzando al contempo il rischio complessivo del proprio portafoglio. In questo contesto, il rischio non dipende solamente dalla volatilità dei singoli asset isolati, ma soprattutto da come questi si muovono congiuntamente nel tempo.

Questa dinamica di co-movimento è catturata geometricamente e matematicamente dalla matrice di correlazione. Il potere della diversificazione risiede interamente nelle proprietà di questa matrice: inserendo in un portafoglio titoli che non si muovono in perfetta sincronia (ovvero con una correlazione inferiore a 1), il rischio di sistema risulta strettamente inferiore alla semplice somma dei rischi individuali.

Tuttavia, l'applicazione pratica di questo principio si scontra con un limite temporale cruciale. Ottimizzare un portafoglio o calcolarne i rischi basandosi esclusivamente sulla matrice di correlazione storica significa assumere implicitamente che le interdipendenze del passato rimangano immutate. Nella realtà, i mercati finanziari sono ecosistemi altamente dinamici e la struttura delle correlazioni è soggetta a continui mutamenti, specialmente nei periodi di stress.

Le decisioni di investimento e di gestione del rischio vengono prese nel presente, ma i loro effetti si manifestano nel futuro. Per questo motivo, l'obiettivo moderno della finanza quantitativa non è semplicemente descrivere il passato, ma **prevedere la struttura di correlazione futura**. Nello specifico del nostro framework, lo scopo è sviluppare modelli in grado di apprendere le dinamiche complesse del mercato per generare scenari realistici e prevedere le matrici di correlazione a **un mese di distanza nel futuro**. Solo anticipando

l'evoluzione delle dipendenze a un orizzonte di 21 giorni lavorativi (1 mese) è possibile costruire strategie robuste, evitando che il portafoglio crolli in performance non appena testato fuori campionario.

2.2 Il problema del rumore nelle matrici empiriche

Nella pratica finanziaria, la vera matrice di correlazione della popolazione non è osservabile direttamente. Gli analisti si affidano quindi allo stimatore campionario standard, partendo dalle serie storiche dei rendimenti degli asset.

Questo approccio incontra un limite strutturale severo, noto come la “maledizione della dimensionalità” o problema del rumore statistico, ampiamente documentato dalla letteratura di *Random Matrix Theory* applicata alla finanza [Bouchaud and Potters, 2009, Plerou et al., 1999, 2002]. L'accuratezza dello stimatore dipende in modo critico dal parametro di spettro q , definito come il rapporto tra la dimensione spaziale e quella temporale del dataset:

$$q = \frac{N}{T} \quad (2.1)$$

dove N è il numero di asset e T è la lunghezza della serie storica (giorni di negoziazione).

Nei mercati moderni, la necessità di analizzare panieri ad alta dimensionalità (come il nostro sottoinsieme dell'indice S&P 500, dove $N = 362$) si scontra con la limitatezza dei dati storici stazionari. Quando la lunghezza temporale T non è infinitamente superiore al numero di asset N , la matrice empirica accumula un livello di rumore campionario così elevato da perdere consistenza statistica.

Dal punto di vista dell'algebra lineare, l'instabilità si manifesta macroscopicamente attraverso lo spettro degli autovalori della matrice. Gli autovalori più piccoli tendono artificialmente verso lo zero, mentre i più grandi vengono sistematicamente sovrastimati. L'impatto operativo di tale distorsione è dirompente: gli algoritmi finiscono per allocare la maggior parte del capitale sfruttando autovalori minuscoli che non descrivono reali relazioni di diversificazione, ma sono meri artefatti statistici. Il risultato pratico è un collasso delle performance su dati reali (*out-of-sample breakdown*).

2.3 Generazione di scenari stocastici futuri tramite decomposizione di Cholesky

Per far fronte al problema del rumore e alla necessità di valutare il portafoglio a un mese di distanza, i sistemi di *risk management* si affidano a metodologie di simulazione avanzate, come i motori Monte Carlo. Il cuore di tali simulazioni risiede nella capacità di generare migliaia di scenari stocastici futuri che preservino rigorosamente la struttura delle dipendenze del mercato reale.

Supponendo di voler simulare scenari a un mese nel futuro, il processo richiede di proiettare la struttura di correlazione attesa su vettori stocastici indipendenti $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N)$. Per compiere questa operazione in modo matematicamente coerente, è fondamentale che la

matrice di correlazione sintetica $\mathbf{C}$ sia simmetrica e definita positiva (PSD). Se questa proprietà è rispettata, è possibile calcolare la sua decomposizione di Cholesky, individuando una matrice triangolare inferiore $\mathbf{L}$ tale per cui:

$$\mathbf{C} = \mathbf{L}\mathbf{L}^T \quad (2.2)$$

Il vettore dei rendimenti simulati per l'orizzonte temporale futuro viene quindi sintetizzato applicando una trasformazione lineare basata su $\mathbf{L}$ alle variabili casuali indipendenti.

Se la matrice di correlazione generata dai modelli deterministici classici perde la proprietà di positività semidefinita (a causa di rumore, arrotondamenti o errori di previsione), l'estrazione di Cholesky fallisce, rendendo impossibile la simulazione dello scenario. Inoltre, i metodi tradizionali non riescono a simulare efficacemente gli *shock* asimmetrici. È in questo spazio che si inserisce la necessità di un'architettura generativa profonda (come i VAE) che garantisca matematicamente la correttezza algebrica della scomposizione di Cholesky e, al tempo stesso, sia in grado di prevedere la reale morfologia delle correlazioni finanziarie a un mese di distanza. Un approccio concettualmente affine, applicato al rischio di portafogli crediti, è quello di [Caprioli et al. \[2024\]](#), in cui un VAE addestrato su matrici di correlazione storiche viene usato per costruire scenari sintetici a supporto della stima del rischio, tramite ricampionamento delle coordinate dello spazio latente appreso.

Capitolo 3

Fatti Stilizzati delle Matrici di Correlazione

3.1 Introduzione alle proprietà strutturali dei mercati reali

In finanza quantitativa, il termine *stylized facts* (fatti stilizzati) identifica un insieme di regolarità statistiche ed empiriche ampiamente verificate nei mercati finanziari globali, le quali risultano persistenti nel tempo, invarianti rispetto alle diverse asset class e indipendenti dagli specifici orizzonti temporali di campionamento [Cont, 2001]. Sebbene l'andamento individuale dei prezzi dei titoli segua dinamiche fortemente stocastiche e apparentemente caotiche, le relazioni di interdipendenza congiunta manifestano vincoli geometrici e topologici estremamente rigidi.

Quando si analizza un sistema ad alta dimensionalità composto da attività finanziarie reali — come il paniere di 362 asset estratti dall'indice S&P 500 nell'orizzonte 2000-2020 utilizzato in questo lavoro — la relativa matrice di correlazione empirica $\hat{C}$ cessa di essere un mero aggregato statistico di coefficienti indipendenti. Essa assume invece la natura di un operatore strutturato che riflette l'organizzazione interna del sistema economico.

Identificare e formalizzare queste proprietà strutturali è un prerequisito fondamentale per la validazione di qualsiasi modello di compressione o generazione. Un framework generativo basato su *deep learning*, come un Variational Autoencoder, non deve semplicemente minimizzare un errore di ricostruzione puntuale (come l'MSE), ma deve dimostrare la capacità matematica di preservare e sintetizzare ex-novo tali regolarità del mercato. Al fine di tracciare un confine netto tra le informazioni strutturali e il rumore statistico puramente casuale, la letteratura scientifica definisce cinque proprietà geometriche essenziali che caratterizzano univocamente i mercati reali. Questo stesso insieme di cinque proprietà è stato adottato, nel contesto della generazione sintetica di matrici di correlazione tramite reti neurali generative, come protocollo di validazione da Marti [2019] nel lavoro pionieristico su CorrGAN, e verrà ripreso in questa tesi (Capitolo 8) per validare le matrici sintetiche prodotte dal VAE.

Le proprietà teoriche descritte in questo capitolo vengono verificate empiricamente su una singola matrice di correlazione del dataset finale, scelta come esempio rappresentativo e identificata dall'indice 100 nella pipeline di preprocessing (Capitolo 5). La Figura 3.1 mostra questa matrice ($N = 362$ asset, finestra $W = 724$ giorni) riordinata secondo un clustering gerarchico: i blocchi rossi densi lungo la diagonale, separati da regioni fuori blocco nettamente più chiare, anticipano visivamente la struttura gerarchica formalizzata nella Sezione 3.5.




Figura 3.1. Matrice di correlazione empirica n.100 del dataset finale ($N = 362$ asset), riordinata secondo clustering gerarchico. I blocchi rossi densi lungo la diagonale corrispondono a raggruppamenti settoriali.

3.2 Distribuzione asimmetrica delle correlazioni pairwise

La prima proprietà macroscopica di una matrice di correlazione finanziaria reale risiede nella morfologia della distribuzione di probabilità dei suoi elementi fuori diagonale C_{ij} con $i \neq j$, noti come coefficienti *pairwise*.

In un mercato teorico puramente casuale, in cui i rendimenti dei titoli fossero ortogonali e statisticamente indipendenti, la distribuzione empirica dei coefficienti di correlazione si presenterebbe come una curva simmetrica centrata esattamente sullo zero, le cui fluttuazioni campionarie attorno al valore nullo dipenderebbero unicamente dalla limitatezza della serie storica T .

Al contrario, nei mercati finanziari reali si osserva un fenomeno sistematico di deviazione statistica (*distribution shift*). La distribuzione delle correlazioni *pairwise* è marcatamente asimmetrica e significativamente spostata verso valori positivi, con una media campionaria stabilmente superiore allo zero, tipicamente confinata nell'intervallo $[0.2, 0.5]$. Questo spostamento globale riflette l'esistenza del cosiddetto “effetto mercato” o fattore di rischio sistematico: in condizioni macroeconomiche ordinarie, e in modo ancora più esasperato durante i crolli finanziari, la quasi totalità degli asset tende a muoversi nella medesima direzione, spinta da shock sistemici globali che dominano sulle componenti idiosincratiche dei singoli titoli.




Figura 3.2. Distribuzione empirica dei coefficienti di correlazione *pairwise* della matrice n. 100 del dataset finale ($N = 362$ asset, $W = 724$ giorni). La media campionaria (0.2334) e la mediana (0.2257) risultano spostate verso valori positivi rispetto allo zero atteso sotto l’ipotesi di indipendenza.

Sulla matrice n. 100 del dataset finale di questa tesi, la distribuzione dei coefficienti *pairwise* (Figura 3.2) presenta una media di 0.2334 e una mediana di 0.2257, con la stragrande maggioranza dei coefficienti positivi e solo una coda marginale di valori negativi:

un riscontro coerente e quantitativamente in linea con l'intervallo teorico $[0.2, 0.5]$ atteso per un mercato azionario reale.

3.3 Analisi spettrale e distribuzione di Marchenko-Pastur

L'analisi dello spettro degli autovalori fornisce la descrizione algebrica più profonda della struttura informativa contenuta in $\hat{\mathbf{C}}$. Sia $\{\lambda_1, \lambda_2, \dots, \lambda_N\}$ l'insieme degli autovalori stabili della matrice di correlazione empirica, ordinati in senso decrescente tale per cui $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$.

Il punto di riferimento matematico per isolare il rumore è fornito dalla *Random Matrix Theory* (RMT) [Bouchaud and Potters, 2009, Plerou et al., 1999, 2002]. Sotto l'ipotesi nulla che la matrice dei dati $\mathbf{X} \in \mathbb{R}^{N \times T}$ sia composta da variabili aleatorie indipendenti e identicamente distribuite con media nulla e varianza unitaria, lo spettro degli autovalori della matrice empirica, nel limite $N \rightarrow \infty, T \rightarrow \infty$ con rapporto di spettro $q = N/T$ costante, converge rigorosamente alla densità di probabilità di Marchenko-Pastur (MP):

$$P(\lambda) = \frac{1}{2\pi q} \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{\lambda} \cdot \mathbb{I}_{[\lambda_-, \lambda_+]}(\lambda) \quad (3.1)$$

I confini teorici dello spettro di puro rumore, noti come *bulk* di Marchenko-Pastur, sono definiti analiticamente dai limiti rigidi:

$$\lambda_{\pm} = (1 \pm \sqrt{q})^2 \quad (3.2)$$

Quando si analizza lo spettro di una matrice di correlazione reale, l'evidenza empirica mostra una violazione drammatica della legge di Marchenko-Pastur, ripartendo gli autovalori in tre componenti distinte:

1. **Il primo autovalore dominante** ($\lambda_1 \gg \lambda_+$): Si osserva un singolo autovalore di magnitudo straordinaria che si colloca ordini di grandezza al di sopra del limite superiore del *bulk* casuale. Questo autovalore cattura l'effetto mercato descritto nella sezione precedente e da solo spiega una frazione enorme (spesso superiore al 30-40%) della varianza totale del sistema finanziario.
2. **Gli autovalori settoriali intermedi** ($\lambda_k > \lambda_+$): Un ristretto numero di autovalori intermedi riesce a violare il limite λ_+ , posizionandosi al di fuori della densità di MP. Questi autovalori descrivono le interdipendenze stabili esistenti tra gruppi di asset appartenenti a specifici comparti industriali o economici.
3. **Il bulk del rumore** ($\lambda \leq \lambda_+$): La stragrande maggioranza dei rimanenti autovalori (spesso oltre il 90% del totale) rimane confinata all'interno dell'intervallo $[\lambda_-, \lambda_+]$. Questa porzione dello spettro è statisticamente indistinguibile dal puro rumore bianco, confermando che la frazione predominante delle relazioni puntuali descritte dalle matrici empiriche è priva di reale contenuto informativo stazionario.




Figura 3.3. Confronto tra lo spettro empirico degli autovalori della matrice n.100 e la densità teorica di Marchenko-Pastur (sinistra) e primi 20 autovalori (destra), con $q = N/T = 362/724 = 0.5$ e limite superiore teorico $\lambda_+ = 2.914$.

Applicando questa analisi alla matrice n. 100 del dataset finale ($q = N/T = 362/724 = 0.5$, con limiti teorici $\lambda_- = 0.086$ e $\lambda_+ = 2.914$, Figura 3.3), si osservano 9 autovalori al di sopra del limite superiore del *bulk*, mentre il primo autovalore $\lambda_1 = 88.753$ spiega da solo il 24.5% della varianza totale (poiché $\text{Tr}(\hat{C}) = N = 362$): un riscontro pienamente coerente con la ripartizione teorica in mercato, settori e rumore descritta sopra.

3.4 Proprietà di Perron-Frobenius empirica

La natura dominante del primo autovalore λ_1 trova una rigorosa formalizzazione nelle proprietà dell'autovettore ad esso associato, indicato come $\mathbf{v}_1 = [v_{1,1}, v_{1,2}, \dots, v_{1,N}]^T$. In ambito puramente matematico, il teorema di Perron-Frobenius stabilisce che per matrici a elementi strettamente non negativi, l'autovettore principale possiede componenti tutte dello stesso segno; Hüttner and Mai [2019] formalizzano esplicitamente questa proprietà per le matrici di correlazione finanziarie e ne propongono un algoritmo di simulazione dedicato.

Sebbene le matrici di correlazione finanziaria empiriche non siano strettamente non negative — poiché presentano fisiologicamente coefficienti negativi dovuti a coperture o dinamiche avverse — la forte dominanza delle correlazioni positive medie indotta dall'effetto mercato fa sì che il sistema finanziario manifesti una sorta di “proprietà di Perron-Frobenius empirica”.

Le implicazioni di questa proprietà si traducono in due vincoli algebrici per la matrice $\hat{C}$:

1. **Unicità e non degenerazione:** L'autovalore massimo λ_1 è reale, strettamente positivo e possiede molteplicità uno. Ciò garantisce che la direzione a massima varianza dello spazio finanziario sia unica.
2. **Uniformità di segno:** Nonostante la presenza di correlazioni *pairwise* negative all'interno della matrice, tutti gli elementi del primo autovettore associato $\mathbf{v}_1$ presentano sistematicamente il medesimo segno algebrico. Per convenzione standard di

normalizzazione, possono essere assunti come strettamente positivi ($v_{1,i} > 0 \forall i = 1, \dots, N$).

Dal punto di vista economico-finanziario, questa proprietà è cruciale. Poiché ciascuna componente $v_{1,i}$ quantifica il livello di partecipazione del titolo i -esimo al primo fattore principale, l'uniformità del segno dimostra che l'effetto mercato agisce in modo cooperativo su tutti i titoli del paniere. Pur con intensità diverse, nessuno degli asset analizzati si muove strutturalmente in opposizione di fase rispetto al trend macroeconomico globale dominante.




Figura 3.4. Componenti del primo autovettore $\mathbf{v}_1$ (*market mode*) della matrice n.100 per ciascuno dei 362 asset: tutte le componenti risultano dello stesso segno, in accordo con la proprietà di Perron-Frobenius.

Verificando empiricamente questa proprietà sulla matrice n. 100 del dataset finale (Figura 3.4), il primo autovettore presenta sistematicamente componenti dello stesso segno (tutte positive) e l'autovalore massimo λ_1 ha molteplicità algebrica pari a uno: la matrice soddisfa pienamente la proprietà di Perron-Frobenius.

3.5 Struttura gerarchica delle correlazioni

Un'altra proprietà fondamentale dei mercati reali è l'organizzazione sub-strutturale delle correlazioni secondo un principio gerarchico. All'interno del tessuto economico, le aziende non interagiscono in modo uniforme: imprese appartenenti alla medesima filiera o al medesimo comparto industriale (es. *Information Technology* o *Energy*) manifestano livelli di co-movimento mutuo significativamente più intensi rispetto a quelli registrati tra aziende operanti in settori ortogonali.

Se si applica un algoritmo di ordinamento ottimale basato su metriche di clustering gerarchico sulla matrice $\hat{\mathbf{C}}$, l'organizzazione interna si palesa visivamente sotto forma di blocchi densi disposti lungo la diagonale principale. Questa struttura ad albero (esprimibile analiticamente mediante dendrogrammi) dimostra che il mercato è organizzato secondo un'architettura multi-scala: un livello globale (effetto mercato), macro-cluster stabili (i

settori GICS) e micro-aggregazioni locali (le sotto-industrie), un risultato osservato per la prima volta da Mantegna [1998] sui titoli del Dow Jones e dell'S&P 500. La preservazione di tale gerarchia è il test fondamentale per determinare se un modello architetturale profondo stia apprendendo la reale tassonomia economica dei dati.




Figura 3.5. Dendrogramma ottenuto tramite *average linkage* sulla distanza $d_{ij} = \sqrt{2(1 - C_{ij})}$, calcolato sulla matrice n.100 (Figura 3.1). Si distinguono chiaramente cluster densi corrispondenti a raggruppamenti settoriali.

3.6 Il Minimum Spanning Tree (MST) e la proprietà scale-free

Per estrarre l'ossatura topologica essenziale eliminando le ridondanze informative della matrice di correlazione, la finanza quantitativa utilizza strumenti derivati dalla teoria dei grafi. Il metodo d'elezione, introdotto da Mantegna [1998], consiste nella costruzione del *Minimum Spanning Tree* (Albero di Espansione Minima).

Il primo passaggio richiede la trasformazione della matrice dei coefficienti di correlazione $\mathbf{C}$ in una matrice delle distanze geometriche $\mathbf{D}_{\text{graph}}$. Per ridefinire gli elementi C_{ij} come distanze metriche reali che soddisfino gli assiomi di positività, simmetria e disuguaglianza triangolare, si applica la trasformazione non lineare:

$$d_{ij} = \sqrt{2(1 - C_{ij})} \quad (3.3)$$

Il coefficiente d_{ij} assume valore 0 in caso di correlazione perfetta positiva ($C_{ij} = 1$), valore $\sqrt{2}$ per asset indipendenti ($C_{ij} = 0$) e valore 2 per titoli perfettamente anticorrelandoli ($C_{ij} = -1$).

Utilizzando la matrice delle distanze come mappa dei pesi di un grafo completo, si applicano algoritmi classici di ottimizzazione combinatoria (quali l'algoritmo di Kruskal o di Prim) per estrarre l'MST. L'MST è un sottografo connesso e privo di cicli che collega tutti gli N nodi (gli asset) selezionando gli $N - 1$ archi che minimizzano la somma totale delle distanze geometriche.

La proprietà stilizzata che qualifica gli MST dei mercati finanziari reali è la natura *scale-free* (invariante di scala) della loro topologia di rete. Sia k_i il grado del nodo i -esimo, definito come il numero di archi incidenti sul nodo stesso nell'albero ottimizzato. Nei mercati reali, la distribuzione empirica del grado dei nodi $P(k)$ non segue una curva

gaussiana o poissoniana, ma è governata da una legge di potenza:

$$P(k) \propto k^{-\gamma} \quad (3.4)$$

dove γ rappresenta l'esponente di scala strutturale, solitamente confinato nell'intervallo $2 < \gamma < 3$.

La validità della legge di potenza implica la presenza di una topologia fortemente ac-centrata. L'MST finanziario è dominato da pochissimi nodi ad altissima connettività, definiti *hubs* super-connessi, che agiscono come centri collettori dell'informazione finanziaria (tipicamente grandi aziende leader di settore o holding sistemiche), attorno ai quali si dispongono radialmente ampi cluster di nodi periferici a basso grado (nodi foglia).




Figura 3.6. Distribuzione di grado del Minimum Spanning Tree della matrice n. 100, in scala log-log: l'andamento lineare conferma la legge di potenza $P(k) \propto k^{-\gamma}$.

Sulla matrice n. 100 (Figura 3.6 e Figura 3.7), il fit log-log della distribuzione di grado restituisce un esponente di scala stimato $\gamma = -2.207$ (grado massimo 14): un valore pienamente interno all'intervallo $2 < |\gamma| < 3$ tipicamente riportato in letteratura, a conferma della natura marcatamente *scale-free*, non gaussiana, della topologia di rete osservata, con pochi *hub* dominanti circondati da un'ampia periferia di nodi a basso grado.

3.7 Benchmark test: fallimento strutturale della Random Matrix Theory

Al fine di validare rigorosamente la significatività statistica dei cinque fatti stilizzati descritti, viene definito un protocollo di *benchmark test* basato sul confronto diretto tra le matrici finanziarie reali e le matrici puramente casuali generate sinteticamente tramite i teoremi della Random Matrix Theory.

Generando una matrice di controllo mediante l'estrazione di N serie temporali di puro rumore gaussiano bianco i.i.d., si costruisce la corrispondente matrice di correlazione




Figura 3.7. Visualizzazione topologica del Minimum Spanning Tree per la matrice n. 100 (Figura 3.1), con nodi etichettati per ticker e colorati per settore GICS: si osservano chiaramente *hub* settoriali e cluster periferici.

casuale. Sottoponendo tale matrice al medesimo protocollo di analisi qualitativo e quantitativo, si registra un fallimento strutturale sistematico nell’adempimento delle proprietà del mercato reale:

Stylized Fact	Mercato Reale (S&P 500)	Benchmark RMT (Pure Noise)
Distribuzione <i>Pairwise</i>	Fortemente asimmetrica, shifted verso valori positivi.	Perfettamente simmetrica e centrata sullo zero.
Spettro degli Autovalori	Presenza di $\lambda_1 \gg \lambda_+$ (mercato) e $\lambda_k > \lambda_+$ (settori).	Interamente vincolato entro i limiti di MP: $[\lambda_-, \lambda_+]$.
Proprietà di Perron-Frobenius	Valida: $\mathbf{v}_1$ ha componenti unicamente positive.	Fallita: $\mathbf{v}_1$ ha componenti a segni casuali stocastici.
Organizzazione Interna	Struttura gerarchica e tassonomica a blocchi settoriali.	Assenza totale di pattern; matrice omogenea amorfa.
Topologia dell’MST	Rete <i>scale-free</i> retta da legge di potenza con <i>hubs</i> .	Grafo casuale omogeneo privo di nodi centrali dominanti.

Tabella 3.1. Quadro comparativo strutturale tra le proprietà geometriche dei mercati reali e il benchmark probabilistico della Random Matrix Theory.

Per rendere visivamente tangibile il fallimento sintetizzato in Tabella 3.1, le Figure 3.8–3.13 confrontano fianco a fianco la matrice reale n. 100 già analizzata nelle Sezioni 3.2–3.6 con una matrice di controllo costruita a partire da $N = 362$ serie temporali di rumore gaussiano bianco i.i.d. $\mathcal{N}(0,1)$ di lunghezza $T = 724$: le stesse dimensioni della matrice reale, cosicché ogni differenza osservata sia imputabile esclusivamente alla struttura di mercato e non a un semplice effetto di dimensionalità campionaria.

La Figura 3.8 mostra il primo confronto diretto sulla distribuzione *pairwise*: mentre la matrice reale conserva la media positiva pari a 0.2334 discussa nella Sezione 3.2, la distribuzione del benchmark casuale è perfettamente simmetrica, centrata su una media pressoché nulla (0.0000) e con deviazione standard 0.0373, in pieno accordo con il valore teorico atteso $1/\sqrt{T} = 0.0372$ per correlazioni campionarie tra serie indipendenti. Circa il 50% dei coefficienti del benchmark risulta negativo, contro lo 0.06% osservato nel mercato reale.




Figura 3.8. Proprietà 1 – Distribuzione dei coefficienti *pairwise*: mercato reale (matrice n. 100, media 0.2334) contro benchmark RMT di rumore gaussiano i.i.d. (media 0.0000, deviazione standard $0.0373 \approx 1/\sqrt{T}$).

La Figura 3.9 conferma la stessa dicotomia nello spettro degli autovalori: nella matrice reale il primo autovalore $\lambda_1 = 88.753$ (pari al 24.5% della varianza totale) fuoriesce di quasi due ordini di grandezza dal limite superiore teorico $\lambda_+ = 2.914$, insieme ad altri 8 autovalori settoriali che violano il medesimo limite. Nel benchmark casuale, costruito con lo stesso rapporto spettrale $q = N/T = 0.5$, l'intero spettro empirico aderisce visivamente alla densità teorica di Marchenko-Pastur: il primo autovalore vale appena 2.907 (leggermente sotto λ_+ , una fluttuazione di dimensione finita pienamente compatibile con la teoria) e nessun autovalore emerge oltre il bulk, a conferma dell'assenza di qualsiasi fattore di mercato o settoriale.

La proprietà di Perron-Frobenius, verificata nella Sezione 3.4 per la matrice reale, fallisce sistematicamente nel benchmark casuale (Figura 3.10): il primo autovettore della matrice di controllo presenta segni distribuiti casualmente (50.8% di componenti negative), contro l'uniformità di segno (tutte le componenti positive) osservata nel mercato reale. L'assenza di un effetto mercato cooperativo si traduce quindi nella perdita totale della struttura di segno dell'autovettore dominante.




Figura 3.9. Proprietà 2 – Spettro degli autovalori contro la densità di Marchenko-Pastur ($q = 0.5$, $\lambda_+ = 2.914$): la matrice reale espone 9 autovalori oltre il bulk (incluso il modo di mercato $\lambda_1 = 88.753$), mentre il benchmark RMT non ne presenta alcuno ($\lambda_1 = 2.907$).




Figura 3.10. Proprietà 3 – Componenti del primo autovettore: segni tutti concordi (positivi) nella matrice reale contro segni casuali (50.8% negativi) nel benchmark RMT, che viola la proprietà di Perron-Frobenius.

Applicando alla matrice casuale lo stesso algoritmo di clustering gerarchico utilizzato nella Sezione 3.5, la Figura 3.11 mostra che nessun riordinamento è in grado di rivelare blocchi diagonali: mentre la matrice reale riordinata espone chiaramente i raggruppamenti settoriali già osservati in Figura 3.1, la matrice casuale riordinata rimane un campo omogeneo e privo di struttura, con correlazioni fuori diagonale confinate nell'intervallo $[-0.163, 0.160]$ (deviazione standard 0.037) contro l'intervallo $[-0.099, 0.836]$ (deviazione standard 0.092) della matrice reale.

Infine, la topologia di rete conferma il quadro (Figure 3.12 e 3.13). L'MST del benchmark casuale presenta un grado massimo di soli 6 collegamenti, contro i 14 del nodo *hub* più connesso della matrice reale, pur condividendo lo stesso grado medio ≈ 1.99 imposto dal vincolo topologico $\sum_i k_i = 2(N - 1)$ comune a ogni albero di espansione. La distribuzione di grado casuale si esaurisce entro poco più di mezza decade, un intervallo




Figura 3.11. Proprietà 4 – Matrice di correlazione riordinata per clustering gerarchico: blocchi settoriali densi e riconoscibili nella matrice reale contro un campo omogeneo e amorfo nel benchmark RMT, ottenuto applicando lo stesso algoritmo di ordinamento.

incompatibile con l'estensione multi-decade richiesta da una autentica legge di potenza scale-free.




Figura 3.12. Proprietà 5 – Distribuzione di grado dell'MST in scala log-log: la matrice reale raggiunge un grado massimo di 14 su un intervallo esteso, mentre il benchmark RMT si esaurisce entro il grado 6, senza alcun nodo *hub*.

La visualizzazione topologica in Figura 3.13 rende immediatamente evidente il contrasto: la matrice reale genera *hub* settoriali chiaramente visibili, colorati per settore GICS e di dimensione proporzionale al grado, mentre l'MST casuale produce una rete omogenea, priva di nodi centrali dominanti e di qualunque cluster settoriale riconoscibile (colore uniforme).




Figura 3.13. Proprietà 5 – Visualizzazione topologica del Minimum Spanning Tree: *hub* settoriali ben visibili nella matrice reale (colore = settore GICS, dimensione = grado del nodo) contro una rete omogenea priva di centri dominanti nel benchmark RMT.

Questo fallimento radicale dimostra matematicamente che i cinque fatti stilizzati costituiscono la firma geometrica esclusiva dell'informazione finanziaria reale. Qualsiasi modello generativo profondo non può limitarsi a operare nel dominio di metriche rigide di errore quadratico medio, ma deve necessariamente superare questo *benchmark test*. Il Variational Autoencoder, per essere considerato un valido motore stocastico di scenari, dovrà generare matrici sintetiche dallo spazio latente che non solo si discostino dal rumore di MP, ma che replichino fedelmente tutte le asimmetrie e le leggi di potenza che la Random Matrix Theory non è in grado di spiegare.

Capitolo 4

Riduzione della Dimensionalità e Modelli Generativi

4.1 Principal Component Analysis (PCA): teoria e limiti lineari

La *Principal Component Analysis* (PCA) rappresenta lo standard aureo classico per la riduzione della dimensionalità e l'estrazione di feature in ambito statistico e finanziario [Jolliffe and Cadima, 2016]. Dal punto di vista algebrico, la PCA opera una trasformazione ortogonale lineare che proietta i dati originali in un nuovo sistema di coordinate, in cui gli assi (le componenti principali) sono allineati lungo le direzioni di massima varianza del dataset.

Considerando il vettore linearizzato di input $\mathbf{x} \in \mathbb{R}^D$ (che nel nostro dominio rappresenta gli elementi della matrice triangolare inferiore), la PCA ricerca una matrice di proiezione $\mathbf{W} \in \mathbb{R}^{D \times k}$ con $k < D$, tale per cui le colonne di $\mathbf{W}$ siano ortonormali ($\mathbf{W}^T \mathbf{W} = \mathbf{I}_k$). La proiezione nello spazio latente lineare è data da:

$$\mathbf{z} = \mathbf{W}^T \mathbf{x} \quad (4.1)$$

dove $\mathbf{z} \in \mathbb{R}^k$ rappresenta il vettore delle coordinate compresse. La ricostruzione nello spazio originale si ottiene applicando la trasformazione inversa:

$$\hat{\mathbf{x}} = \mathbf{W}\mathbf{z} = \mathbf{W}\mathbf{W}^T \mathbf{x} \quad (4.2)$$

L'ottimizzazione della PCA consiste nel trovare la matrice $\mathbf{W}$ che minimizzi l'errore quadratico medio di ricostruzione (MSE) globale, equivalente a massimizzare la traccia della matrice di covarianza proiettata. La soluzione analitica a questo problema coincide con l'autodecomposizione della matrice di covarianza dei dati: le colonne di $\mathbf{W}$ sono gli autovettori associati ai k autovalori dominanti.

Tuttavia, l'applicazione della PCA per la modellizzazione di matrici di correlazione finanziarie incontra un limite insormontabile: la linearità intrinseca. La PCA assume che

la *manifold* (la varietà geometrica sotterranea) su cui risiedono i dati reali sia un iperpiano lineare. I mercati finanziari, al contrario, sono caratterizzati da dinamiche non lineari estreme, come asimmetrie nei co-movimenti sistemici durante le crisi (*tail dependence*) e complesse interazioni gerarchiche di settore. Una trasformazione puramente lineare come la PCA è matematicamente incapace di catturare queste curvature topologiche, producendo ricostruzioni storiche che tendono ad appiattire l'informazione complessa. Anche in ambito più strettamente finanziario, dove la PCA è tradizionalmente applicata ai rendimenti per estrarre fattori di rischio latenti, un limite analogo emerge dalla rigidità dei *loadings*: Kelly et al. [2019] mostrano come rendere dinamici tali pesi — condizionandoli a caratteristiche osservabili dei titoli — migliori sensibilmente la capacità esplicativa rispetto alla PCA statica classica, un'ulteriore conferma indiretta dei limiti dell'approccio puramente lineare che questa tesi affronta nel dominio delle matrici di correlazione.

4.2 Autoencoder Lineari (Linear AE): ponte verso le reti neurali

Per superare il paradigma dell'algebra lineare classica, l'architettura dei modelli di *deep learning* introduce gli *Autoencoder* (AE). Un autoencoder è una rete neurale *feed-forward* addestrata in modo non supervisionato con l'obiettivo di copiare il proprio input nel proprio output, passando attraverso uno strato intermedio compresso detto "collo di bottiglia" (*bottleneck*).

L'architettura minima è composta da due funzioni: un *Encoder* f_ϕ che mappa l'input nello spazio latente $\mathbf{z} = f_\phi(\mathbf{x})$, e un *Decoder* g_θ che ricostruisce l'input $\hat{\mathbf{x}} = g_\theta(\mathbf{z})$.

Il punto di giunzione teorico tra reti neurali e algebra statistica è rappresentato dall'Autoencoder Lineare. Affinché tale modello replichi fedelmente la PCA, è necessario imporre vincoli architetturali rigorosi: le funzioni di attivazione devono essere strettamente lineari (identità), la rete deve essere priva di termini di *bias* e non deve essere applicata alcuna forma di regolarizzazione sui pesi (come il *weight decay*), garantendo che l'ottimizzatore minimizzi esclusivamente il puro errore quadratico medio (MSE):

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - g_\theta(f_\phi(\mathbf{x}_i))\|^2 \quad (4.3)$$

Sotto tali condizioni, assumendo i dati in ingresso centrati, le equazioni della rete si riducono a una doppia trasformazione matriciale pura: $\mathbf{z} = \mathbf{W}_1 \mathbf{x}$ per l'Encoder e $\hat{\mathbf{x}} = \mathbf{W}_2 \mathbf{z}$ per il Decoder.

Come dimostrato formalmente dallo studio seminale di Bourlard e Kamp (1988), l'addestramento di un Linear AE così vincolato comporta una convergenza geometrica rigorosa verso l'ottimo globale. L'algoritmo di retropropagazione farà sì che lo spazio latente generato dalle matrici dei pesi $\mathbf{W}_1$ e $\mathbf{W}_2$ ricopra esattamente il medesimo sottospazio principale identificato dalle prime k componenti della PCA.

Sebbene le matrici dei pesi dell'AE non siano necessariamente ortogonali come nella PCA — Plaut [2018] mostra come sia comunque possibile recuperare esattamente le componenti principali ordinate e ortonormali applicando una SVD ai pesi del *decoder* —

l'Autoencoder Lineare funge da prova matematica cruciale: le reti neurali sono in grado di replicare perfettamente l'ottimo globale lineare. Questo lo rende il *benchmark* strutturale di partenza prima di introdurre la complessità profonda.

4.3 Autoencoder Profondi (AE): introduzione alla non-linearità

L'evoluzione naturale dell'architettura lineare è l'Autoencoder Profondo (Deep AE). Aggiungendo strati nascosti (*hidden layers*) sovrapposti e introducendo funzioni di attivazione non lineari (come ReLU, Tanh o Sigmoidale), la rete neurale acquisisce la capacità, sancita dal Teorema di Approssimazione Universale, di modellare qualsiasi funzione continua complessa.

In questo regime, l'Encoder e il Decoder cessano di essere semplici matrici di proiezione e si trasformano in operatori topologici non lineari. Il Deep AE è in grado di apprendere una *manifold* curva e contorta, piegando lo spazio a latente per mappare in modo efficiente le relazioni gerarchiche settoriali e le proprietà non gaussiane delle matrici di correlazione. La dimensionalità D originale viene progressivamente ridotta attraverso gli strati fino alla dimensione latente k .

Tuttavia, per quanto formidabile nella fase di compressione e ricostruzione storica, il Deep AE fallisce qualora venga impiegato come motore stocastico per simulazioni Monte Carlo. Il problema risiede nella natura non vincolata del suo spazio latente. La rete apprende a disporre i campioni storici nello spazio $\mathbf{z}$ unicamente per minimizzare l'errore di ricostruzione, ignorando l'organizzazione globale di tale spazio. Il risultato è un dominio latente altamente irregolare, frammentato, popolato da vaste "zone vuote" prive di significato geometrico. Se si estraesse un vettore $\mathbf{z}_{\text{random}}$ casuale da questo spazio e lo si facesse passare per il Decoder, la rete genererebbe una matrice di correlazione sintetica totalmente priva di senso economico, incapace di rispettare i fatti stilizzati (violazione del limite di Marchenko-Pastur o della proprietà di Perron-Frobenius). Il Deep AE è eccellente nel ricordare, ma strutturalmente inadatto a immaginare.

4.4 Variational Autoencoders (VAE) e regolarizzazione dello spazio latente

Per abilitare la generazione stocastica di scenari realistici, è necessario un cambio di paradigma architetturale che conduca dal determinismo geometrico alla teoria dell'inferenza probabilistica variazionale. Il *Variational Autoencoder* (VAE), introdotto da Kingma e Welling (2013) e qui ripreso seguendo l'esposizione tutoriale di Doersch [2016], risolve il problema della frammentazione dello spazio latente costringendo l'Encoder a emettere non più singoli vettori puntuali, ma intere distribuzioni di probabilità.

Un paradigma generativo alternativo, altrettanto diffuso in letteratura, è quello delle *Generative Adversarial Networks* (GAN) [Goodfellow, 2016], in cui un generatore e un discriminatore vengono addestrati in un gioco minimax: è questo l'approccio scelto da Marti [2019] per CorrGAN e da Wiese et al. [2019] per la generazione di intere serie

storiche di prezzi (Quant GANs). Rispetto alle GAN, il VAE offre un addestramento più stabile (basato sulla massimizzazione diretta di un limite inferiore della verosimiglianza, senza il gioco minimax generatore/discriminatore) e — aspetto centrale per questo lavoro — uno spazio latente esplicitamente strutturato e di bassa dimensionalità, che può essere ispezionato e ricampionato direttamente: è questa la proprietà sfruttata anche da [Caprioli et al. \[2024\]](#) per costruire scenari di rischio interpretabili, ed è la stessa proprietà su cui si basa la procedura di generazione adottata in questa tesi (Capitolo 8).

Nel VAE, per ogni campione di input $\mathbf{x}$, l'Encoder (ora definito come rete di inferenza) prevede due vettori distinti: un vettore delle medie $\boldsymbol{\mu}$ e un vettore delle varianze $\boldsymbol{\sigma}^2$. Questi vettori parametrizzano una distribuzione gaussiana multivariata $q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$ dalla quale viene campionato il vettore latente $\mathbf{z}$. Affinché questo processo di estrazione stocastica sia differenziabile tramite *backpropagation*, si implementa il cosiddetto *Reparameterization Trick*:

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon} \quad \text{con} \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (4.4)$$

La grandezza ingegneristica del VAE risiede nella sua funzione di *loss*, che massimizza il limite inferiore dell'evidenza (ELBO). Essa è composta da due termini antagonisti:

$$\mathcal{L}_{\text{VAE}} = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[-\log p_\theta(\mathbf{x}|\mathbf{z})]}_{\text{Reconstruction Loss}} + \underbrace{\beta D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z}))}_{\text{KL Divergence}} \quad (4.5)$$

Il primo termine è la *Reconstruction Loss* (tipicamente calcolata come MSE nel nostro dominio continuo), che spinge la rete a minimizzare l'errore tra la matrice di correlazione in ingresso e quella ricostruita.

Il secondo termine, la Divergenza di Kullback-Leibler (D_{KL}), è il motore stocastico dell'architettura. Essa agisce come un rigoroso regolarizzatore topologico, penalizzando l'Encoder se le distribuzioni generate $q_\phi(\mathbf{z}|\mathbf{x})$ si allontanano da una distribuzione *prior* di riferimento, solitamente una gaussiana normale standard $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$.

La competizione tra questi due termini plasma uno spazio latente rivoluzionario. La Divergenza KL costringe tutte le distribuzioni dei singoli campioni ad addensarsi vicino all'origine dello spazio e a sovrapporsi le une con le altre in modo continuo e omogeneo (*packing*), eliminando le zone vuote tipiche degli AE classici. Contemporaneamente, la Reconstruction Loss costringe i campioni simili (es. matrici di correlazione di fasi di espansione economica) a rimanere vicini per poter essere decodificati correttamente, preservando un'ordinata morfologia strutturale.

Questo spazio latente continuo, denso e regolarizzato è il dominio perfetto per il campionamento stocastico. Nella sua forma più semplice, è sufficiente campionare un vettore casuale $\mathbf{z}_{\text{sim}} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ dal *prior* e passarlo al Decoder deterministico $p_\theta(\mathbf{x}|\mathbf{z})$: il modello estrarrà dalla regione di sovrapposizione un pattern coerente, generando una matrice di correlazione sintetica totalmente nuova, mai apparsa nella storia passata, ma che rispetterà rigorosamente l'infrastruttura topologica e i vincoli finanziari (fatti stilizzati) del mercato di addestramento.

Nella pratica di questo lavoro, tuttavia, l'obiettivo non è generare uno scenario plausibile qualunque, ma proiettare la struttura di correlazione a un preciso orizzonte di un mese a partire dallo stato di mercato corrente (Capitolo 2, §2.1). Per questo motivo,

come descritto nel dettaglio nel Capitolo 8, il campionamento diretto dal *prior* $\mathcal{N}(\mathbf{0}, \mathbf{I})$ viene sostituito da una procedura di *block-bootstrap* che ricampiona blocchi di incrementi storici osservati nello spazio latente, ancorando così la generazione stocastica allo stato di mercato osservato oggi, pur sfruttando la medesima regolarità topologica dello spazio latente qui descritta.

Parte II

**Metodologia e Pipeline di
Analisi**

Capitolo 5

Pre-processing e Costruzione del Dataset

5.1 Descrizione del dataset

Il fondamento empirico di questo lavoro di tesi è costituito da un dataset storico di natura azionaria, focalizzato sull'indice S&P 500, assunto come proxy rappresentativa del mercato azionario globale e dell'economia statunitense. Al fine di garantire una base dati sufficientemente ampia per l'addestramento dei modelli di *deep learning* e, contestualmente, catturare molteplici regimi di mercato (incluse fasi di espansione, recessione e shock sistemici), l'orizzonte temporale di riferimento è stato fissato tra l'anno 2000 e il 2020.

Per assicurare la continuità e la stabilità statistica del dataset, l'intera popolazione dei titoli è stata filtrata applicando un rigoroso requisito di sopravvivenza ininterrotta (*survivorship*). Sono stati mantenuti esclusivamente gli asset che hanno registrato quotazioni giornaliere continue per tutto il ventennio di osservazione. Questo processo di epurazione ha prodotto un bacino finale di $N = 362$ titoli azionari. A differenza di campionamenti ridotti, il mantenimento dell'intera popolazione sopravvissuta garantisce una rappresentazione macrostrutturale completa del mercato, eliminando potenziali bias di selezione e preservando in modo organico l'eterogeneità settoriale GICS (*Global Industry Classification Standard*). Tale eterogeneità è fondamentale affinché le matrici di correlazione empiriche manifestino la tipica struttura gerarchica e lo spettro degli autovalori aderente alla vera realtà economica.

I dati grezzi sono costituiti dai prezzi di chiusura giornalieri rettificati (*adjusted closing prices*), i quali incorporano ex-ante gli effetti di operazioni societarie straordinarie, quali stacchi di dividendi, *stock split* e raggruppamenti, prevenendo salti artificiali nelle serie storiche che inquinerebbero il calcolo delle covarianze.

La categoria settoriale GICS di ciascun titolo, necessaria per le analisi di struttura gerarchica del Capitolo 3, non era disponibile da un *provider* dati strutturato: è stata pertanto ricostruita tramite classificazione automatica affidata a un modello linguistico di grandi dimensioni (*Google Gemini*, modello `gemini-2.5-flash`), interrogato con un prompt *few-shot* contenente esempi di riferimento per ciascuna delle undici categorie

GICS. La classificazione ha avuto successo per 360 titoli su 362 (99.4%), con solamente due ticker (**ABC**, **CERN**) rimasti non classificabili (*Unknown*), verosimilmente per ambiguità o obsolescenza del simbolo azionario. La Tabella 5.1 riporta la distribuzione settoriale risultante, che riflette una composizione eterogenea e realistica del mercato.

Settore GICS	N. titoli	%
Industrials	56	15.5%
Financials	50	13.8%
Health Care	46	12.7%
Information Technology	44	12.2%
Consumer Discretionary	33	9.1%
Consumer Staples	29	8.0%
Real Estate	28	7.7%
Utilities	24	6.6%
Materials	20	5.5%
Energy	19	5.2%
Communication Services	11	3.0%
Unknown	2	0.6%
Totale	362	100%

Tabella 5.1. Distribuzione settoriale GICS dei 362 titoli del dataset finale.

5.2 Calcolo dei rendimenti e stima delle matrici empiriche

A partire dalla matrice dei prezzi storici $\mathbf{P} \in \mathbb{R}^{N \times T_{\text{tot}}}$, dove T_{tot} rappresenta il numero totale di giorni di contrattazione nel ventennio e $N = 362$, il primo passaggio di trasformazione algebrica consiste nel calcolo dei log-rendimenti giornalieri continui. Il rendimento dell'asset i -esimo al tempo t è definito come:

$$r_{i,t} = \ln \left(\frac{P_{i,t}}{P_{i,t-1}} \right) \quad (5.1)$$

L'addestramento di modelli di *machine learning* richiede un dataset composto da centinaia di campioni. Poiché la serie storica produce un'unica traiettoria temporale, si rende necessario implementare una procedura di estrazione a finestre mobili (*rolling windows*).

Sia T_w l'ampiezza temporale della finestra di osservazione, fissata operativamente a 724 giorni lavorativi (corrispondenti a quasi tre anni solari di contrattazioni). Definendo un parametro di passo (*stride*) S , la finestra viene fatta scorrere lungo l'intera serie storica. Per ogni step k , si isola un sotto-campione di log-rendimenti $\mathbf{X}^{(k)} \in \mathbb{R}^{N \times T_w}$ e si calcola la corrispondente matrice di correlazione di Pearson empirica $\mathbf{C}^{(k)} \in \mathbb{R}^{N \times N}$, il cui generico elemento è:

$$C_{ij}^{(k)} = \frac{\text{Cov}(r_i, r_j)}{\sigma_i \sigma_j} \quad \text{con dati estratti in } t \in [k \cdot S, k \cdot S + T_w] \quad (5.2)$$

Applicando un passo $S = 10$ giorni (corrispondente esattamente a due settimane lavorative), si bilancia la necessità di generare un numero congruo di campioni per l'addestramento con l'esigenza di ridurre la ridondanza informativa del micro-rumore giornaliero. Questa estrazione tramite finestre ampie cattura in modo molto stabile e privo di rumore transitorio i veri *shift* strutturali di medio-lungo periodo del mercato. In ogni finestra, il rapporto di dimensionamento temporale (rapporto di spettro) si attesta esattamente a $q = N/T_w = 362/724 = 0.5$. Tale valore, mantenendosi rigorosamente costante nel tempo, determina un livello di rumore statistico omogeneo e perfettamente bilanciato, il cui comportamento spettrale è analiticamente governabile dalle leggi della *Random Matrix Theory* e dai limiti di Marchenko-Pastur discussi nei capitoli precedenti.

5.3 Tecnica di campionamento: il Random Shuffle per la stazionarietà

Nella strutturazione convenzionale di serie storiche finanziarie per il *deep learning*, la prassi consolidata prevede una rigida divisione cronologica dei dati in *Training Set*, *Validation Set* e *Test Set*, accompagnata da tecniche di *purging* per gestire la sovrapposizione temporale causata dalle finestre mobili. Tuttavia, test preliminari condotti mediante partizionamento temporale sequenziale hanno evidenziato una dinamica di *distribution shift* estrema: i regimi macroeconomici passati non fornivano informazioni topologiche sufficienti per permettere alle architetture profonde di generalizzare fuori campionario sui regimi futuri.

Per valutare il reale potere ricostruttivo e la capacità di compressione geometrica delle reti neurali, isolandole dall'impatto dei mutamenti macroeconomici radicali nel tempo, la pipeline sperimentale adotta una strategia di campionamento tramite mescolamento casuale (*random shuffle*) sull'intero pool di matrici.

Il processo di estrazione a finestre mobili, applicando il passo costante (*stride*) $S = 10$ giorni lavorativi lungo l'intera serie storica dei prezzi, produce un bacino complessivo di 412 matrici di correlazione empiriche. Queste matrici vengono interamente mischiate in modo stocastico prima di essere ripartite nei tre set operativi, portando alla seguente conformazione tensoriale finale:

- **Training Set:** *shape* (288, 362, 362)
- **Validation Set:** *shape* (82, 362, 362)
- **Test Set:** *shape* (42, 362, 362)

Questo approccio garantisce che la distribuzione statistica sottostante ai tre sottoinsiemi sia perfettamente omogenea e stazionaria: scenari di elevata volatilità e scenari di mercato stabili risultano equamente distribuiti sia nel set di addestramento che in quelli di validazione e test. Questa omogeneizzazione annulla l'impatto del *distribution shift* e permette di testare rigorosamente la capacità dei modelli (PCA, Linear AE, Deep AE, VAE) di apprendere la complessa *manifold* delle correlazioni a parità di condizioni statistiche.

Osservazione 1 *Il mescolamento casuale risolve il problema del distribution shift di regime macroeconomico, ma non elimina di per sé la sovrapposizione informativa tra finestre adiacenti. Poiché lo stride $S = 10$ giorni è molto più piccolo della finestra $T_w = 724$ giorni, due matrici con indice quasi consecutivo condividono fino al 98.6% delle osservazioni sottostanti (714 giorni su 724). Una permutazione puramente casuale, priva di un vincolo di distanza minima tra gli indici assegnati a split diversi, può quindi collocare matrici quasi identiche l'una nel Training Set e l'altra nel Validation o Test Set. Questo limite, distinto dal problema del distribution shift qui risolto, viene discusso tra i limiti metodologici del presente lavoro.*

5.4 Estrazione e flattening delle matrici triangolari inferiori

L'ultimo passaggio della pipeline riguarda la conformazione dell'input per le reti neurali. Ogni matrice di correlazione empirica generata $\mathbf{C}^{(k)}$ ha dimensione $N \times N$, ovvero 362×362 . Tuttavia, per le proprietà intrinseche dell'operatore di correlazione, la matrice è perfettamente simmetrica rispetto alla diagonale principale ($C_{ij} = C_{ji}$) e presenta esclusivamente valori unitari sulla diagonale stessa ($C_{ii} = 1$).

Fornire in pasto a un modello di *deep learning* l'intera griglia 362×362 comporterebbe un grave spreco di risorse computazionali e introdurrebbe una ridondanza geometrica dannosa, costringendo il modello ad allocare pesi sinaptici per apprendere relazioni di simmetria identiche e valori costanti banalmente noti.

Per ottimizzare drasticamente lo spazio delle feature, si procede all'isolamento e all'estrazione della sola matrice triangolare inferiore, scartando la porzione superiore (ridondante per simmetria). Poiché la diagonale principale della matrice di correlazione è banalmente costante ($C_{ii} = 1 \forall i$), essa viene scartata insieme al triangolo superiore (*strictly lower triangular matrix*, offset $k = -1$), riducendo il numero D di elementi unici e informativi alla formula delle combinazioni semplici:

$$D_{\text{raw}} = \frac{N(N-1)}{2} = \frac{362 \times 361}{2} = 65341 \text{ elementi} \quad (5.3)$$

Attraverso un'operazione di *flattening*, gli elementi della matrice triangolare inferiore vengono linearizzati in un vettore monodimensionale $\mathbf{x}^{(k)} \in \mathbb{R}^{65341}$. Questa parametrizzazione (indicata nel seguito come *dominio raw*) costituisce l'input della prima fase sperimentale di questo lavoro.

Come anticipato nel Capitolo 1, per garantire strutturalmente la positività semidefinita delle matrici ricostruite si è successivamente adottata, in via definitiva, la parametrizzazione basata sulla decomposizione di Cholesky $\mathbf{C} = \mathbf{L}\mathbf{L}^T$. In questo caso la diagonale del fattore triangolare inferiore $\mathbf{L}$ non è costante (rappresenta le varianze condizionate residue della fattorizzazione) e deve quindi essere inclusa nel *flattening* (offset $k = 0$), portando la dimensione canonica dell'input a:

$$D_{\text{Cholesky}} = \frac{N(N+1)}{2} = \frac{362 \times 363}{2} = 65703 \text{ elementi} \quad (5.4)$$

È questo vettore $\mathbf{x}^{(k)} \in \mathbb{R}^{65703}$, e non quello a 65341 componenti del dominio raw, a costituire l'input canonico che alimenta i *layer* di ingresso di PCA, Autoencoder Lineare, Autoencoder Profondo e VAE nella pipeline sperimentale definitiva descritta nei capitoli successivi; il dominio raw a 65341 componenti resta documentato e utilizzato solo a fini di confronto metodologico (Capitolo 7).

Capitolo 6

Architetture dei Modelli e Setup Sperimentale

6.1 Implementazione della PCA come baseline

Al fine di stabilire un *benchmark* quantitativo rigoroso per valutare le performance delle reti neurali, la pipeline sperimentale prevede l'implementazione iniziale della *Principal Component Analysis* (PCA). Questo modello funge da base comparativa per determinare il limite massimo di compressione lineare raggiungibile sui dati.

Come tutti i modelli di questa pipeline (Sezioni 6.2–6.4), la PCA è stata addestrata sia sul dominio raw ($\mathbf{x} \in \mathbb{R}^{65341}$, componenti triangolari inferiori della correlazione) sia, in via definitiva, sul dominio della decomposizione di Cholesky ($\mathbf{x} \in \mathbb{R}^{65703}$, si veda la Sezione 5.4), fittata sul solo *Training Set* senza alcuna standardizzazione preventiva delle feature. Fissata una dimensione target $K \in \{3, 10, 20, 25, 100, 288\}$ per lo spazio compresso, l'algoritmo estrae gli autovettori corrispondenti ai K autovalori dominanti della matrice di covarianza globale del set di addestramento; nel dominio Cholesky, la matrice ricostruita $\hat{\mathbf{L}}$ viene poi riportata al dominio della correlazione tramite $\hat{\mathbf{C}} = \hat{\mathbf{L}}\hat{\mathbf{L}}^T$ seguita da rinormalizzazione, garantendo la PSD per costruzione anche per il modello lineare. Le performance di ricostruzione, misurate tramite l'Errore Quadratico Medio (MSE) sulle matrici del *Test Set*, costituiscono la soglia che i modelli di *deep learning* devono teoricamente eguagliare (nel caso lineare) o superare (nel caso non lineare) — confronto riportato in dettaglio nel Capitolo 7.

6.2 Design e iperparametri dell'Autoencoder Lineare

L'Autoencoder Lineare (Linear AE) è stato progettato per fungere da ponte analitico tra l'apprendimento profondo e l'algebra lineare. Nell'implementazione, Linear AE, Autoencoder Profondo e VAE condividono un'unica classe parametrica (**AutoEncoder/VAE**), in cui la variante lineare si ottiene omettendo gli strati nascosti intermedi. Per garantire la

perfetta replicabilità del sottospazio della PCA, l'architettura è stata sottoposta a vincoli ingegneristici stringenti:

- **Struttura:** Un singolo *layer* denso per l'Encoder ($\mathbb{R}^D \rightarrow \mathbb{R}^K$) e uno speculare per il Decoder ($\mathbb{R}^K \rightarrow \mathbb{R}^D$), con $D = 65703$ nella parametrizzazione Cholesky definitiva ($D = 65341$ nel dominio raw).
- **Funzioni di attivazione:** Rigorosamente identità (lineari) in ogni nodo della rete.
- **Assenza di Bias e Regolarizzazione:** I termini di *bias* sono stati disabilitati in tutti i *layer* ($\mathbf{b} = 0$) e non è stata applicata alcuna penalizzazione di tipo *weight decay* (L2) per non alterare la magnitudo della scomposizione spettrale appresa.

L'ottimizzazione dei pesi è stata condotta minimizzando esclusivamente la funzione di costo spaziale MSE tramite l'ottimizzatore Adam ($\text{lr} = 10^{-3}$, *batch size* 64, fino a 5000 epoche). Come prassi di *sanity check*, gli iperparametri di addestramento sono stati calibrati in modo iterativo per garantire che la *loss* del Linear AE convergesse asintoticamente sull'orizzonte esatto dettato dalla PCA sul set di addestramento a parità di K , validando l'assenza di minimi locali sub-ottimali (si vedano i risultati quantitativi nel Capitolo 7, Tabella 7.1).

6.3 Design e iperparametri dell'Autoencoder Non-Lineare

Per superare la rigidità geometrica dei modelli precedenti e catturare le interdipendenze gerarchiche e asimmetriche del mercato reale, è stato sviluppato un Autoencoder Profondo (AE). L'inclusione di strati multipli e funzioni non lineari dota il modello della flessibilità necessaria per piegare lo spazio latente e fittare la *manifold* complessa dei dati finanziari.

L'architettura è strutturata con un *design* a imbuto (simmetrico), condiviso con il VAE (Sezione 6.4):

- **Encoder:** L'infrastruttura inizia con il *layer* di ingresso ($\mathbb{R}^D$, $D = 65703$ nella parametrizzazione Cholesky), seguito da tre strati nascosti (*hidden layers*) di dimensione decrescente $2048 \rightarrow 1024 \rightarrow 512$, fino al livello di *bottleneck* ($\mathbb{R}^K$). L'architettura prevede la possibilità di interporre un *layer* di *Dropout* tra gli strati dell'Encoder per mitigare il rischio di memorizzazione mnemonica (*co-adaptation*); nelle configurazioni impiegate per i risultati finali (Capitolo 7) tale regolarizzazione si è rivelata non necessaria (probabilità di *dropout* pari a 0), grazie all'omogeneità statistica già garantita dal campionamento casuale del Capitolo 5.
- **Decoder:** Struttura speculare ($512 \rightarrow 1024 \rightarrow 2048 \rightarrow D$) che riceve il vettore latente K -dimensionale e lo proietta nuovamente alla dimensione originale attraverso un'espansione simmetrica.
- **Funzioni di attivazione:** Per tutti gli strati nascosti è stata adottata la funzione di attivazione LeakyReLU (con parametro di pendenza α fissato a 0.01) per scongiurare

il problema del *vanishing gradient* e garantire un flusso di gradiente non nullo anche per valori di input negativi. L'ultimo *layer* di output del Decoder, a differenza di quanto inizialmente previsto in fase di progettazione, non impiega alcuna funzione di attivazione (l'opzione Tanh, valutata per vincolare i valori ricostruiti al dominio $[-1,1]$ coerente con i coefficienti di correlazione di Pearson, è stata infine disattivata in tutte le run utilizzate per i risultati, lasciando che sia il *clipping* finale in fase di ricostruzione della matrice a imporre tale vincolo).

Al fine di prevenire l'*overfitting* e selezionare la configurazione ottimale, il protocollo di addestramento prevede l'esecuzione per un numero prefissato di epoche (tipicamente 1000), monitorando costantemente il *Validation Set* (generato tramite la tecnica del *random shuffle*), con ottimizzatore Adam, *scheduler Cosine Annealing* e *batch size* pari a 64. La strategia di salvataggio dei pesi (*Model Checkpointing*) è impostata per conservare esclusivamente il modello in corrispondenza del valore minimo assoluto della *Validation Loss*.

Grazie all'omogeneità statistica garantita dal campionamento casuale, che annulla il problema del *distribution shift* temporale, il Deep AE dimostra una capacità espressiva eccezionale: la *Training Loss* e la *Validation Loss* risultano stabilmente decrescenti, scendendo al di sotto del limite rigido fissato dal *benchmark* della PCA per medesimi valori di K . Questo successo empirico certifica la capacità della rete di superare i limiti dell'algebra lineare, generalizzando efficacemente sulle dinamiche non lineari del mercato.

Tuttavia, l'eccellente potere ricostruttivo del Deep AE porta alla luce un limite strutturale di diversa natura: l'incapacità generativa. Trattandosi di un modello puramente deterministico, l'Encoder mappa l'input in vettori latenti $\mathbf{z}$ puntuali, creando uno spazio disaggregato e privo di organizzazione probabilistica. Estrapolare nuovi scenari campionando vettori casuali da questo dominio produrrebbe matrici del tutto prive di validità macroeconomica. Tale ostacolo sancisce definitivamente la necessità di transitare verso il paradigma variazionale (VAE), progettato esattamente per superare il determinismo e abilitare la simulazione stocastica.

6.4 Design e iperparametri del VAE

Il Variational Autoencoder (VAE) rappresenta l'apice ingegneristico della pipeline, deputato non solo alla compressione, ma alla generazione stocastica. L'architettura condivide l'*encoder/decoder* a imbuto ($2048 \rightarrow 1024 \rightarrow 512$, LeakyReLU) del Deep AE (Sezione 6.3), espandendone la topologia trasformando lo strato di *bottleneck* deterministico in un modulo di inferenza probabilistica.

- **Rete di Inferenza (Encoder):** Al termine degli strati nascosti, la rete si biforca in due layer paralleli che emettono, rispettivamente, il vettore delle medie $\boldsymbol{\mu}$ e il vettore delle varianze logaritmiche $\log(\boldsymbol{\sigma}^2)$ della distribuzione latente, per garantire la stabilità numerica.
- **Sampling e Reparameterization:** Lo strato latente non riceve un input fisso, ma un campione estratto dinamicamente tramite il *reparameterization trick* $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot$

ϵ , dove $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$; in fase di valutazione (ricostruzione) si utilizza direttamente $\mathbf{z} = \boldsymbol{\mu}$, senza rumore stocastico.

- **Rete Generativa (Decoder):** Il Decoder speculare riceve $\mathbf{z}$ e procede alla ricostruzione, garantendo la PSD della matrice di correlazione tramite la stessa procedura basata su Cholesky descritta per l'Autoencoder Profondo.

Il bilanciamento tra l'errore di ricostruzione e il vincolo topologico imposto dalla Divergenza di Kullback-Leibler (KL) è l'iperparametro critico del sistema, secondo il framework β -VAE $\mathcal{L} = \mathcal{L}_{\text{Recon}} + \beta \mathcal{L}_{\text{KL}}$. Nella pipeline sono state sperimentate due formulazioni della *Reconstruction Loss*: una prima variante basata sul semplice MSE tra i coefficienti (di correlazione o di Cholesky) ricostruiti e originali; e una seconda variante, adottata come definitiva per i risultati del Capitolo 7, basata sulla **Divergenza di Jeffreys** tra le distribuzioni gaussiane $\mathcal{N}(\mathbf{0}, \mathbf{R}_{\text{orig}})$ e $\mathcal{N}(\mathbf{0}, \mathbf{R}_{\text{recon}})$ associate alla matrice di correlazione originale e a quella ricostruita:

$$\mathcal{L}_{\text{Recon}} = \frac{1}{2} \left[\text{Tr}(\mathbf{R}_{\text{recon}}^{-1} \mathbf{R}_{\text{orig}}) + \text{Tr}(\mathbf{R}_{\text{orig}}^{-1} \mathbf{R}_{\text{recon}}) - 2N \right] \quad (6.1)$$

A differenza dell'MSE, questa metrica — calcolata sulla matrice di correlazione ricostruita all'interno del grafo computazionale differenziabile, con un termine di *ridge* $10^{-5} \mathbf{I}$ per la stabilità numerica dell'inversione — pesa esplicitamente l'errore sugli autovalori più piccoli (i portafogli a varianza minima), penalizzando maggiormente gli errori sulla struttura fine dello spettro rispetto a un errore elemento-per-elemento. L'addestramento con questa loss ha richiesto l'introduzione di un *gradient clipping* (norma massima 500) per contenere l'instabilità numerica nelle prime epoche, dovuta all'inversione di matrici di correlazione quasi singolari.

L'addestramento modella uno spazio continuo che permette, in linea di principio, di estrarre nuove matrici sintetiche campionando puramente dalla normale standard $p(\mathbf{z})$ senza necessitare di input originari; la procedura di generazione effettivamente adottata in questa tesi, più articolata, è descritta nel Capitolo 8.

6.5 Metriche di valutazione e criteri di convergenza

L'addestramento dei modelli neurali è stato governato monitorando un set di metriche oggettive e applicando precise policy di ottimizzazione per massimizzare la stabilità dell'apprendimento e la capacità di estrapolazione fuori campionario:

1. **Metriche Spaziali Rigide:** La valutazione quantitativa puntuale si basa sul *Mean Squared Error* (MSE), impiegato direttamente come funzione di costo e indicatore primario. A questo si affiancano il *Mean Absolute Error* (MAE), più resistente agli *outlier*, e la Norma di Frobenius, che quantifica l'energia complessiva residua tra la matrice empirica originale e la sua approssimazione ricostruita o generata.
2. **Metriche Topologiche:** Per verificare che la fedeltà di ricostruzione non sia solo puntuale ma preservi anche la struttura di rete (Capitolo 3), ogni matrice ricostruita

viene confrontata con l'originale attraverso il rispettivo *Minimum Spanning Tree*: percentuale di archi in comune (*edge overlap* e indice di Jaccard), distanza L_1 tra le distribuzioni di grado dei nodi, differenza nella *average path length* (pesata e non) e sovrapposizione dei nodi a più alta *betweenness centrality*.

3. **Ottimizzatore e Learning Rate Policy:** È stato impiegato l'algoritmo di ottimizzazione Adam, rinomato per la gestione dinamica del momento del gradiente. Per facilitare il superamento del limite lineare sul *Training Set* e agevolare la discesa verso il minimo globale, è stato implementato uno *scheduler* per il *Learning Rate* basato sulla tecnica del *Cosine Annealing*. Questa strategia riduce il tasso di apprendimento seguendo il decadimento morbido e continuo della funzione coseno, permettendo esplorazioni ampie nelle fasi iniziali e un'ottimizzazione fine, priva dei bruschi salti tipici degli approcci *step-based*, man mano che la rete si avvicina al *plateau* di convergenza.
4. **Monitoraggio della Convergenza:** La gestione a epoche (*epochs*) tramite *mini-batches* è stata affiancata dall'impiego del *Validation Set* come arbitro indipendente per il *Model Checkpointing*. L'algoritmo valuta l'intero ciclo di epoche prefissato e salva i pesi architetturali esclusivamente in corrispondenza del valore minimo assoluto raggiunto dalla *Validation Loss*. Questo protocollo garantisce che le prestazioni valutate in sede finale sul *Test Set* costituiscano la stima più imparziale e robusta possibile per gli scenari futuri di *asset allocation*.

Parte III

Risultati, Validazione e Applicazioni

Capitolo 7

Analisi della Compressione e Ricostruzione Storica

7.1 Valutazione della PCA e dell'AE Lineare: il benchmark della linearità

La prima fase di validazione empirica ha avuto come obiettivo la misurazione delle capacità di ricostruzione dei modelli puramente lineari. Come descritto nel Capitolo 5, l'input fornito ai modelli non è costituito dalle serie storiche dei rendimenti originali, bensì dai vettori appiattiti $\mathbf{x} \in \mathbb{R}^{65703}$ rappresentanti la decomposizione di Cholesky delle matrici di correlazione mobili (dominio adottato in via definitiva; i risultati nel dominio raw, $\mathbf{x} \in \mathbb{R}^{65341}$, sono riportati a fini di confronto in nota dove rilevante). Di conseguenza, la PCA in questa fase non estrae il classico "fattore di mercato" associato ai titoli (che deriverebbe dall'autodecomposizione dei rendimenti), ma identifica le direzioni di massima varianza nello *spazio delle correlazioni/Cholesky*, tipicamente dominate dalla tendenza sistemica delle correlazioni *pairwise* a variare coralmemente nel tempo (il cosiddetto *breathing effect*, o "respiro" del mercato).

Le misurazioni sul *Training Set* hanno confermato rigorosamente il teorema di Bourlard e Kamp (1988): a parità di dimensione del collo di bottiglia K , l'Autoencoder Lineare (privo di *bias* e funzioni di attivazione) converge asintoticamente al medesimo Errore Quadratico Medio (MSE) della *Principal Component Analysis* (PCA), con uno scarto relativo inferiore al 20% a ogni K testato (Tabella 7.1). Fissato questo limite, la PCA e il Linear AE stabiliscono il *benchmark* assoluto per la pura compressione lineare dello spazio delle correlazioni: qualsiasi architettura profonda proposta deve dimostrare di poter infrangere tale soglia sfruttando la propria espressività topologica.

Tuttavia, l'analisi dell'errore di ricostruzione sul *Test Set* (Figura 7.1) rivela il limite strutturale di questi approcci: a ogni valore di K , sia la PCA sia il Linear AE restano nettamente al di sopra dell'errore dell'Autoencoder Profondo (Sezione 7.2). La rigidità dell'iperpiano di proiezione impedisce ai modelli lineari di adattarsi alle complesse inter-dipendenze non lineari che governano le rotazioni settoriali e le asimmetrie strutturali tra

Metodo	$K = 3$	$K = 10$	$K = 20$	$K = 100$
PCA	3.56×10^{-3}	5.55×10^{-4}	2.73×10^{-4}	7.39×10^{-5}
Linear AE	4.14×10^{-3}	6.72×10^{-4}	3.38×10^{-4}	8.19×10^{-5}
Autoencoder Profondo	1.70×10^{-4}	8.45×10^{-5}	7.19×10^{-5}	7.34×10^{-5}
VAE (Jeffreys, Cholesky)	—	—	1.55×10^{-4}	—

Tabella 7.1. Errore quadratico medio (MSE) di ricostruzione sul *Test Set*, dominio Cholesky, al variare della dimensione latente K . Il VAE è stato valutato solo a $K = 20$ (si veda la nota alla Tabella 7.2).




Figura 7.1. MSE di ricostruzione sul *Test Set* (dominio Cholesky) in funzione della dimensione latente K , per i quattro modelli confrontati (scala logaritmica).

diversi regimi di mercato. La PCA comprime l'informazione in modo algebricamente efficiente, ma restituisce una ricostruzione storicamente "appiattita", faticando a preservare la complessa microstruttura dei veri *stylized facts* finanziari.

7.2 Performance di ricostruzione: AE Non-Lineare e VAE

L'introduzione della non-linearità attraverso l'Autoencoder Profondo (Deep AE) ha prodotto un netto superamento del limite imposto dalla PCA, sia sul *Training Set* sia, cosa più rilevante, sul *Test Set* mai visto durante l'addestramento (Tabella 7.1 e Figura 7.1): a $K = 20$, ad esempio, l'MSE di test dell'AE (7.19×10^{-5}) è di quasi quattro volte inferiore a quello della PCA (2.73×10^{-4}). Questo risultato è reso possibile dall'omogeneizzazione statistica introdotta dal campionamento a mescolamento casuale (Capitolo 5): a differenza di quanto osservato nei test preliminari con partizionamento temporale sequenziale (dove il *distribution shift* tra regimi macroeconomici impediva ai modelli non lineari di generalizzare, portandoli persino a essere superati dalla PCA), nella pipeline definitiva

l'Autoencoder Profondo non mostra segni di *overfitting*: *Training Loss* e *Validation/Test Loss* rimangono stabilmente allineate su tutto l'arco di K testati.

Il passaggio al Variational Autoencoder (VAE) introduce una dinamica prestazionale più sfumata di quanto una prima intuizione potrebbe suggerire, e dipende in modo cruciale dal dominio di rappresentazione della matrice (Sezione 6.4). Nel dominio raw (correlazione grezza), il VAE registra un incremento marcato dell'errore di ricostruzione rispetto a tutti gli altri modelli, PCA e Linear AE inclusi (a $K = 20$ sul *Test Set*, MSE pari a 6.33×10^{-3} contro 1.78×10^{-4} di PCA e Linear AE). Tuttavia, nel dominio Cholesky — quello adottato in via definitiva per la parametrizzazione PSD-aware (Capitolo 4) — il quadro si inverte parzialmente: il VAE (variante con loss basata sulla Divergenza di Jeffreys, Sezione 6.4) ottiene a $K = 20$ un MSE di test pari a 1.55×10^{-4} , **inferiore** sia a quello della PCA (2.73×10^{-4}) sia a quello del Linear AE (3.38×10^{-4}), pur restando superiore a quello dell'Autoencoder Profondo deterministico (7.19×10^{-5}).

Metrica MST ($K = 20$, Test)	PCA	Linear AE	AE	VAE
<i>Edge overlap</i> (%)	83.0	83.1	91.1	88.4
<i>Edge Jaccard</i> (%)	71.2	71.4	84.0	79.4
Distanza L_1 distribuzione di grado	0.081	0.084	0.068	0.076
<i>Betweenness top-10 overlap</i> (%)	71.7	68.6	80.2	77.9

Tabella 7.2. Metriche topologiche di similarità del Minimum Spanning Tree tra matrice originale e ricostruita, dominio Cholesky, $K = 20$, *Test Set*. Il VAE non è mai stato confrontato a $K = 3$ o $K = 100$: si vedano le Osservazioni a fine sezione.




Figura 7.2. Percentuale di archi in comune tra l'MST della matrice originale e quello della matrice ricostruita, dominio Cholesky, *Test Set*, in funzione di K .

Le metriche topologiche basate sul Minimum Spanning Tree (Tabella 7.2 e Figura 7.2) confermano lo stesso ordinamento: l'Autoencoder Profondo preserva la topologia di rete meglio di tutti gli altri modelli a ogni K ; il VAE si colloca sistematicamente in posizione

intermedia, superando nettamente PCA e Linear AE pur non raggiungendo la fedeltà topologica dell'AE deterministico.

Questo comportamento — l'inversione dell'ordinamento tra dominio raw e dominio Cholesky — non è un artefatto casuale, ma la diretta conseguenza della diversa natura della *Reconstruction Loss* impiegata: nel dominio Cholesky la loss basata sulla Divergenza di Jeffreys (Sezione 6.4) pesa esplicitamente l'errore sulla struttura spettrale della matrice di correlazione ricostruita, anziché limitarsi a un errore elemento-per-elemento sui coefficienti grezzi del fattore di Cholesky; questa parametrizzazione più informativa, unita alla garanzia strutturale di PSD, riduce significativamente il costo che il vincolo di regolarizzazione D_{KL} impone alla fedeltà di ricostruzione.

Osservazione 2 *Il confronto a $K = 20$ presentato in questa sezione è l'unico punto in cui tutti e quattro i modelli sono stati valutati sullo stesso Test Set con la stessa metodologia. Il VAE non è stato sistematicamente confrontato a $K = 3$ o $K = 100$; inoltre l'errore di ricostruzione del VAE, a differenza degli altri tre modelli, non decresce monotonicamente con K (MSE sul Training Set: 6.33×10^{-5} a $K = 10$, 8.69×10^{-5} a $K = 20$, 1.16×10^{-4} a $K = 30$) — un andamento anomalo, verosimilmente legato alla competizione tra ricostruzione e regolarizzazione KL e al fatto che le run confrontate a $K = 10, 20, 30$ non condividono esattamente gli stessi iperparametri di addestramento (non è quindi un ablation study controllato sul solo K).*

7.3 Il trade-off tra compressione esatta e flessibilità generativa

I risultati finora descritti delineano il compromesso fondamentale che giustifica l'adozione delle architetture variazionali in finanza quantitativa. Non si tratta, come i risultati del dominio Cholesky dimostrano, di una dicotomia netta tra "il VAE ricostruisce peggio di tutto" e "il VAE genera scenari realistici": il VAE resta competitivo, e anzi superiore, ai *benchmark* lineari anche in pura ricostruzione. Il compromesso reale è più circoscritto, e riguarda specificamente il confronto tra Autoencoder Profondo deterministico e VAE.

L'Autoencoder Profondo deterministico massimizza l'efficacia della compressione storica (Sezione 7.2), ma fallisce totalmente qualora lo si voglia utilizzare come motore di simulazione. Poiché lo spazio latente di un AE classico non è governato da alcuna restrizione probabilistica, i vettori $\mathbf{z}$ si dispongono in modo disaggregato e frammentario, creando vaste regioni di vuoto geometrico (Capitolo 4, §4.3). Tentare di generare nuovi scenari campionando un vettore casuale da tale spazio e proiettandolo attraverso il *Decoder* produce output privi di coerenza economico-finanziaria. L'AE deterministico è quindi confinato alla pura memorizzazione di un passato statico, per quanto accurata.

Il VAE, pur restando lievemente meno accurato dell'AE nella pura ricostruzione (Tabella 7.1), paga questo scarto — contenuto, e non catastrofico come inizialmente ipotizzato — in cambio dell'unica proprietà che rende possibile la generazione stocastica: un vincolo di regolarizzazione (D_{KL}) che modella uno spazio latente continuo, denso e privo di singolarità, in cui è possibile campionare in modo significativo (Capitolo 4, §4.4). È proprio questa capacità generativa, resa possibile senza rinunciare in modo sostanziale alla fedeltà

di ricostruzione, a motivare la scelta del VAE come modello finale per la generazione di scenari sintetici affrontata nel Capitolo 8, dove la procedura di campionamento effettivamente adottata (un *block-bootstrap* storico nello spazio latente) e la validazione delle matrici generate sui cinque fatti stilizzati del Capitolo 3 vengono presentate in dettaglio.

Capitolo 8

Generazione Stocastica di Nuovi Scenari (Validazione del VAE)

8.1 Campionamento dallo spazio latente: dal prior al block-bootstrap storico

Come discusso nel Capitolo 4 (§4.4), la regolarizzazione imposta dalla Divergenza di Kullback-Leibler rende in linea di principio possibile generare nuove matrici di correlazione campionando direttamente un vettore casuale $\mathbf{z}_{\text{sim}} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ dal *prior* e decodificandolo. Tuttavia, l'obiettivo di questo lavoro non è produrre uno scenario plausibile qualsiasi, bensì **prevedere la struttura di correlazione a un orizzonte di un mese** a partire dallo stato di mercato osservato oggi (Capitolo 2, §2.1). Per questo motivo, la procedura di generazione effettivamente adottata sostituisce il semplice campionamento dal *prior* con una tecnica di **block-bootstrap storico nello spazio latente**, che ancora la generazione stocastica alla dinamica recente del mercato pur sfruttando la medesima regolarità topologica dello spazio latente descritta nel Capitolo 4.

La procedura, applicata al modello VAE a 20 dimensioni latenti nel dominio Cholesky con loss di Jeffreys (VAE_20dim_cholesky_06_loss, lo stesso modello impiegato per il confronto del Capitolo 7), si articola nei seguenti passaggi:

1. **Ricostruzione della traiettoria latente storica.** L'encoder del VAE già addestrato viene applicato all'intera serie storica delle matrici di correlazione calcolate con passo giornaliero (stride = 1, a differenza dello stride di 10 giorni usato per l'addestramento, si veda il Capitolo 5), producendo una traiettoria latente continua $\{\mathbf{z}_t\}_{t=1}^T$ con $T = 4124$ osservazioni giornaliere.
2. **Calcolo degli incrementi giornalieri.** Si calcola la sequenza degli incrementi $\Delta \mathbf{z}_t = \mathbf{z}_t - \mathbf{z}_{t-1}$, che rappresenta la variazione giorno-su-giorno osservata nello spazio latente durante l'intero periodo storico.

3. **Campionamento a blocchi.** Per generare ciascuno scenario sintetico, si estrae casualmente un blocco di 21 incrementi giornalieri consecutivi (corrispondenti a un mese lavorativo) dalla sequenza storica $\{\Delta \mathbf{z}_t\}$ e se ne calcola la somma cumulata $\delta \mathbf{z}$.
4. **Proiezione a un mese.** Il salto latente campionato viene sommato allo stato attuale $\mathbf{z}_{\text{oggi}}$ (l'ultima osservazione della traiettoria storica), ottenendo lo stato latente previsto $\mathbf{z}_{\text{futuro}} = \mathbf{z}_{\text{oggi}} + \delta \mathbf{z}$.
5. **Decodifica e ricostruzione PSD.** Il Decoder produce il fattore di Cholesky corrispondente a $\mathbf{z}_{\text{futuro}}$, da cui si ricostruisce la matrice di correlazione sintetica tramite $\mathbf{C} = \mathbf{L}\mathbf{L}^T$ e normalizzazione, garantendone la semidefinita positività per costruzione (Capitolo 4, §4.4).

Ripetendo il campionamento a blocchi un numero N di volte (in questo lavoro, $N = 100$ e $N = 1000$), si ottiene un insieme di scenari sintetici a un mese di distanza, ciascuno ancorato allo stesso stato di partenza $\mathbf{z}_{\text{oggi}}$ ma diversificato dalla variabilità storica campionata a blocchi.




Figura 8.1. Illustrazione della procedura di block-bootstrap per uno scenario sintetico (*Scenario 63* tra i 1000 generati): in alto, la composizione del salto latente cumulato sulle 20 dimensioni; in basso, il confronto tra lo stato attuale $\mathbf{z}_{\text{oggi}}$ e lo stato previsto a un mese $\mathbf{z}_{\text{futuro}}$.

La Figura 8.1 illustra la composizione del salto latente per uno degli scenari generati: si osserva come solo alcune dimensioni latenti (tipicamente 2–4 su 20) contribuiscano in modo sostanziale allo spostamento complessivo, mentre le restanti rimangono pressoché

invariate rispetto allo stato attuale — un comportamento coerente con la struttura dello spazio latente appreso dal VAE, in cui poche direzioni concentrano la maggior parte della variabilità informativa del mercato.

8.2 Verifica dei cinque fatti stilizzati sulle matrici generate

Per validare la plausibilità economico-finanziaria delle matrici sintetiche prodotte, ciascuno scenario generato viene confrontato con la matrice di correlazione osservata oggi sulla base dei cinque fatti stilizzati introdotti nel Capitolo 3. Lo scenario qui presentato in dettaglio (*Scenario 63*, tra i 1000 generati dal modello `VAE_20dim_cholesky_06_loss`) è stato scelto perché si colloca al 95° percentile lungo il primo asse principale della nuvola di scenari generati (che spiega il 23.4% della varianza totale, Figura 8.2): non è quindi uno scenario arbitrario o "comodo", ma uno scenario di coda, rappresentativo di una plausibile evoluzione di mercato relativamente pronunciata rispetto allo stato attuale.




Figura 8.2. Analisi statistica della nuvola di 1000 scenari generati: distribuzione delle distanze di Mahalanobis dal centroide (sinistra) e proiezione sul primo asse principale (destra). Lo Scenario 63, oggetto dell'analisi di dettaglio, si colloca al 95° percentile lungo il primo asse.

Distribuzione pairwise. La distribuzione dei coefficienti di correlazione dello scenario sintetico (Figura 8.3) mantiene lo spostamento verso valori positivi osservato nel mercato reale: media 0.4635 e mediana 0.4711 per lo scenario generato, contro 0.4512 e 0.4593 della matrice odierna — coerenti, per ordine di grandezza, con quanto verificato sulla matrice di esempio analizzata nel Capitolo 3.

Spettro e distribuzione di Marchenko-Pastur. Lo spettro della matrice generata (Figura 8.4) preserva la struttura a tre componenti descritta nel Capitolo 3: l'autovalore di mercato rimane dominante e di ordine di grandezza confrontabile (169.1 per la matrice




Figura 8.3. Confronto tra la distribuzione dei coefficienti *pairwise* della matrice odierna (sinistra) e della matrice sintetica a un mese (destra).

odierna, 173.2 per lo scenario generato), e lo stesso numero di autovalori settoriali (nove) supera il limite superiore teorico di Marchenko-Pastur in entrambe le matrici.




Figura 8.4. Spettro degli autovalori della matrice odierna (in alto) e della matrice sintetica (in basso) confrontato con la distribuzione teorica di Marchenko-Pastur.

Proprietà di Perron-Frobenius. Il primo autovettore (*market mode*) della matrice sintetica presenta componenti tutte dello stesso segno, in accordo con la proprietà di

Perron-Frobenius, con una similarità coseno rispetto all'autovettore della matrice odierna pari a 0.9999 (Figura 8.5); anche il secondo e il terzo autovettore (*sector mode*) risultano preservati con similarità coseno rispettivamente di 0.9893 e 0.9883.




Figura 8.5. Confronto dei primi tre autovettori tra matrice odierna e matrice sintetica: le componenti del *market mode* (in alto) sono tutte dello stesso segno in entrambe le matrici.

Struttura gerarchica. Il dendrogramma ottenuto per clustering gerarchico sulla matrice sintetica (Figura 8.6) riproduce visivamente un'organizzazione a blocchi molto simile a quella della matrice odierna, con gli stessi principali raggruppamenti settoriali riconoscibili nella struttura ad albero.

Topologia scale-free del MST. L'esponente della legge di potenza stimato sulla distribuzione di grado del Minimum Spanning Tree (Figura 8.7) risulta $\gamma_{oggi} = -2.119$ per la matrice odierna e $\gamma_{futuro} = -2.227$ per lo scenario sintetico: entrambi i valori confermano la natura *scale-free* della topologia di rete, con un grado massimo di 15 e 14 connessioni rispettivamente.




Figura 8.6. Dendrogrammi comparativi per la matrice odierna (in alto) e la matrice sintetica a un mese (in basso).




Figura 8.7. Distribuzione di grado del Minimum Spanning Tree in scala log-log, matrice odierna vs matrice sintetica a un mese.

8.3 Limiti della validazione e sviluppi futuri

Osservazione 3 La verifica presentata in questa sezione, pur non avendo evidenziato alcuna violazione dei cinque fatti stilizzati, è condotta **su un singolo scenario per volta** scelto tra i 1000 generati, e non in forma aggregata sull'intero insieme. Una validazione statisticamente più esaustiva richiederebbe di ripetere l'analisi (o quantomeno le

metriche riassuntive: percentuale di scenari con proprietà di Perron-Frobenius soddisfatta, distribuzione dell'esponente γ , istogramma pooled delle correlazioni pairwise) sull'intero insieme di scenari generati, anziché su un singolo campione rappresentativo. Questo approfondimento è lasciato come sviluppo naturale del presente lavoro.

Le matrici sintetiche generate in questo capitolo, avendo superato la verifica qualitativa sui cinque fatti stilizzati, costituiscono un insieme di scenari plausibili pronti per essere utilizzati come input di un motore di simulazione Monte Carlo per l'*asset allocation* e la gestione del rischio di portafoglio (ad esempio per la stima del Value at Risk o dell'Expected Shortfall, sul modello di [Caprioli et al. \[2024\]](#)) — applicazione che, per scelta di perimetro, non è stata affrontata in questo lavoro e viene proposta tra gli sviluppi futuri nelle Conclusioni.

Capitolo 9

Conclusioni e Sviluppi Futuri

9.1 Sintesi dei risultati ottenuti

Il presente lavoro di tesi ha progettato, implementato e validato un framework basato su architetture neurali profonde per la compressione, la ricostruzione e la generazione stocastica di matrici di correlazione finanziarie realistiche, applicato a un paniere di $N = 362$ titoli dell'indice S&P 500 osservati lungo un orizzonte ventennale (2000-2020, Capitolo 5).

Il percorso metodologico ha seguito un'evoluzione incrementale, motivata empiricamente passo dopo passo. Il primo tentativo di ricostruzione, condotto direttamente nel dominio della matrice di correlazione grezza, ha evidenziato che le matrici ricostruite non rispettavano in modo affidabile il vincolo di semidefinita positività (PSD): un limite non accettabile per una matrice di correlazione, che ha motivato il passaggio, adottato in via definitiva, alla ricostruzione della decomposizione di Cholesky (Capitoli 4 e 6), garantendo la PSD per costruzione matematica indipendentemente dalla qualità dell'apprendimento.

Sul piano della pura ricostruzione storica (Capitolo 7), i risultati confermano rigorosamente il teorema di Bourlard e Kamp: PCA e Autoencoder Lineare convergono, a parità di dimensione latente K , verso lo stesso limite di errore, stabilendo il *benchmark* lineare. L'Autoencoder Profondo, grazie alla non-linearità e all'omogeneizzazione statistica ottenuta con il campionamento a mescolamento casuale (Capitolo 5), supera nettamente tale limite a ogni K , senza mostrare segni di *overfitting*. Il Variational Autoencoder, nella parametrizzazione Cholesky con loss basata sulla Divergenza di Jeffreys (modello `VAE_20dim_cholesky_06_loss`, adottato come riferimento definitivo in questo lavoro), si colloca in una posizione intermedia: pur restando meno accurato dell'Autoencoder Profondo deterministico, supera sia la PCA sia l'Autoencoder Lineare a $K = 20$ — un risultato che ridimensiona, rispetto alle aspettative iniziali, il costo in termini di fedeltà di ricostruzione imposto dalla regolarizzazione variazionale.

È tuttavia sul fronte generativo che il VAE dimostra il proprio valore distintivo (Capitolo 8). Sfruttando la continuità e la densità dello spazio latente indotte dalla Divergenza di Kullback-Leibler, è stato possibile costruire una procedura di generazione — un *block-bootstrap* storico degli incrementi latenti giornalieri — capace di proiettare la struttura di correlazione a un orizzonte di un mese a partire dallo stato di mercato osservato oggi.

Le matrici sintetiche così generate, verificate rispetto ai cinque fatti stilizzati delle matrici di correlazione finanziarie (Capitolo 3), non mostrano violazioni: la distribuzione dei coefficienti *pairwise* resta spostata verso valori positivi, lo spettro degli autovalori mantiene la stessa ripartizione tra effetto mercato, effetti settoriali e rumore, la proprietà di Perron-Frobenius è preservata con similarità coseno superiore a 0.98 su tutti i modi principali, e sia la struttura gerarchica sia la topologia *scale-free* del Minimum Spanning Tree risultano qualitativamente conservate. Un Autoencoder Profondo puramente deterministico, per quanto superiore nella ricostruzione storica, non possiede alcuna delle proprietà topologiche dello spazio latente necessarie per svolgere lo stesso compito: è questa complementarità — l’AE per ricordare, il VAE per immaginare — la sintesi più efficace dei risultati ottenuti.

9.2 Impatto nel campo del Risk Management quantitativo

Il problema affrontato in questa tesi — la necessità di superare la limitatezza campionaria delle serie storiche per stimare il rischio di portafoglio (Capitolo 2) — è centrale nella pratica quantitativa. I risultati ottenuti mostrano che un motore generativo basato su VAE, se correttamente parametrizzato tramite la decomposizione di Cholesky, può produrre scenari di correlazione sintetici che sono al tempo stesso matematicamente validi (PSD per costruzione) e statisticamente plausibili (aderenti ai fatti stilizzati del mercato reale), ancorati inoltre allo stato di mercato corrente tramite la procedura di *block-bootstrap* latente.

Un lavoro concettualmente affine, condotto da Caprioli et al. [2024] nel contesto del rischio di portafogli crediti, dimostra come scenari di questo tipo possano essere impiegati per stimare distribuzioni di rischio di portafoglio (Value at Risk ed Expected Shortfall) senza ricorrere a costose simulazioni Monte Carlo ripetute, tramite ricampionamento diretto delle coordinate dello spazio latente appreso — un’operazione metodologicamente affine al *block-bootstrap* qui sviluppato. Il presente lavoro non si è spinto fino a questa applicazione finale (si veda la Sezione 9.4), ma fornisce la componente generativa — validata sui fatti stilizzati — che ne costituirebbe il presupposto necessario.

9.3 Limiti del modello attuale

Diversi limiti metodologici, emersi nel corso del lavoro, meritano di essere dichiarati esplicitamente.

In primo luogo, la validazione dei cinque fatti stilizzati sulle matrici generate (Capitolo 8) è stata condotta su singoli scenari selezionati tra quelli generati, non in forma aggregata sull’intero insieme di 1000 scenari sintetici. Sebbene lo scenario esaminato in dettaglio sia stato scelto deliberatamente tra i più estremi della distribuzione (95° percentile lungo l’asse principale di variazione), una validazione statistica sull’intero insieme — ad esempio la percentuale di scenari che soddisfano la proprietà di Perron-Frobenius,

o la distribuzione dell'esponente di scala γ del Minimum Spanning Tree — fornirebbe un'evidenza più rigorosa e resta un'estensione naturale non ancora implementata.

In secondo luogo, la strategia di campionamento a mescolamento casuale (Capitolo 5), pur risolvendo efficacemente il problema del *distribution shift* di regime macroeconomico tra *Training*, *Validation* e *Test Set*, non elimina la sovrapposizione informativa tra finestre di correlazione adiacenti (fino al 98.6% di osservazioni condivise tra finestre a indice quasi consecutivo). L'assenza di un vincolo di distanza minima tra gli indici assegnati a split diversi rappresenta un potenziale, per quanto limitato, rischio di ottimismo nelle metriche di generalizzazione riportate.

In terzo luogo, le prestazioni relative dei modelli si sono dimostrate sensibili al dominio di rappresentazione della matrice: nel dominio raw il VAE risulta nettamente inferiore anche ai *benchmark* lineari, mentre nel dominio Cholesky li supera (Capitolo 7). Il confronto tra modelli, inoltre, non copre in modo sistematico e uniforme tutte le dimensioni latenti K per il VAE (mai testato a $K = 3$ o $K = 100$), e l'errore di ricostruzione del VAE non decresce monotonicamente con K come invece accade per gli altri tre modelli — un comportamento che meriterebbe un'indagine più sistematica, a parità di iperparametri di addestramento, per essere pienamente compreso.

Infine, la classificazione settoriale GICS impiegata per le analisi di struttura gerarchica (Capitolo 3) è stata ottenuta tramite classificazione automatica affidata a un modello linguistico di grandi dimensioni, in assenza di un provider dati strutturato, e non è stata sottoposta a validazione incrociata con fonti ufficiali.

9.4 Sviluppi futuri

Il naturale proseguimento di questo lavoro è l'applicazione pratica delle matrici sintetiche generate e validate al calcolo del rischio di portafoglio: utilizzando gli scenari prodotti dal *block-bootstrap* latente come input di un motore di simulazione Monte Carlo, sarebbe possibile stimare il Value at Risk (VaR) e l'Expected Shortfall su portafogli reali, confrontando la stima ottenuta con gli scenari arricchiti dal VAE rispetto a quella basata sui soli dati storici tradizionali — sul modello proposto da Caprioli et al. [2024]. Questa applicazione, inizialmente prevista nel perimetro della tesi, non è stata infine sviluppata ed è qui proposta come prosecuzione prioritaria del lavoro.

Un secondo filone di sviluppo riguarda il rafforzamento della validazione statistica delle matrici generate, estendendo l'analisi dei cinque fatti stilizzati dal singolo scenario rappresentativo all'intero insieme di scenari prodotti, con metriche aggregate di conformità.

Un terzo filone riguarda il confronto diretto con paradigmi generativi alternativi basati su reti avversarie (GAN), quali CorrGAN [Marti, 2019] o i Quant GANs [Wiese et al., 2019], per quantificare in modo sistematico i vantaggi e gli svantaggi del VAE (stabilità di addestramento, interpretabilità dello spazio latente) rispetto all'approccio avversariale in questo specifico dominio applicativo. Più in generale, l'integrazione di modelli di diffusione, oggi allo stato dell'arte per la generazione condizionata in molti domini, rappresenta un'ulteriore direzione di ricerca promettente.

Infine, l'estensione della pipeline ad altre asset class (reddito fisso, valute, materie prime) e a panieri di titoli internazionali permetterebbe di verificare la generalità del framework proposto al di là del mercato azionario statunitense qui analizzato, così come l'introduzione di una procedura di *purging* esplicito tra i sottoinsiemi di addestramento, validazione e test irrobustirebbe ulteriormente la stima delle capacità di generalizzazione dei modelli.

Bibliografia

- Jean-Philippe Bouchaud and Marc Potters. Financial applications of random matrix theory: a short review, 2009. URL <https://arxiv.org/abs/0910.1205>. Citato a pag. [11](#), [16](#), [22](#)
- Sergio Caprioli, Emanuele Cagliero, and Riccardo Crupi. Quantifying credit portfolio sensitivity to asset correlations with interpretable generative neural networks. *Journal of Risk Model Validation*, 18(1), 2024. doi: 10.21314/JRMV.2024.002. Citato a pag. [12](#), [17](#), [36](#), [67](#), [70](#), [71](#)
- Rama Cont. Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2):223–236, 2001. Citato a pag. [19](#)
- Carl Doersch. Tutorial on variational autoencoders, 2016. URL <https://arxiv.org/abs/1606.05908>. v3, revised January 3, 2021. Citato a pag. [35](#)
- Ian Goodfellow. NIPS 2016 tutorial: Generative adversarial networks, 2016. URL <https://arxiv.org/abs/1701.00160>. Citato a pag. [35](#)
- Amelie Hüttner and Jan-Frederik Mai. Simulating realistic correlation matrices for financial applications: correlation matrices with the Perron–Frobenius property. *Journal of Statistical Computation and Simulation*, 89(2):315–336, 2019. doi: 10.1080/00949655.2018.1546861. URL <https://doi.org/10.1080/00949655.2018.1546861>. Citato a pag. [23](#)
- Ian T. Jolliffe and Jorge Cadima. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065):20150202, 2016. doi: 10.1098/rsta.2015.0202. Citato a pag. [33](#)
- Bryan T. Kelly, Seth Pruitt, and Yinan Su. Characteristics are covariances: A unified model of risk and return. *Journal of Financial Economics*, 134:501–524, 2019. doi: 10.1016/j.jfineco.2019.05.001. Citato a pag. [34](#)
- Rosario N. Mantegna. Hierarchical structure in financial markets. 1998. Citato a pag. [25](#)
- Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952. doi: 10.2307/2975974. Citato a pag. [15](#)

- Gautier Marti. Corrgan: Sampling realistic financial correlation matrices using generative adversarial networks. *arXiv preprint arXiv:1910.09504*, 2019. Citato a pag. [12](#), [19](#), [35](#), [71](#)
- Elad Plaut. From principal subspaces to principal components with linear autoencoders, 2018. *arXiv:1804.10253v3*. Citato a pag. [34](#)
- Vasiliki Plerou, Parameswaran Gopikrishnan, Bernd Rosenow, Luís A. Nunes Amaral, and H. Eugene Stanley. Universal and non-universal properties of cross-correlations in financial time series. *Physical Review Letters*, 83(7):1471–1474, 1999. doi: 10.1103/PhysRevLett.83.1471. Citato a pag. [16](#), [22](#)
- Vasiliki Plerou, Parameswaran Gopikrishnan, Bernd Rosenow, Luís A. Nunes Amaral, Thomas Guhr, and H. Eugene Stanley. A random matrix approach to cross-correlations in financial data. *Physical Review E*, 65:066126, 2002. doi: 10.1103/PhysRevE.65.066126. Citato a pag. [11](#), [16](#), [22](#)
- Magnus Wiese, Robert Knobloch, Ralf Korn, and Peter Kretschmer. Quant GANs: Deep generation of financial time series, 2019. *arXiv:1907.06673v2*. Citato a pag. [35](#), [71](#)