

POLITECNICO DI TORINO

Corso di Laurea Magistrale in Ingegneria Informatica

Orientamento Artificial Intelligence and Data Analytics

Tesi di Laurea Magistrale

Dai pixel ai portafogli finanziari: generare scenari di mercato realistici tramite variational autoencoder



Relatori

prof. Flavio Giobergia

prof. Sergio Caprioli

firma dei relatori

.....
.....

Candidato

Dylan Magliano

firma del candidato

.....

Anno Accademico 2025-2026

A mio padre

† A mio nonno Pino

Sommario

Il presente lavoro di tesi si inserisce nel contesto della finanza quantitativa e del *risk management*, affrontando le limitazioni dei modelli deterministici nella stima delle matrici di correlazione empiriche, tipicamente affette da rumore statistico e limiti di campionamento storico. Si propone un framework basato sul *deep learning* per la compressione, ricostruzione e generazione stocastica di scenari di mercato realistici.

La metodologia si basa sull'analisi dei rendimenti giornalieri di un campione rappresentativo di 100 titoli dell'indice S&P 500 nell'orizzonte temporale 2000-2020, selezionati per preservare l'eterogeneità settoriale del mercato. A partire dalle matrici di correlazione empiriche opportunamente pre-processate, viene condotto uno studio comparativo sistematico tra Principal Component Analysis (PCA), Autoencoder Lineari (Linear AE), Autoencoder Profondi non lineari (AE) e Variational Autoencoder (VAE). Ciascun modello viene valutato sia sotto il profilo quantitativo — attraverso metriche di errore quali *Mean Squared Error* (MSE), *Mean Absolute Error* (MAE), la norma di Frobenius e l'analisi comparativa del *Minimum Spanning Tree* (MST) generato — sia sotto il profilo qualitativo mediante algoritmi di *clustering* gerarchico per verificare la conservazione delle aggregazioni settoriali naturali del mercato. I risultati empirici evidenziano come, nel dominio della pura ricostruzione storica, gli approcci lineari offrano prestazioni dominanti a causa della natura intrinseca del dataset finanziario.

Per superare i limiti dei modelli deterministici e abilitare la generazione stocastica, il VAE viene impiegato per campionare nuove matrici di correlazione sintetiche dallo spazio latente regolarizzato. Queste nuove configurazioni vengono sottoposte al medesimo protocollo di validazione qualitativa e quantitativa, oltre a una verifica rigorosa rispetto a cinque *stylized facts* fondamentali: distribuzione asimmetrica verso valori positivi delle correlazioni *pairwise*, aderenza dello spettro degli autovalori alla distribuzione di Marchenko-Pastur, validità della proprietà di Perron-Frobenius, conservazione della struttura gerarchica e topologia *scale-free* dell'MST. Il confronto con matrici casuali tramite la *Random Matrix Theory* (RMT) conferma la capacità del VAE di preservare tali proprietà strutturali dei mercati reali.

Infine, le matrici sintetiche generate e validate vengono impiegate all'interno di un motore di simulazione Monte Carlo per la stima del Value at Risk (VaR) e dell'Expected Shortfall (ES) su portafogli reali. L'architettura proposta dimostra come l'intersezione tra modelli generativi profondi e stilizzazioni empiriche consenta di catturare i rischi di coda in modo significativamente più robusto rispetto ai metodi storici convenzionali.

Indice

I	Fondamenti Teorici	7
1	Introduzione	9
1.1	Contesto generale sull'asset allocation e la gestione del rischio	9
1.2	Definizione del problema di ricerca e motivazione dell'uso dei modelli generativi profondi	10
1.3	Obiettivi della tesi	11
2	Matrici di Correlazione in Ambito Finanziario	13
2.1	Ruolo della correlazione nella Modern Portfolio Theory (Markowitz)	13
2.2	Il problema del rumore nelle matrici empiriche	14
2.3	Utilizzo delle matrici per la generazione di scenari stocastici e stima del rischio (VaR)	15
3	Fatti Stilizzati delle Matrici di Correlazione	17
3.1	Introduzione alle proprietà strutturali dei mercati reali	17
3.2	Distribuzione asimmetrica delle correlazioni pairwise	18
3.3	Analisi spettrale e distribuzione di Marchenko-Pastur	18
3.4	Proprietà di Perron-Frobenius empirica	19
3.5	Struttura gerarchica delle correlazioni	20
3.6	Il Minimum Spanning Tree (MST) e la proprietà scale-free	20
3.7	Benchmark test: fallimento strutturale della Random Matrix Theory . . .	21
II	Metodologia e Pipeline di Analisi	23
III	Risultati, Validazione e Applicazioni	25

Parte I

Fondamenti Teorici

Capitolo 1

Introduzione

1.1 Contesto generale sull'asset allocation e la gestione del rischio

L'ottimizzazione del portafoglio e la gestione del rischio rappresentano due dei pilastri fondamentali della finanza quantitativa moderna. A partire dal lavoro pionieristico di Harry Markowitz del 1952 sulla *Modern Portfolio Theory* (MPT), il problema dell'allocation ottimale delle risorse è stato formalizzato come un problema di ottimizzazione vincolata a due obiettivi contrapposti: la massimizzazione del rendimento atteso e la contestuale minimizzazione della varianza del portafoglio. In questo paradigma economico, la matrice di covarianza e, in modo equivalente, la matrice di correlazione tra i rendimenti delle diverse attività finanziarie giocano un ruolo matematico centrale, agendo come l'operatore lineare che quantifica il rischio sistematico e i benefici della diversificazione.

Parallelamente, l'evoluzione dei mercati globali e l'introduzione di framework normativi sempre più stringenti hanno spinto l'industria finanziaria verso l'adozione di metriche di rischio più sofisticate della semplice varianza. Tra queste, il *Value at Risk* (VaR) e l'*Expected Shortfall* (ES) sono diventati gli standard *de facto* per la quantificazione delle perdite potenziali in condizioni di mercato avverse entro un determinato orizzonte temporale e livello di confidenza.

La stima accurata di tali metriche di rischio di coda si affida ampiamente a metodologie di simulazione, tra cui spiccano le simulazioni Monte Carlo. L'efficacia e l'affidabilità di questi motori di simulazione dipendono in maniera critica dalla qualità e dal realismo degli scenari di mercato generati. Se i modelli matematici sottostanti non riescono a catturare fedelmente le interdipendenze e la struttura correlativa degli asset finanziari, le stime del rischio risultano inevitabilmente distorte, conducendo a decisioni di *asset allocation* sub-ottimali e a una potenziale sottostima delle minacce sistemiche.

1.2 Definizione del problema di ricerca e motivazione dell'uso dei modelli generativi profondi

Il principale ostacolo nell'applicazione pratica dei modelli classici risiede nella natura intrinseca delle matrici di correlazione empiriche. Quando stimata a partire da serie storiche campionarie di rendimenti, la matrice di correlazione soffre in modo significativo del problema del rumore statistico e della non-stazionarietà dei mercati. Quando il numero di asset analizzati (N) è dello stesso ordine di grandezza della lunghezza della serie storica (T), la matrice empirica diventa instabile, introducendo autovalori spuri che degradano le performance degli algoritmi di ottimizzazione, un fenomeno ampiamente studiato nell'ambito della *Random Matrix Theory* (RMT).

Nel presente lavoro, l'analisi si concentra sui rendimenti giornalieri dei titoli componenti l'indice S&P 500 estratti lungo un ampio orizzonte temporale ventennale, compreso tra il 2000 e il 2020. Per mitigare la complessità computazionale e l'instabilità numerica associate alla dimensionalità dell'intero indice, mantenendo al contempo una fedele rappresentazione macroeconomica, la ricerca isola un paniere target di 100 asset. Al fine di evitare distorsioni e preservare la struttura intrinseca del mercato, la selezione viene eseguita tramite un algoritmo di campionamento stratificato, il quale garantisce il rispetto delle percentuali originali dei settori definiti dal *Global Industry Classification Standard* (GICS).

I metodi tradizionali per gestire il rumore in tali matrici (come lo *shrinkage* o il *bootstrapping* storico) presentano forti limiti: tendono a linearizzare le relazioni eliminando anomalie informative o rimangono vincolati alla limitatezza storica, impedendo l'esplorazione di scenari estremi mai osservati precedentemente ma statisticamente plausibili. In questo panorama, i modelli generativi profondi (*Deep Generative Models*) offrono un cambio di paradigma radicale. Architetture basate sui *Variational Autoencoders* (VAE) consentono di mappare lo spazio ad alta dimensionalità delle matrici di correlazione empiriche in uno spazio latente continuo e regolarizzato.

Per ottimizzare l'efficienza computazionale ed eliminare le ridondanze geometriche dovute alla simmetria intrinseca e alla diagonale unitaria, l'input dei modelli viene ridotto alla sola componente triangolare inferiore linearizzata delle matrici estratte dal sottoinsieme stratificato. Attraverso questo vincolo rappresentazionale, i modelli apprendono a comprimere e successivamente riprodurre l'intera struttura informativa.

Al fine di mappare con rigore scientifico le capacità di questi strumenti, il framework introduce un doppio binario di validazione, sia qualitativo che quantitativo, applicato uniformemente a tutte le tecniche testate — Principal Component Analysis (PCA), Autoencoder Lineari (Linear AE), Autoencoder Profondi (AE) e Variational Autoencoder (VAE) — sia in fase di ricostruzione storica che, nel caso del VAE, in fase di generazione stocastica di nuove matrici campionate dallo spazio latente. L'integrazione di metriche di errore matematico classiche combinate con metriche topologiche finanziarie permette di valutare non solo l'accuratezza puntuale dei modelli, ma anche la conservazione delle proprietà strutturali profonde del mercato.

1.3 Obiettivi della tesi

Il presente lavoro di tesi si propone di progettare, implementare e validare un framework basato su architetture neurali profonde per la compressione, ricostruzione e generazione stocastica di matrici di correlazione finanziaria realistiche, finalizzato al miglioramento delle simulazioni di rischio.

Gli obiettivi specifici della ricerca possono essere declinati nei seguenti punti:

1. **Sviluppo della pipeline di pre-processing e campionamento:** Definire una procedura rigorosa per l'estrazione e la pulizia dei rendimenti dei titoli dell'S&P 500 (2000-2020), implementando il campionamento stratificato basato sui settori GICS per isolare i 100 asset di studio ed effettuando la scomposizione per estrarre le sole matrici triangolari inferiori come input ottimizzato.
2. **Studio comparativo e validazione multidimensionale:** Analizzare ed evidenziare quantitativamente le performance strutturali di PCA, Linear AE, AE e VAE nella fase di ricostruzione storica, calcolando e confrontando sistematicamente metriche matematiche di errore rigide quali il *Mean Squared Error* (MSE), il *Mean Absolute Error* (MAE) e la norma di Frobenius. Tale impianto quantitativo viene integrato da una valutazione qualitativa e topologica — applicata sia alle ricostruzioni storiche sia alle nuove matrici sintetizzate dal VAE — mediante algoritmi di *clustering* gerarchico per mappare visivamente la preservazione dei cluster settoriali e l'estrazione del *Minimum Spanning Tree* (MST) per misurare la fedeltà della connettività strutturale degli asset.
3. **Generazione stocastica e validazione tramite Stylized Facts:** Configurare l'impianto probabilistico del VAE per sintetizzare nuove matrici di correlazione tramite campionamento dello spazio latente, estendendo ad esse l'intero protocollo qualitativo/quantitativo e validandole rigorosamente rispetto ai cinque *stylized facts* fondamentali del mercato rispetto alla *Random Matrix Theory* (RMT).
4. **Integrazione e stima del rischio:** Applicare le matrici sintetiche generate e validate dal VAE all'interno di scenari Monte Carlo per calcolare il Value at Risk e l'Expected Shortfall di portafogli reali, dimostrando l'efficacia del framework nel catturare i rischi di coda in modo più robusto rispetto ai metodi storici convenzionali.

Capitolo 2

Matrici di Correlazione in Ambito Finanziario

2.1 Ruolo della correlazione nella Modern Portfolio Theory (Markowitz)

La formalizzazione moderna del concetto di diversificazione trova il suo fondamento matematico nella *Modern Portfolio Theory* (MPT) introdotta da Harry Markowitz nel 1952. Il paradigma fondamentale della MPT si basa sull'ipotesi che un investitore razionale selezioni le proprie strategie di allocazione considerando esclusivamente due parametri statistici: il rendimento atteso, inteso come misura del guadagno potenziale, e la varianza (o deviazione standard) dei rendimenti, assunta come metrica del rischio complessivo del portafoglio.

Si consideri un universo investibile composto da N attività finanziarie rischiose. Sia $\mathbf{r} = [r_1, r_2, \dots, r_N]^T \in \mathbb{R}^N$ il vettore aleatorio dei rendimenti dei singoli asset, con vettore dei valori attesi $\mathbb{E}[\mathbf{r}] = \boldsymbol{\mu} \in \mathbb{R}^N$. Un portafoglio è univocamente definito dal vettore dei pesi $\mathbf{w} = [w_1, w_2, \dots, w_N]^T \in \mathbb{R}^N$, dove ciascuna componente w_i rappresenta la frazione di capitale allocata nell'asset i -esimo, sotto il vincolo di piena allocazione delle risorse $\sum_{i=1}^N w_i = \mathbf{w}^T \mathbf{1} = 1$.

Il rendimento atteso del portafoglio, $E(R_p)$, è una combinazione lineare dei rendimenti attesi dei singoli titoli:

$$E(R_p) = \mathbb{E}[\mathbf{w}^T \mathbf{r}] = \mathbf{w}^T \boldsymbol{\mu} \quad (2.1)$$

Il rischio del portafoglio, espresso mediante la sua varianza σ_p^2 , è invece governato da una forma quadratica definita a partire dalla matrice di covarianza $\boldsymbol{\Sigma} \in \mathbb{R}^{N \times N}$:

$$\sigma_p^2 = \text{Var}(\mathbf{w}^T \mathbf{r}) = \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} = \sum_{i=1}^N \sum_{j=1}^N w_i w_j \sigma_{ij} \quad (2.2)$$

dove σ_{ij} rappresenta la covarianza tra i rendimenti dell'asset i e dell'asset j . La matrice di covarianza può essere fattorizzata isolando le componenti di volatilità individuale dalla

struttura di interdipendenza lineare. Sia $\mathbf{D} \in \mathbb{R}^{N \times N}$ la matrice diagonale contenente le deviazioni standard dei singoli asset, $\mathbf{D} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_N)$. La relazione fondamentale che lega la covarianza alla matrice di correlazione lineare di Pearson $\mathbf{C} \in \mathbb{R}^{N \times N}$ è espressa da:

$$\mathbf{\Sigma} = \mathbf{D}\mathbf{C}\mathbf{D} \quad (2.3)$$

In virtù della decomponevolezza espressa nella (2.3), l'elemento generico C_{ij} della matrice di correlazione corrisponde al coefficiente di correlazione strutturale $\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}$, vincolato geometricamente nell'intervallo $[-1, 1]$.

Il principio della diversificazione risiede interamente nelle proprietà algebriche di $\mathbf{C}$. Qualora i titoli presentino una correlazione lineare perfetta e positiva ($\rho_{ij} = 1 \forall i, j$), il rischio di portafoglio si riduce a una semplice media ponderata delle volatilità individuali, annullando qualsiasi effetto di mitigazione del rischio. Al contrario, la presenza di coefficienti $\rho_{ij} < 1$ garantisce che la deviazione standard del portafoglio sia strettamente inferiore alla combinazione lineare delle deviazioni standard dei singoli titoli.

Nell'ambito dell'ottimizzazione di portafoglio secondo il criterio media-varianza, l'obiettivo si traduce nella determinazione della frontiera efficiente tramite la risoluzione di problemi di programmazione quadratica del tipo:

$$\min_{\mathbf{w}} \frac{1}{2} \mathbf{w}^T \mathbf{\Sigma} \mathbf{w} \quad \text{s.t.} \quad \mathbf{w}^T \mathbf{1} = 1, \quad \mathbf{w}^T \boldsymbol{\mu} = \mu_{\text{target}} \quad (2.4)$$

In questo contesto, la matrice di correlazione opera come il nucleo geometrico che modella lo spazio delle soluzioni ammissibili. Errori di stima anche marginali nella struttura di $\mathbf{C}$ alterano drasticamente gli autovettori associati, distorcendo l'identificazione delle direzioni a varianza minima e conducendo a soluzioni di allocazione altamente instabili e inefficienti fuori campionario.

2.2 Il problema del rumore nelle matrici empiriche

Nella pratica finanziaria, la vera matrice di correlazione della popolazione non è osservabile direttamente. Di conseguenza, gli analisti si affidano allo stimatore campionario standard, partendo dai log-rendimenti storici degli asset. Data una serie storica di rendimenti per N attività finanziarie lungo un orizzonte temporale di T giorni, si definisce innanzitutto la matrice di covarianza empirica $\hat{\mathbf{\Sigma}}$, il cui elemento generico è calcolato come:

$$\hat{\Sigma}_{ij} = \frac{1}{T-1} \sum_{t=1}^T (r_{i,t} - \bar{r}_i)(r_{j,t} - \bar{r}_j) \quad (2.5)$$

dove $\bar{r}_i$ rappresenta la media campionaria del log-rendimento dell'asset i .

La matrice di correlazione empirica $\hat{\mathbf{C}}$ viene quindi derivata normalizzando le covarianze per il prodotto delle rispettive deviazioni standard campionarie $\hat{\sigma}$:

$$\hat{C}_{ij} = \frac{\hat{\Sigma}_{ij}}{\hat{\sigma}_i \hat{\sigma}_j} \quad (2.6)$$

Questo approccio incontra un limite strutturale severo, noto in letteratura come la “maledizione della dimensionalità” o problema del rumore statistico. L’accuratezza dello stimatore campionario dipende in modo critico dal parametro di spettro q , definito come il rapporto tra la dimensione spaziale e quella temporale del dataset:

$$q = \frac{N}{T} \quad (2.7)$$

Nei mercati finanziari moderni, la necessità di analizzare panieri ad alta dimensionalità (come nel caso dello studio di sottoinsiemi estesi dell’indice S&P 500, dove $N = 100$) si scontra sistematicamente con la limitatezza dei dati storici stazionari disponibili. All’aumentare del rapporto q , ovvero quando la lunghezza temporale T non è infinitamente superiore al numero di asset N , la matrice empirica $\hat{\mathbf{C}}$ accumula un livello di rumore campionario così elevato da perdere consistenza statistica.

Dal punto di vista dell’algebra lineare, l’instabilità si manifesta macroscopicamente attraverso lo spettro degli autovalori della matrice. Quando $q \rightarrow 1$, gli autovalori più piccoli di $\hat{\mathbf{C}}$ tendono artificialmente verso lo zero, mentre gli autovalori più grandi vengono sistematicamente sovrastimati rispetto ai loro controvalori teorici reali. Questo fenomeno distorce pesantemente l’inversione della matrice richiesta dagli algoritmi di ottimizzazione, poiché l’operazione di inversione $\hat{\mathbf{C}}^{-1}$ amplifica l’effetto degli autovalori artificialmente prossimi allo zero.

L’impatto operativo di tale distorsione è dirompente e viene definito in finanza quantitativa come il paradosso del *noise maximizer*. Gli algoritmi di ottimizzazione basati sul framework di Markowitz cercano intrinsecamente le combinazioni di asset in grado di minimizzare il rischio complessivo del sistema. Nel farlo, l’ottimizzatore seleziona preferenzialmente i pesi associati agli autovettori corrispondenti agli autovalori più piccoli della matrice empirica. Tuttavia, poiché in regime di q elevato tali autovalori minuscoli non descrivono reali relazioni di diversificazione economica ma sono meri artefatti statistici generati dal rumore di campionamento, l’algoritmo finisce per allocare la maggior parte del capitale all’interno del rumore stesso. Il risultato pratico è un collasso generalizzato delle performance del portafoglio non appena questo viene testato su dati reali fuori campionario (*out-of-sample breakdown*).

2.3 Utilizzo delle matrici per la generazione di scenari stocastici e stima del rischio (VaR)

Oltre all’allocazione ottimale delle risorse, la matrice di correlazione costituisce l’elemento cardine per i sistemi di gestione del rischio deputati alla simulazione di scenari futuri e al calcolo dei requisiti patrimoniali. Tra le metodologie standard impiegate dai risk manager quantitativi, la simulazione Monte Carlo rappresenta l’approccio più flessibile per modellare l’evoluzione congiunta di asset finanziari complessi.

Il motore di una simulazione Monte Carlo multivariata si basa sulla capacità di generare vettori di rendimenti sintetici che preservino rigorosamente la struttura delle dipendenze lineari osservata nel mercato reale. Supponendo di voler simulare un vettore di rendimenti futuri $\mathbf{r}_{\text{sim}} \in \mathbb{R}^N$ caratterizzato da un vettore di medie attese $\boldsymbol{\mu}$ e da una determinata

matrice di covarianza target $\Sigma = \mathbf{D}\mathbf{C}\mathbf{D}$, il processo matematico richiede l'estrazione di un vettore di variabili casuali indipendenti e identicamente distribuite $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N)$.

Per proiettare la struttura di correlazione sul vettore stocastico indipendente $\mathbf{z}$, si applica una decomposizione lineare basata sulla fattorizzazione della matrice di correlazione $\mathbf{C}$. Assumendo che $\mathbf{C}$ sia simmetrica e definita positiva, è possibile calcolare la sua decomposizione di Cholesky, che individua una matrice triangolare inferiore $\mathbf{L} \in \mathbb{R}^{N \times N}$ tale per cui:

$$\mathbf{C} = \mathbf{L}\mathbf{L}^T \quad (2.8)$$

Il vettore dei rendimenti simulati viene quindi sintetizzato applicando la trasformazione lineare:

$$\mathbf{r}_{\text{sim}} = \boldsymbol{\mu} + \mathbf{D}\mathbf{L}\mathbf{z} \quad (2.9)$$

Attraverso questa operazione, la matrice di covarianza dei rendimenti generati rispecchia esattamente la struttura desiderata, poiché:

$$\text{Var}(\mathbf{r}_{\text{sim}}) = \text{Var}(\mathbf{D}\mathbf{L}\mathbf{z}) = \mathbf{D}\mathbf{L}\text{Var}(\mathbf{z})\mathbf{L}^T\mathbf{D} = \mathbf{D}\mathbf{L}\mathbf{I}_N\mathbf{L}^T\mathbf{D} = \mathbf{D}\mathbf{C}\mathbf{D} = \Sigma \quad (2.10)$$

La generazione ripetuta di decine di migliaia di questi vettori stocastici permette di mappare la distribuzione di probabilità empirica delle perdite e dei guadagni futuri del portafoglio complessivo. Su questa distribuzione aggregata vengono calcolate le principali metriche di rischio di coda.

La prima metrica è il *Value at Risk* (VaR_α), definito come la perdita massima potenziale che il portafoglio può subire entro un determinato orizzonte temporale, dato un livello di confidenza statistica $\alpha \in (0, 1)$. Matematicamente, l'identificazione del VaR corrisponde al calcolo del quantile della distribuzione delle perdite del portafoglio L :

$$\inf\{L \in \mathbb{R} : \mathbb{P}(L > \text{VaR}_\alpha) \leq 1 - \alpha\} \quad (2.11)$$

Poiché il VaR non fornisce informazioni sull'entità delle perdite che superano la soglia del quantile, ad esso viene sistematicamente affiancato l'*Expected Shortfall* (ES_α), o *Conditional VaR*, che quantifica il valore atteso delle perdite condizionato al superamento del VaR stesso:

$$\text{ES}_\alpha = \mathbb{E}[L \mid L > \text{VaR}_\alpha] \quad (2.12)$$

Se la matrice di correlazione $\mathbf{C}$ utilizzata per alimentare la decomposizione di Cholesky è contaminata da rumore statistico o basata su assunzioni storiche eccessivamente rigide, l'intero motore Monte Carlo produce scenari distorti. Da un lato, le matrici empiriche rumorose possono perdere la proprietà algebrica di semidefinita positività a causa di arrotondamenti numerici o dati mancanti, rendendo impossibile il calcolo di $\mathbf{L}$. Dall'altro, i modelli deterministici tradizionali non sono in grado di catturare le variazioni strutturali e le interdipendenze asimmetriche che si attivano tipicamente durante le fasi di stress finanziario. Ciò porta a una grave sottostima dei co-movimenti sistemici in caso di crolli di mercato, generando scenari Monte Carlo artificialmente ottimistici che espongono le imprese a rischi di coda non coperti da adeguati buffer patrimoniali.

Capitolo 3

Fatti Stilizzati delle Matrici di Correlazione

3.1 Introduzione alle proprietà strutturali dei mercati reali

In finanza quantitativa, il termine *stylized facts* (fatti stilizzati) identifica un insieme di regolarità statistiche ed empiriche ampiamente verificate nei mercati finanziari globali, le quali risultano persistenti nel tempo, invarianti rispetto alle diverse asset class e indipendenti dagli specifici orizzonti temporali di campionamento. Sebbene l'andamento individuale dei prezzi dei titoli segua dinamiche fortemente stocastiche e apparentemente caotiche, le relazioni di interdipendenza congiunta manifestano vincoli geometrici e topologici estremamente rigidi.

Quando si analizza un sistema ad alta dimensionalità composto da attività finanziarie reali — come il paniere rappresentativo di 100 asset estratti dall'indice S&P 500 nell'orizzonte 2000-2020 — la relativa matrice di correlazione empirica $\hat{C}$ cessa di essere un mero aggregato statistico di coefficienti indipendenti. Essa assume invece la natura di un operatore strutturato che riflette l'organizzazione interna del sistema economico.

Identificare e formalizzare queste proprietà strutturali è un prerequisito fondamentale per la validazione di qualsiasi modello di compressione o generazione. Un framework generativo basato su *deep learning*, come un Variational Autoencoder, non deve semplicemente minimizzare un errore di ricostruzione puntuale (come l'MSE), ma deve dimostrare la capacità matematica di preservare e sintetizzare ex-novo tali regolarità biologiche del mercato. Al fine di tracciare un confine netto tra le informazioni strutturali e il rumore statistico puramente casuale, la letteratura scientifica definisce cinque proprietà geometriche essenziali che caratterizzano univocamente i mercati reali.

3.2 Distribuzione asimmetrica delle correlazioni pairwise

La prima proprietà macroscopica di una matrice di correlazione finanziaria reale risiede nella morfologia della distribuzione di probabilità dei suoi elementi fuori diagonale C_{ij} con $i \neq j$, noti come coefficienti *pairwise*.

In un mercato teorico puramente casuale, in cui i rendimenti dei titoli fossero ortogonali e statisticamente indipendenti, la distribuzione empirica dei coefficienti di correlazione si presenterebbe come una curva simmetrica centrata esattamente sullo zero, le cui fluttuazioni campionarie attorno al valore nullo dipenderebbero unicamente dalla limitatezza della serie storica T .

Al contrario, nei mercati finanziari reali si osserva un fenomeno sistematico di deviazione statistica (*distribution shift*). La distribuzione delle correlazioni *pairwise* è marcatamente asimmetrica e significativamente spostata verso valori positivi, con una media campionaria stabilmente superiore allo zero, tipicamente confinata nell'intervallo $[0.2, 0.5]$. Questo spostamento globale riflette l'esistenza del cosiddetto "effetto mercato" o fattore di rischio sistematico: in condizioni macroeconomiche ordinarie, e in modo ancora più esasperato durante i crolli finanziari, la quasi totalità degli asset tende a muoversi nella medesima direzione, spinta da shock sistemici globali che dominano sulle componenti idiosincratiche dei singoli titoli.

3.3 Analisi spettrale e distribuzione di Marchenko-Pastur

L'analisi dello spettro degli autovalori fornisce la descrizione algebrica più profonda della struttura informativa contenuta in $\hat{\mathbf{C}}$. Sia $\{\lambda_1, \lambda_2, \dots, \lambda_N\}$ l'insieme degli autovalori stabili della matrice di correlazione empirica, ordinati in senso decrescente tale per cui $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N$.

Il punto di riferimento matematico per isolare il rumore è fornito dalla *Random Matrix Theory* (RMT). Sotto l'ipotesi nulla che la matrice dei dati $\mathbf{X} \in \mathbb{R}^{N \times T}$ sia composta da variabili aleatorie indipendenti e identicamente distribuite con media nulla e varianza unitaria, lo spettro degli autovalori della matrice empirica, nel limite $N \rightarrow \infty, T \rightarrow \infty$ con rapporto di spettro $q = N/T$ costante, converge rigorosamente alla densità di probabilità di Marchenko-Pastur (MP):

$$P(\lambda) = \frac{1}{2\pi q} \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{\lambda} \cdot \mathbb{I}_{[\lambda_-, \lambda_+]}(\lambda) \quad (3.1)$$

I confini teorici dello spettro di puro rumore, noti come *bulk* di Marchenko-Pastur, sono definiti analiticamente dai limiti rigidi:

$$\lambda_{\pm} = (1 \pm \sqrt{q})^2 \quad (3.2)$$

Quando si analizza lo spettro di una matrice di correlazione reale, l'evidenza empirica mostra una violazione drammatica della legge di Marchenko-Pastur, ripartendo gli autovalori in tre componenti distinte:

1. **Il primo autovalore dominante** ($\lambda_1 \gg \lambda_+$): Si osserva un singolo autovalore di magnitudo straordinaria che si colloca ordini di grandezza al di sopra del limite superiore del *bulk* casuale. Questo autovalore cattura l'effetto mercato descritto nella sezione precedente e da solo spiega una frazione enorme (spesso superiore al 30-40%) della varianza totale del sistema finanziario.
2. **Gli autovalori settoriali intermedi** ($\lambda_k > \lambda_+$): Un ristretto numero di autovalori intermedi riesce a violare il limite λ_+ , posizionandosi al di fuori della densità di MP. Questi autovalori descrivono le interdipendenze stabili esistenti tra gruppi di asset appartenenti a specifici comparti industriali o economici.
3. **Il bulk del rumore** ($\lambda \leq \lambda_+$): La stragrande maggioranza dei rimanenti autovalori (spesso oltre il 90% del totale) rimane confinata all'interno dell'intervallo $[\lambda_-, \lambda_+]$. Questa porzione dello spettro è statisticamente indistinguibile dal puro rumore bianco, confermando che la frazione predominante delle relazioni puntuali descritte dalle matrici empiriche è priva di reale contenuto informativo stazionario.

3.4 Proprietà di Perron-Frobenius empirica

La natura dominante del primo autovalore λ_1 trova una rigorosa formalizzazione nelle proprietà dell'autovettore ad esso associato, indicato come $\mathbf{v}_1 = [v_{1,1}, v_{1,2}, \dots, v_{1,N}]^T$. In ambito puramente matematico, il teorema di Perron-Frobenius stabilisce che per matrici a elementi strettamente non negativi, l'autovettore principale possiede componenti tutte dello stesso segno.

Sebbene le matrici di correlazione finanziaria empiriche non siano strettamente non negative — poiché presentano fisiologicamente coefficienti negativi dovuti a coperture o dinamiche avverse — la forte dominanza delle correlazioni positive medie indotta dall'effetto mercato fa sì che il sistema finanziario manifesti una sorta di “proprietà di Perron-Frobenius empirica”.

Le implicazioni di questa proprietà si traducono in due vincoli algebrici per la matrice $\hat{\mathbf{C}}$:

1. **Unicità e non degenerazione:** L'autovalore massimo λ_1 è reale, strettamente positivo e possiede molteplicità uno. Ciò garantisce che la direzione a massima varianza dello spazio finanziario sia unica.
2. **Uniformità di segno:** Nonostante la presenza di correlazioni *pairwise* negative all'interno della matrice, tutti gli elementi del primo autovettore associato $\mathbf{v}_1$ presentano sistematicamente il medesimo segno algebrico. Per convenzione standard di normalizzazione, possono essere assunti come strettamente positivi ($v_{1,i} > 0 \forall i = 1, \dots, N$).

Dal punto di vista economico-finanziario, questa proprietà è cruciale. Poiché ciascuna componente $v_{1,i}$ quantifica il livello di partecipazione del titolo i -esimo al primo fattore principale, l'uniformità del segno dimostra che l'effetto mercato agisce in modo cooperativo su tutti i titoli del paniere. Pur con intensità diverse, nessuno degli asset analizzati si

muove strutturalmente in opposizione di fase rispetto al trend macroeconomico globale dominante.

3.5 Struttura gerarchica delle correlazioni

Un'altra proprietà fondamentale dei mercati reali è l'organizzazione sub-strutturale delle correlazioni secondo un principio gerarchico. All'interno del tessuto economico, le aziende non interagiscono in modo uniforme: imprese appartenenti alla medesima filiera o al medesimo comparto industriale (es. *Information Technology* o *Energy*) manifestano livelli di co-movimento mutuo significativamente più intensi rispetto a quelli registrati tra aziende operanti in settori ortogonali.

Se si applica un algoritmo di ordinamento ottimale basato su metriche di clustering gerarchico sulla matrice $\hat{\mathbf{C}}$, l'organizzazione interna si palesa visivamente sotto forma di blocchi densi disposti lungo la diagonale principale. Questa struttura ad albero (esprimibile analiticamente mediante dendrogrammi) dimostra che il mercato è organizzato secondo un'architettura multi-scala: un livello globale (effetto mercato), macro-cluster stabili (i settori GICS) e micro-aggregazioni locali (le sotto-industrie). La preservazione di tale gerarchia è il test fondamentale per determinare se un modello architetturale profondo stia apprendendo la reale tassonomia economica dei dati.

3.6 Il Minimum Spanning Tree (MST) e la proprietà scale-free

Per estrarre l'ossatura topologica essenziale eliminando le ridondanze informative della matrice di correlazione, la finanza quantitativa utilizza strumenti derivati dalla teoria dei grafi. Il metodo d'elezione consiste nella costruzione del *Minimum Spanning Tree* (Albero di Espansione Minima).

Il primo passaggio richiede la trasformazione della matrice dei coefficienti di correlazione $\mathbf{C}$ in una matrice delle distanze geometriche $\mathbf{D}_{\text{graph}}$. Per ridefinire gli elementi C_{ij} come distanze metriche reali che soddisfino gli assiomi di positività, simmetria e disuguaglianza triangolare, si applica la trasformazione non lineare:

$$d_{ij} = \sqrt{2(1 - C_{ij})} \quad (3.3)$$

Il coefficiente d_{ij} assume valore 0 in caso di correlazione perfetta positiva ($C_{ij} = 1$), valore $\sqrt{2}$ per asset indipendenti ($C_{ij} = 0$) e valore 2 per titoli perfettamente anticorrelandoli ($C_{ij} = -1$).

Utilizzando la matrice delle distanze come mappa dei pesi di un grafo completo, si applicano algoritmi classici di ottimizzazione combinatoria (quali l'algoritmo di Kruskal o di Prim) per estrarre l'MST. L'MST è un sottografo connesso e privo di cicli che collega tutti gli N nodi (gli asset) selezionando gli $N - 1$ archi che minimizzano la somma totale delle distanze geometriche.

La proprietà stilizzata che qualifica gli MST dei mercati finanziari reali è la natura *scale-free* (invariante di scala) della loro topologia di rete. Sia k_i il grado del nodo i -esimo, definito come il numero di archi incidenti sul nodo stesso nell'albero ottimizzato. Nei mercati reali, la distribuzione empirica del grado dei nodi $P(k)$ non segue una curva gaussiana o poissoniana, ma è governata da una legge di potenza:

$$P(k) \propto k^{-\gamma} \quad (3.4)$$

dove γ rappresenta l'esponente di scala strutturale, solitamente confinato nell'intervallo $2 < \gamma < 3$.

La validità della legge di potenza implica la presenza di una topologia fortemente accentrata. L'MST finanziario è dominato da pochissimi nodi ad altissima connettività, definiti *hubs* super-connessi, che agiscono come centri collettori dell'informazione finanziaria (tipicamente grandi aziende leader di settore o holding sistemiche), attorno ai quali si dispongono radialmente ampi cluster di nodi periferici a basso grado (nodi foglia).

3.7 Benchmark test: fallimento strutturale della Random Matrix Theory

Al fine di validare rigorosamente la significatività statistica dei cinque fatti stilizzati descritti, viene definito un protocollo di *benchmark test* basato sul confronto diretto tra le matrici finanziarie reali e le matrici puramente casuali generate sinteticamente tramite i teoremi della Random Matrix Theory.

Generando una matrice di controllo mediante l'estrazione di N serie temporali di puro rumore gaussiano bianco i.i.d., si costruisce la corrispondente matrice di correlazione casuale. Sottoponendo tale matrice al medesimo protocollo di analisi qualitativo e quantitativo, si registra un fallimento strutturale sistematico nell'adempimento delle proprietà del mercato reale:

Stylized Fact	Mercato Reale (S&P 500)	Benchmark RMT (Pure Noise)
Distribuzione <i>Pairwise</i>	Fortemente asimmetrica, shifted verso valori positivi.	Perfettamente simmetrica e centrata sullo zero.
Spettro degli Autovalori	Presenza di $\lambda_1 \gg \lambda_+$ (mercato) e $\lambda_k > \lambda_+$ (settori).	Interamente vincolato entro i limiti di MP: $[\lambda_-, \lambda_+]$.
Proprietà di Perron-Frobenius	Valida: $\mathbf{v}_1$ ha componenti unicamente positive.	Fallita: $\mathbf{v}_1$ ha componenti a segni casuali stocastici.
Organizzazione Interna	Struttura gerarchica e tassonomica a blocchi settoriali.	Assenza totale di pattern; matrice omogenea amorfa.
Topologia dell'MST	Rete <i>scale-free</i> retta da legge di potenza con <i>hubs</i> .	Grafo casuale omogeneo privo di nodi centrali dominanti.

Tabella 3.1. Quadro comparativo strutturale tra le proprietà geometriche dei mercati reali e il benchmark probabilistico della Random Matrix Theory.

Questo fallimento radicale dimostra matematicamente che i cinque fatti stilizzati costituiscono la firma geometrica esclusiva dell'informazione finanziaria reale. Qualsiasi modello generativo profondo non può limitarsi a operare nel dominio di metriche rigide di errore quadratico medio, ma deve necessariamente superare questo *benchmark test*. Il Variational Autoencoder, per essere considerato un valido motore stocastico di scenari, dovrà generare matrici sintetiche dallo spazio latente che non solo si discostino dal rumore di MP, ma che replichino fedelmente tutte le asimmetrie e le leggi di potenza che la Random Matrix Theory non è in grado di spiegare.

Parte II

Metodologia e Pipeline di
Analisi

Parte III

Risultati, Validazione e Applicazioni

